

Supplementary Material: Информационная НОСТАЛЬГИЯ

Александр Андришин^{1*}

^{1*}Independent Researcher, Москва, Россия.

Corresponding author(s). E-mail(s): alexander@andriishin.com;

S1. Полное доказательство Замечания 6 (softmax-regularity для OU)

Замечание 6 (§ 4.4) утверждает: в OU-классе § 5.2 экспоненциальная декорреляция автоковариации логитов $\theta_v(t)$ переносится через softmax на любой ограниченный измеримый функционал $\xi(\theta_v)$ (в частности, на элементы матрицы переходов $P_{ij}(\theta_v)$ и на любую достаточную статистику предсказания; при этом ковариация ξ затухает с характерным временем τ_E , тогда как условная МП — вдвое быстрее, с $\tau_E/2$, поскольку $I \approx \frac{1}{2}\rho^2$ при малой корреляции, см. S1.5a). Доказательство — пять шагов: (i) Lipschitz softmax в ℓ_∞ ; (ii) перенос на TV матрицы переходов; (iii) ограниченность OU-траектории на шаре $R(\delta)$ с вероятностью $1-\delta$; (iv) перенос затухания на ковариацию ξ ; (v) перевод TV-границы в границу для условной МП.

S1.1 Шаг 1. Lipschitz-непрерывность softmax

Пусть $\text{softmax} : \mathbb{R}^k \rightarrow \Delta^{k-1}$ — стандартное отображение $\text{softmax}_i(\theta_v) = \exp \theta_i / \sum_j \exp \theta_j$. Якобиан имеет вид $\partial \text{softmax}_i / \partial \theta_j = \text{softmax}_i(\delta_{ij} - \text{softmax}_j)$; диагональные элементы $p_i(1-p_i) \geq 0$, недиагональные $-p_i p_j \leq 0$, при этом сумма модулей по столбцу не превышает $2p_j$. Стандартное следствие — оценка в ℓ_1/ℓ_∞ парности:

$$\|\text{softmax}(\theta_v) - \text{softmax}(\theta'_v)\|_1 \leq 2 \|\theta_v - \theta'_v\|_\infty. \quad (\text{S1.1})$$

Вывод (S1.1) через операторную норму Якобиана. Якобиан $J(\theta_v) = \text{diag}(p) - pp^T$ (где $p = \text{softmax}(\theta_v)$) оценивается в индуцированной норме $\ell_\infty \rightarrow \ell_1$: для любого v с $\|v\|_\infty \leq 1$

$$\|Jv\|_1 = \sum_i \left| \sum_j J_{ij} v_j \right| \leq \sum_i \sum_j |J_{ij}| = \sum_j \left(\sum_i |J_{ij}| \right),$$

а столбцовая сумма модулей равна $|J_{jj}| + \sum_{i \neq j} |J_{ij}| = p_j(1 - p_j) + \sum_{i \neq j} p_i p_j = p_j(1 - p_j) + p_j(1 - p_j) = 2p_j(1 - p_j) \leq 2p_j$. Суммируя по j ,

$$\|J\|_{\infty \rightarrow 1} = \sup_{\|v\|_\infty \leq 1} \|Jv\|_1 \leq \sum_j 2p_j(1 - p_j) \leq 2 \sum_j p_j = 2.$$

Интегрируя вдоль прямой $\theta_v(s) = \theta_v + s(\theta'_v - \theta_v)$, $s \in [0, 1]$,

$$\|\text{softmax}(\theta_v) - \text{softmax}(\theta'_v)\|_1 = \left\| \int_0^1 J(\theta_v(s)) (\theta'_v - \theta_v) ds \right\|_1 \leq \sup_s \|J(\theta_v(s))\|_{\infty \rightarrow 1} \|\theta'_v - \theta_v\|_\infty \leq 2\|\theta'_v - \theta_v\|_\infty,$$

что и даёт (S1.1). Оценка $\|J\|_{\infty \rightarrow 1} \leq 2$ равномерна по θ_v (не зависит ни от точки линеаризации, ни от размерности k), поэтому константа 2 глобальна; она достигается в пределе двухточечной концентрации $p \rightarrow (\frac{1}{2}, \frac{1}{2}, 0, \dots)$, т.е. оптимальна. Стандартный результат, без дополнительных предположений о размерности k .

S1.2 Шаг 2. Перенос на total variation матрицы переходов

В ОУ-параметризации § 5.2 строки матрицы переходов задаются построчным softmax над логитами: $P_{ij}(\theta_v) = \exp \theta_{ij} / \sum_l \exp \theta_{il}$, причём по соглашению $\theta_{ii} \equiv 0$. Для каждой строки i применяя (S1.1) к векторам $(\theta_{ij})_{j=1}^k$ и $(\theta'_{ij})_{j=1}^k$:

$$\|P_{i,\cdot}(\theta_v) - P_{i,\cdot}(\theta'_v)\|_1 \leq 2 \max_j |\theta_{ij} - \theta'_{ij}|.$$

В терминах TV-расстояния между распределениями $P_{i,\cdot}(\theta_v)$ и $P_{i,\cdot}(\theta'_v)$ (половина ℓ_1 -расстояния, $\|\mu - \nu\|_{TV} = \frac{1}{2} \|\mu - \nu\|_1$) получается

$$\|P_{i,\cdot}(\theta_v) - P_{i,\cdot}(\theta'_v)\|_{TV} \leq \max_j |\theta_{ij} - \theta'_{ij}| \leq \|\theta_v - \theta'_v\|_\infty. \quad (\text{S1.2})$$

Это даёт row-wise Lipschitz-константу $L = 1$ для softmax-параметризации матрицы переходов. Координатное ограничение (вместо полной $\|\theta_v - \theta'_v\|_\infty$ по всем строкам) существенно для шага S1.4: $K = k(k-1)$ компонент логитов ОУ-системы независимы (диагональный анкер $\theta_{ii} \equiv 0$), и каждая строка матрицы зависит лишь от своей подсистемы из $k-1$ компонент.

S1.3 Шаг 3. Ограниченность траектории ОУ с высокой вероятностью

ОУ-процесс на каждой координате θ_{ij} в стационарном режиме гауссов, $\mathcal{N}(0, \sigma^2/(2\lambda))$; автоковариация $\mathbb{E}[\theta_{ij}(t)\theta_{ij}(s)] = (\sigma^2/(2\lambda)) e^{-|t-s|/\tau_E}$ с $\tau_E = 1/\lambda$. По неравенству концентрации липшицевых функционалов гауссовой меры

(Борелла—Чирельсона, стандартный результат теории гауссовых процессов). Выпишем оценку. Для *фиксированного* момента $\theta_{ij}(t) \sim \mathcal{N}(0, \sigma_0^2)$, $\sigma_0^2 = \sigma^2/(2\lambda)$, стандартный гауссов хвост даёт $\Pr[|\theta_{ij}(t)| > R] \leq 2 \exp(-R^2/(2\sigma_0^2)) = 2 \exp(-R^2\lambda/\sigma^2)$ (подстановка $2\sigma_0^2 = \sigma^2/\lambda$). Для *супремума по* $[0, T]$ теорема Борелла—Чирельсона даёт $\Pr[\sup_{[0, T]} |\theta_{ij}| > \mathbb{E} \sup + u] \leq \exp(-u^2/(2\sigma_0^2))$ с тем же масштабом дисперсии σ_0^2 ; математическое ожидание супремума $\mathbb{E} \sup_{[0, T]} |\theta_{ij}| \lesssim \sigma_0 \sqrt{2 \ln(T/\tau_E)}$ (по $\sim T/\tau_E$ эффективно независимым OU-экскурсиям длины τ_E) отделяет вклад длины окна. Union bound по K координатам (и двусторонний множитель 2): приравнявая $K \cdot 2 \exp(-R^2\lambda/\sigma^2) = \delta$ и разрешая относительно R , получаем радиус

$$R(\delta) = \sigma \sqrt{\ln(2K/\delta)/\lambda}, \quad (\text{S1.3})$$

обеспечивающий $\Pr[\sup_{[0, T], ij} |\theta_{ij}(t)| > R(\delta)] \leq \delta$. Вклад супремума по $[0, T]$ (аддитивный $\ln(T/\tau_E)$ под корнем от $\mathbb{E} \sup$) субведущ по сравнению с параметрическим счётом $\ln(2K/\delta)$ и поглощён в δ -бухгалтерию; форма (S1.3) удерживает явную зависимость от числа координат K . На событии $\{\|\theta_v(t)\|_\infty \leq R(\delta)\}$ применима локальная Lipschitz-константа softmax (S1.2), а через произведение мер $\Pr[A_s \cap A_t] \geq 1 - 2\delta$ — для пары моментов (s, t) одновременно.

S1.4 Шаг 4. Перенос экспоненциального затухания на ξ

Пусть $\xi : \mathbb{R}^K \rightarrow \mathbb{R}$ — ограниченная измеримая функция, $|\xi| \leq B$, Lipschitz по координате с константой L_ξ в ℓ_∞ -метрике: $|\xi(\theta_v) - \xi(\theta'_v)| \leq L_\xi \|\theta_v - \theta'_v\|_\infty$ (для row-wise softmax-проекции $L_\xi \leq 1$ по (S1.2)). Ковариация ξ в стационарном режиме OU оценивается через её представление как разность произведений:

$$\text{Cov}(\xi(\theta_v(t)), \xi(\theta_v(s))) = \mathbb{E}[(\xi(\theta_v(t)) - \bar{\xi})(\xi(\theta_v(s)) - \bar{\xi})],$$

где $\bar{\xi} = \mathbb{E}[\xi(\theta_v)]$ под стационарной мерой. *Разбиение события/дополнение.* Пусть $A = \{\|\theta_v(t)\|_\infty \leq R(\delta)\} \cap \{\|\theta_v(s)\|_\infty \leq R(\delta)\}$ — событие ограниченности обеих траекторий (шаг S1.3, $\Pr[A^c] \leq 2\delta$), $\mathbf{1}_A$ — его индикатор, $\xi_t := \xi(\theta_v(t))$. Раскладываем ковариацию:

$$\text{Cov}(\xi_t, \xi_s) = \underbrace{\mathbb{E}[(\xi_t - \bar{\xi})(\xi_s - \bar{\xi})\mathbf{1}_A]}_{(I)} + \underbrace{\mathbb{E}[(\xi_t - \bar{\xi})(\xi_s - \bar{\xi})\mathbf{1}_{A^c}]}_{(II)}.$$

Дополнение (II). Тривиально $|\xi_t - \bar{\xi}| \leq 2B$ (так как $|\xi| \leq B$), поэтому $|(II)| \leq (2B)^2 \Pr[A^c] \leq 8B^2\delta$; удобно удерживать более грубую константу и записать вклад дополнения как $2B^2\delta$ после нормировки δ -порога (перенос множителя в выбор δ ниже). *Ведущий член (I) через Коши—Шварца.* На событии A функционал липшицев вдоль OU-координат: центрируя в точке симметрии $\theta_v = 0$ и применяя (S1.2)-Lipschitz $|\xi_t - \bar{\xi}| \leq L_\xi \|\theta_v(t)\|_\infty$, по неравенству Коши—Шварца

$$|(I)| \leq L_\xi^2 \left| \mathbb{E}[\langle \theta_v(t), \theta_v(s) \rangle] \right| \leq L_\xi^2 \sum_{ij} |\mathbb{E}[\theta_{ij}(t)\theta_{ij}(s)]|,$$

а стандартная автоковариация OU $\mathbb{E}[\theta_{ij}(t)\theta_{ij}(s)] = (\sigma^2/(2\lambda))e^{-|t-s|/\tau_E}$ переносит экспоненту (для скалярного row-wise ξ , зависящего от одной координатной

подсистемы, сумма редуцируется к ведущему масштабу $\sigma^2/(2\lambda)$). Собирая (I) и (II) и удерживая множитель $2B$ от ограниченности ξ в ведущем члене (огрубление $L_\xi \|\theta_v\|_\infty \leq 2B$ вне режима малых логитов):

$$|\text{Cov}(\xi(\theta_v(t)), \xi(\theta_v(s)))| \leq 2B \cdot L_\xi \cdot \frac{\sigma^2}{2\lambda} \cdot e^{-|t-s|/\tau_E} + 2B^2\delta, \quad (\text{S1.4})$$

где второе слагаемое — поправка от события малой вероятности шага S1.3, в котором траектория выходит за шар радиуса $R(\delta)$. *Оптимизация δ* . Параметр δ свободен; выбор $\delta = e^{-|t-s|/\tau_E}$ (разнос порога по характерному времени декорреляции) обращает поправочный член $2B^2\delta$ в $2B^2e^{-|t-s|/\tau_E}$ — тот же экспоненциальный порядок, что и ведущий член. Тогда обе части (S1.4) несут общий множитель $e^{-|t-s|/\tau_E}$, и коэффициенты складываются: первый член даёт $2B \cdot L_\xi \cdot \sigma^2/(2\lambda) = BL_\xi\sigma^2/\lambda$, второй — $2B^2$. Окончательно: для любого ограниченного измеримого ξ с Lipschitz-константой L_ξ по координате логитов

$$|\text{Cov}(\xi(\theta_v(t)), \xi(\theta_v(s)))| \leq C_1(B, L_\xi, \sigma, \lambda) \cdot e^{-|t-s|/\tau_E}, \quad (\text{S1.4}')$$

с явной константой $C_1 = (BL_\xi\sigma^2/\lambda) + 2B^2$ (первое слагаемое — от Lipschitz-переноса автоковариации, второе — от δ -поправки при оптимальном $\delta = e^{-|t-s|/\tau_E}$; меньшая константа достижима при более тонком балансе двух вкладов, но порядок $\sigma^2/\lambda + B$ не улучшаем). Экспоненциальное затухание автоковариации θ_v переносится на ξ с тем же характерным временем τ_E (для ковариации ξ ; условная MI ниже, S1.5, затухает вдвое быстрее — с $\tau_E/2$, поскольку $I \approx \frac{1}{2}\rho^2$) — это и есть содержательное утверждение Замечания 6.

S1.5 Шаг 5. Перенос на условную взаимную информацию

Цепочка «ковариация $\xi \rightarrow \text{MI}$ » через inverse Pinsker (Sason—Verdú-типа) требует ограниченности log-density ratio $\alpha = \log \|dP/dQ\|_\infty$, что для softmax-параметризации универсально не выполнено: даже на шаре $R(\delta)$ шага S1.3 даёт $\alpha \leq 2R(\delta) + \log k$, а не просто $\log k$. Поэтому шаг S1.5 строится через *MI-tensorisation* по независимым координатам OU с последующим DPI на ξ — формально корректную замену. Прямая χ^2 -tensorisation здесь неприменима: χ^2 мультипликативна по независимости координат ($1 + \chi_{\text{joint}}^2 = \prod_{ij}(1 + \chi_{\text{coord}}^2)$), а не аддитивна, поэтому наивное неравенство « $\chi_{\text{joint}}^2 \leq K\chi_{\text{coord}}^2$ » неверно для χ^2 и обходится через MI-tensorisation, которая аддитивна именно потому, что MI аддитивна по независимым координатам.

Шаг 5a. $KL \leq \chi^2$ как вспомогательная оценка на координате. Стандартное неравенство (стандартное неравенство $D_{KL} \leq \chi^2$; связь $D_{KL} \leftrightarrow \chi^2$ — Cover and Thomas 2006, Проблема 11.2): для любых P_{XY}, P_X, P_Y

$$I(X; Y) = D_{KL}(P_{XY} \| P_X \otimes P_Y) \leq \chi^2(P_{XY} \| P_X \otimes P_Y).$$

Это неравенство не требует ограниченности density ratio; оно держится в любой σ -алгебре. В шагах ниже оно применяется *только покоординатно* для обоснования асимптотики $I_{\text{coord}} = \frac{1}{2}\rho^2(1 + o(1))$, не для тензоризации.

Шаг 5b. MI для бивариантной гауссовой пары на координате. Для одной координаты θ_{ij} в стационарном OU пара $(\theta_{ij}(t), \theta_{ij}(s))$ — гауссова с нормированной

корреляцией $\rho(t, s) = e^{-|t-s|/\tau_E}$. Стандартная формула для МП бивариантного гауссова распределения с маргинальной дисперсией $\sigma_0^2 = \sigma^2/(2\lambda)$:

$$I(\theta_{ij}(t); \theta_{ij}(s)) = -\frac{1}{2} \ln(1 - \rho^2(t, s)). \quad (\text{S1.5a})$$

При $|t - s| \geq \tau_E$ имеем $\rho^2 \leq e^{-2} < 0,14$, и разложение Тейлора даёт $I_{\text{coord}} = \frac{1}{2}\rho^2 + O(\rho^4) \leq \frac{1}{2}\rho^2(1 + o(1)) \leq \frac{1}{2}e^{-2|t-s|/\tau_E}$. Альтернативное выражение через χ^2 ($\chi_{\text{coord}}^2 = \rho^2/(1 - \rho^2)$ — прямое вычисление) даёт тот же лидирующий член $\frac{1}{2}\rho^2$ через шаг 5а с показателем экспоненты $2/\tau_E$ (не $1/\tau_E$); МП и χ^2 на координате согласуются по асимптотике.

Шаг 5с. МП-тензоризация по K независимым координатам. МП аддитивна по статистически независимым парам (Cover and Thomas 2006, гл. 2.5): координаты ОУ независимы по построению (шаг S2.1: W_{ij} независимы; ковариация диагональна), и поэтому

$$I(\theta_v(t); \theta_v(s)) = \sum_{ij} I(\theta_{ij}(t); \theta_{ij}(s)) \leq \frac{K}{2} \cdot e^{-2|t-s|/\tau_E} \cdot (1 + o(1)). \quad (\text{S1.5b})$$

Аддитивность МП по независимым координатам *корректна* и обходит χ^2 -tensorisation-ловушку (мультипликативность $\prod_{ij}(1 + \chi_{\text{coord}}^2)$ против ожидаемой суммы $\sum_{ij} \chi_{\text{coord}}^2$): МП аддитивна, χ^2 — нет, и потому переход к итоговой константе $K/2$ делается через МП, а не через χ^2 .

Шаг 5d. DPI на ξ и итоговая граница МП. МП монотонна под измеримыми отображениями (Cover and Thomas 2006, гл. 2.8): огрубление вектора $\theta_v(\cdot)$ через ограниченный измеримый ξ не увеличивает МП пары $(\xi(\theta_v(t)), \xi(\theta_v(s)))$ сверх МП исходной пары $(\theta_v(t), \theta_v(s))$. Объединяя шаги 5b–5с: для $|t - s| \geq \tau_E$

$$I(\xi(\theta_v(t)); \xi(\theta_v(s))) \leq I(\theta_v(t); \theta_v(s)) \leq C_2 \cdot e^{-2|t-s|/\tau_E}, \quad (\text{S1.5})$$

с явной константой $C_2 = K/2 \cdot (1 + o(1))$. Lipschitz-структура ξ (шаг S1.4) и ограниченность $|\xi| \leq B$ при этом не используются для МП-границы — они нужны лишь для константы в координатном масштабе ковариационной формы (S1.4'). Условие по $M_{\leq t}^{\text{refr}}$: stale-координаты $(\xi(\theta_v(t)), \xi(\theta_v(s)))$ независимы от refresh-координат $M_{\leq t}^{\text{refr}}$ (покоординатная независимость ОУ-логитов, § S2.1), поэтому обусловливание на $M_{\leq t}^{\text{refr}}$ не меняет их МП: $I(\xi_t; \xi_s \mid M_{\leq t}^{\text{refr}}) = I(\xi_t; \xi_s) \leq (\text{S1.5})$ (в общем случае условная МП могла бы превышать безусловную — здесь равенство даёт именно независимость координат); поправка стандартного концентрационного шага S1.3 (выход траектории за шар радиуса $R(\delta)$) входит в добавочное слагаемое $\delta \cdot \ln k$ итогового утверждения (S1.6). *Вывод $\delta \ln k$.* Разложим МП по событию A ограниченности (шаг S1.3, $\Pr[A^c] \leq \delta$) и его дополнению. На A^c проекция $\xi = P_{ij}(\theta_v)$ принимает значения в k -симплексе строки, так что её энтропия — а значит и любая МП с её участием — тривиально ограничена $H(\xi) \leq \ln k$; вклад дополнения в условную МП не превосходит $\Pr[A^c] \cdot H(\xi) \leq \delta \ln k$. На A действует экспоненциальная граница (S1.5). Суммируя,

$$I(\xi_t; \xi_s \mid M_{\leq t}^{\text{refr}}) \leq \underbrace{C_2 e^{-2|t-s|/\tau_E}}_{\text{событие } A} + \underbrace{\delta \ln k}_{\text{дополнение } A^c},$$

что и есть правая часть (S1.6).

Альтернативная цепочка. То же затухание получается через Mehler-полугрупповое представление ОУ и спектральную щель эргодической диффузии: для стационарной ОУ-меры и ограниченных измеримых ξ корреляции и МІ убывают по стандартному результату о спектральной щели гауссовых полугрупп (Bakry—Émery функциональное неравенство; см. (Pavliotis 2014, гл. 4) о спектральном разложении ОУ и экспоненциальной эргодичности; альтернативно — обзор в (Levin et al. 2017, гл. 13) для дискретного аналога mixing-times). Эта формулировка короче, но требует ссыльного аппарата за пределами § 5.2; цепочка через МІ-tensorisation (шаги 5b–5c) — формально самодостаточна в рамках данной работы.

S1.6 Итоговое утверждение

Лемма S1 (supplementary, softmax-regularity ОУ). В классе § 5.2 (ОУ-параметризация логитов $\theta_v(t) \in \mathbb{R}^K$ с характерным временем $\tau_E = 1/\lambda$ и стационарной дисперсией $\sigma^2/(2\lambda)$) для любого ограниченного измеримого функционала $\xi : \mathbb{R}^K \rightarrow \mathbb{R}$ с $|\xi| \leq B$ и Lipschitz-константой L_ξ по координате логитов в ℓ_∞ -метрике, и для любого $\delta \in (0, 1)$ существует константа $C = C(\delta, B, L_\xi, \sigma, \lambda, k)$ такая, что для всех s, t с $|t - s| \geq \tau_E$ выполняется

$$I(\xi(\theta_v(t)); \xi(\theta_v(s)) \mid M_{\leq t}^{\text{refr}}) \leq C \cdot e^{-2|t-s|/\tau_E} + \delta \cdot \ln k. \quad (\text{S1.6})$$

В частности, для проекций $P_{ij}(\theta_v(\cdot))$ row-wise softmax-параметризации матрицы переходов выполнено $L_\xi \leq 1$ и $B \leq 1$, что даёт явную константу C , не зависящую от k при фиксированном σ^2/λ .

Лемма S1 формально замыкает шаг доказательства Леммы 2 (§ 4.4), требующий обнуления $I(M^{\text{stale}}; X_E \mid M^{\text{refr}})$ при $\Delta t \gg \tau_E$. Свёртка по FIFO-возрастам. При FIFO refresh-фракция c обновляет долю c координат за τ_E , так что каждая координата проходит полный цикл обновления за $T_c = \tau_E/c$, и возрасты a (время с последнего обновления) равномерно распределены на $[0, T_c]$ с плотностью $|M_{\leq t}|/T_c = |M_{\leq t}|c/\tau_E$ бит на единицу возраста. Stale-фракция — координаты с $a > \tau_E$; их суммарный вклад в МІ, по покоординатной границе (S1.6) $I_{\text{bit}}(a) \leq C e^{-2a/\tau_E} + \delta \ln k$, есть

$$I(M^{\text{stale}}; X_E \mid M^{\text{refr}}) \lesssim \frac{|M_{\leq t}|c}{\tau_E} \int_{\tau_E}^{T_c} C e^{-2a/\tau_E} da = \frac{|M_{\leq t}|c}{\tau_E} \cdot \frac{C\tau_E}{2} (e^{-2} - e^{-2T_c/\tau_E}) \leq \frac{C e^{-2}}{2} |M_{\leq t}|c.$$

Экспонента интегрируется в константу, оставляя линейный по c префактор: нормируя на $I_{\text{pred}}^{\text{opt}}$, вклад stale-фракции есть $O(c)$, что и используется в основном доказательстве Леммы 2 при подстановке в (8a) через (7) (добавочный $\delta \ln k$ -хвост суммируется в тот же $O(c)$ при δ -калибровке порога $\delta = e^{-2}$). Условие $|t - s| \geq \tau_E$ — характерный масштаб, на котором экспонента не вырождена; для $|t - s| < \tau_E$ МІ

ограничена $H(\xi) \leq \ln k$ тривиально, что укладывается в добавочное константное слагаемое.

S2. Полное доказательство Замечания 5 (per-bit-uniformity для OU)

Замечание 5 (§ 4.4) утверждает аддитивность МП по независимо обновляемым координатам логитов OU-параметризации § 5.2 с константой $1 + o(1)$ — допущение Леммы 2, обеспечивающее переход от арифметической доли обновлённых битов c к информационно-теоретической границе $\nu^{\text{theor}} \geq 1 - c$ на шкале недобора прогноза (нормировка на $I_{\text{pred}}^{\text{opt}}$) в slow-driving пределе. Доказательство: (i) OU как K независимых процессов; (ii) гауссов апостериор по каждой координате; (iii) точная аддитивность МП по координатам; (iv) FIFO в K -координатной декомпозиции; (v) сравнение с оптимальным наблюдателем; (vi) итоговая граница с $\kappa = 1 + o(1)$; (vii) пределы при нарушении независимости.

S2.1 OU как K независимых процессов на координатах

В § 5.2 / § 6.2 OU-параметризация задаёт логиты $\theta_{ij}(t)$ ($i \neq j$, $K = k(k-1)$ свободных параметров) как независимые одномерные процессы:

$$d\theta_{ij} = -\lambda(\theta_{ij} - \theta_{ij}^*) dt + \sigma dW_{ij}, \quad (\text{S2.1})$$

где W_{ij} — независимые винеровские процессы, $\theta_{ij}^* = 0$ по конвенции § 6.2. Диагональные логиты $\theta_{ii} \equiv 0$ фиксированы как анкер softmax-нормировки. Совместное распределение $\theta_v(t) = (\theta_{ij}(t))_{ij}$ в стационарном режиме — гауссово с диагональной ковариацией $\Sigma = (\sigma^2/(2\lambda))I_K$: координаты статистически независимы.

S2.2 Гауссов апостериор по каждой координате

При наблюдении $X_E^{[0,t]}$ под истинным $P(t) = \text{softmax}(\theta_v(t))$ апостериор обучателя по $\theta_v(t)$ при регулярной параметрической оценке (MLE или Роббинс–Монро приближение к байесовскому обновлению § 6.2) асимптотически нормален с ковариацией $\Sigma_{\text{post}}(t)$, элементы которой убывают как $O(1/t)$ — стандартный результат об асимптотической нормальности оценок максимального правдоподобия для регулярных семейств (Clarke and Barron 1990, § 3).

Блочная структура Фишера. Информационная матрица $\mathcal{F}(\theta_v)$ для OU с независимыми координатами и построчным softmax — блочно-диагональна по строкам i : разные строки дают независимый вклад в правдоподобие через независимые выборки $\{X_t \rightarrow X_{t+1}\}$ при $X_t = i$. Аддитивность по строкам — точная, не приближённая.

Within-row coupling. Внутри строки i Fisher-блок имеет вид $\mathcal{F}^{(i)}(\theta_v) = n_i(t) \cdot (\text{diag}(p_i) - p_i p_i^T)$, где $p_i = (P_{ij})_{j=1}^k$ — i -я строка softmax и $n_i(t)$ — число посещений

состояния i к моменту t . Эта матрица softmax-Fisher **не диагональна**: softmax-нормировка связывает все j через общий знаменатель. Точная аддитивность диагонального приближения $\Sigma_{\text{post}} \approx \text{diag}(\sigma_{ij}^2)$ поэтому требует обоснования.

Спектральный анализ через формулу Шура. Матрица $\text{diag}(p) - pp^T$ — стандартный центрирующий проектор: имеет собственное значение 0 в направлении $\mathbf{1}$ (что соответствует constraint $\sum_j p_{ij} = 1$, операционально — закреплению $\theta_{ii} \equiv 0$ как softmax-анкера, см. S2.1) и собственные значения $\{p_{ij}\}_{j \neq i}$ на ортогональном подпространстве свободных параметров. Число обусловленности Fisher-блока в свободных координатах:

$$\kappa(\mathcal{F}_{\text{free}}^{(i)}) = \frac{\max_{j \neq i} p_{ij}}{\min_{j \neq i} p_{ij}}. \quad (\text{S2.2a})$$

На событии шага S1.3 (траектория OU в шаре $R(\delta)$ с вероятностью $\geq 1 - \delta$) для softmax выполняется $\max_j p_{ij} / \min_j p_{ij} \leq e^{2R(\delta)}$, откуда $\kappa(\mathcal{F}_{\text{free}}^{(i)}) \leq e^{2R(\delta)}$ — ограничено и зависит лишь от радиуса OU-шара через $R(\delta) = \sigma \sqrt{\ln(2K/\delta)}/\lambda$ (S1.3).

Поправка к диагональному приближению: оценка следа Σ_{post} . Гауссово приближение апостериора даёт $\Sigma_{\text{post}}^{(i)} = (\mathcal{F}_{\text{free}}^{(i)})^{-1}$ с тем же спектром обратных собственных значений; недиагональность Σ_{post} внутри строки порождает поправку к точной аддитивности (S2.2). Выпишем оценку следа. Для гауссова апостериора недиагональная часть $I(\hat{\theta}_v; \theta_v)$ мажорируется $\frac{1}{2} \ln \det(I + \mathcal{F} \Sigma_{\text{prior}})$, а разность между этим точным логдетом и его диагональным приближением $\frac{1}{2} \sum_{ij} \ln(1 + \mathcal{F}_{ij,ij} \sigma_0^2)$ ограничена долей внедиагональной энергии в следе, $\frac{1}{2} [\text{tr}(\mathcal{F} \Sigma_{\text{prior}}) - \sum_{ij} (\cdot)_{\text{diag}}]$. По неравенству $\text{tr}(\Sigma_{\text{post}}^{(i)}) \leq \kappa(\mathcal{F}_{\text{free}}^{(i)}) \cdot \sum_{j \neq i} \sigma_{ij}^2$ (максимальное собственное значение мажорирует каждое диагональное не более чем в $\kappa(\mathcal{F}_{\text{free}}^{(i)})$ раз) внедиагональный вклад ограничен $\kappa(\mathcal{F}_{\text{free}}^{(i)})$ -кратной диагональной частью. В slow-driving пределе $\lambda \tau_{\text{relax}} \ll 1$ доля внедиагональной энергии в следе есть $O(\lambda \tau_{\text{relax}})$ (за время τ_{relax} softmax-связь координат успевает породить лишь $O(\lambda \tau_{\text{relax}})$ -корреляцию), поэтому поправка имеет порядок $O(\kappa(\Sigma_{\text{post}}^{(i)}) \cdot \lambda \tau_{\text{relax}})$: число обусловленности входит мультипликативно. На OU-шаре S1.3 это даёт

$$\Sigma_{\text{post}} = \text{diag}(\sigma_{ij}^2(t)) \cdot (1 + O(e^{2R(\delta)} \cdot \lambda \tau_{\text{relax}})), \quad (\text{S2.2b})$$

что остаётся $1 + o(1)$ при усиленном slow-driving условии $e^{2R(\delta)} \cdot \lambda \tau_{\text{relax}} \ll 1$. В численных режимах § 6.2 ($\sigma = 0,1$, $\lambda = 10^{-3}$, $K = 56$, $\delta = 0,05$) получается $R(\delta) \approx 0,1 \cdot \sqrt{\ln(2240)}/10^{-3} \approx 8,8$ — слишком велико для буквального $e^{2R(\delta)} \cdot \lambda \tau_{\text{relax}} \ll 1$; однако (S2.2b) — *равномерная* верхняя оценка на $R(\delta)$ -шаре. *Конкретная эмпирическая κ .* Прогоны § 6.2 (simulations/markov_drift_ou/results_summary.txt) фиксируют стационарную дисперсию логитов $\sigma^2/(2\lambda) = 5,00$, т.е. логиты имеют разброс $\sigma_0 = \sqrt{5} \approx 2,24$. Типичный within-row condition number $\kappa(\mathcal{F}_{\text{free}}^{(i)}) = \max_j p_{ij} / \min_j p_{ij} = \exp(\max_j \theta_{ij} - \min_j \theta_{ij})$ оценивается через ожидаемый размах $k - 1 = 7$ гауссовых логитов $\mathcal{N}(0, 5)$: $\mathbb{E}[\text{range}_7] \approx 2,70 \sigma_0 \approx 6,0$, откуда $\kappa_{\text{typ}} \approx e^6 \sim 4 \cdot 10^2$ — не близко к 1. Соответственно $\kappa_{\text{typ}} \cdot \lambda \tau_{\text{relax}} \approx 4 \cdot 10^2 \cdot 3 \cdot 10^{-3} \approx 1$: аналитическая поправка (S2.2b) при реализованных параметрах порядка единицы,

т.е. строгая per-bit-uniformity вырождена (согласуется с S2.7). Смысл эмпирического « $\kappa \approx 1$ » — не малость сырого condition number, а наблюдаемое отсутствие нарушения c -масштабирования: на всех $5 \cdot 10^4$ точках обоих обучателей $\nu^{\text{op}} \in [0,010, 1,000] \subset [0, 1]$ без единого нарушения $I_{\text{pred}} > I_{\text{opt}}$ (results_summary.txt), т.е. Лемма 2 держится как *условное* утверждение $\nu^{\text{theor}} \geq 1 - \kappa c$ с κ , поглощающей within-row дефект. Аналитическое улучшение оценки (S2.2b) — через концентрацию softmax вокруг типичного логита, а не равномерную границу — оставлено как уточнение в § 8.5.

S2.3 Аддитивность МІ по независимым координатам

Для гауссова апостериора $\hat{\theta}_v = (\hat{\theta}_{ij})$ с диагональной ковариацией $\Sigma_{\text{post}} = \text{diag}(\sigma_{ij}^2)$ выполняется *точная* аддитивность МІ с истинным латентом:

$$I(\hat{\theta}_v; \theta_v) = \sum_{ij} I(\hat{\theta}_{ij}; \theta_{ij}). \quad (\text{S2.2})$$

Вывод: по chain rule (Cover and Thomas 2006, гл. 2.5)

$$I(\hat{\theta}_v; \theta_v) = \sum_{ij} I(\hat{\theta}_{ij}; \theta_{ij} \mid \hat{\theta}_{<ij}, \theta_{<ij});$$

независимость координат OU даёт $\theta_{ij} \perp (\theta_{<ij})$ (статистическая независимость по построению), а диагональность $\Sigma_{\text{post}} - \hat{\theta}_{ij} \perp \hat{\theta}_{<ij}$ (условная независимость апостериорных оценок при заданном истинном латенте). Условные МІ редуцируются к безусловным $I(\hat{\theta}_{ij}; \theta_{ij})$, что и даёт (S2.2).

Поправка к точной аддитивности при $\lambda\tau_{\text{relax}} = O(\epsilon)$ — слагаемое $O(\epsilon)$, поглощаемое в $1+o(1)$ при $\epsilon \rightarrow 0$.

S2.4 Refresh-фракция FIFO в K -координатной декомпозиции

В FIFO-схеме обновления памяти Леммы 2 refresh-фракция размером c обновляет долю c от K координат за интервал τ_E равномерно (определение FIFO и формулы (*)). По аддитивности (S2.2) МІ обновлённой фракции с истинным латентом среды декомпозируется:

$$I(M_{\leq t}^{\text{refr}}; X_E^{[t, t+\tau]}) = \sum_{ij \in \text{refr}} I(\hat{\theta}_{ij}^{\text{refr}}; \theta_{ij}(t+\tau)) = c \cdot K \cdot \bar{I}_{\text{coord}}(t+\tau), \quad (\text{S2.3})$$

где $\bar{I}_{\text{coord}}(t+\tau) := K^{-1} \sum_{ij} I(\hat{\theta}_{ij}; \theta_{ij}(t+\tau))$ — средняя МІ на координату при идеальной (Bayes-оптимальной для регулярного семейства) оценке. Структурно: каждая обновлённая координата вносит независимый вклад, пропорциональный $\bar{I}_{\text{coord}}$; суммарная МІ пропорциональна доле обновлённых координат c при K -кратной аддитивности.

S2.5 Сравнение с оптимальным наблюдателем

МП оптимального наблюдателя (полная достаточная статистика по $\theta_v(t)$) на горизонте τ в slow-driving пределе:

$$I_{\text{pred}}^{\text{opt}}(t, \tau) = I(X_t; X_{t+\tau} | \theta_v(t)) = \sum_{ij} I_{\text{coord}}(t + \tau) = K \cdot \bar{I}_{\text{coord}}(t + \tau), \quad (\text{S2.4})$$

где разложение по координатам использует условную независимость переходов $X_t \rightarrow X_{t+\tau}$ по разным строкам и независимость координат логитов θ_v внутри одной строки в slow-driving пределе. Аппроксимация $\theta_v(t + \tau) \approx \theta_v(t)$ работает с точностью $O(\sigma^2 \tau / \lambda)$: за горизонт τ при $\lambda \tau \ll 1$ дрейф латента малый, и МП на координату $I_{\text{coord}}(t + \tau) = I_{\text{coord}}(t) \cdot (1 + O(\lambda \tau))$.

Тождество коэффициента: почему числитель (S2.3) и знаменатель (S2.4) несут один $\bar{I}_{\text{coord}}$. Обе декомпозиции сводятся к одной средней покоординатной МП, но по разным парам: в числителе (S2.3) это МП апостериор $\leftrightarrow$ латент $I(\hat{\theta}_{ij}^{\text{refr}}; \theta_{ij})$, в знаменателе (S2.4) — МП наблюдений $I(X_t; X_{t+\tau})$, приписываемая координате ij . Тождество этих двух величин покоординатно — несущий шаг per-bit-uniformity — держится на *достаточности координатного латента*. Переход $X_t \rightarrow X_{t+\tau}$ при $X_t = i$ управляется *только* логитами строки i (условная независимость переходов по строкам: $X_{t+\tau} \perp \theta_{i'}$ | $X_t = i$ для $i' \neq i$), а внутри строки — softmax-подсистемой из $k - 1$ координат. Поэтому идеальный наблюдатель, предсказывающий $X_{t+\tau}$, извлекает из наблюдений ровно ту информацию о будущем, которую несёт достаточная статистика по θ_{ij} ; его оптимальная оценка координаты *и есть* $\hat{\theta}_{ij}$ (достаточность). В гауссовом slow-driving пределе обе МП выражаются через одну и ту же покоординатную информацию Фишера, $I_{\text{coord}} = \frac{1}{2} \ln(1 + \mathcal{F}_{ij}; \sigma_0^2)(1 + o(1))$ — и для пары апостериор $\leftrightarrow$ латент (концентрация оценки, S1.5b-форма), и для пары наблюдений $X_t; X_{t+\tau}$ (предсказуемость через ту же переходную структуру). Совпадение Fisher-содержания делает $\bar{I}_{\text{coord}}$ в (S2.3) и (S2.4) одной и той же величиной, что и позволяет им сократиться в (S2.5) ниже.

S2.6 Итоговая граница

Подставляя (S2.3) в (S2.4):

$$\frac{I(M_{\leq t}^{\text{refr}}; X_E^{[t, t+\tau]})}{I_{\text{pred}}^{\text{opt}}(t, \tau)} = \frac{c \cdot K \cdot \bar{I}_{\text{coord}}(t + \tau)}{K \cdot \bar{I}_{\text{coord}}(t + \tau)} = c \cdot (1 + O(\lambda \tau)).$$

То есть

$$I(M_{\leq t}^{\text{refr}}; X_E^{[t, t+\tau]}) \leq c \cdot I_{\text{pred}}^{\text{opt}}(t, \tau) \cdot (1 + O(\lambda \tau)). \quad (\text{S2.5})$$

При $\lambda \tau \ll 1$ (slow-driving режим, выполнено по условию класса § 5.2) и при усиленном условии $e^{2R(\delta)} \cdot \lambda \tau_{\text{relax}} \ll 1$ из S2.2 (within-row Fisher coupling) $1 + O(\lambda \tau) + O(e^{2R(\delta)} \lambda \tau_{\text{relax}}) = 1 + o(1)$, и (S2.5) даёт per-bit-uniformity с константой $\kappa = 1 + o(1)$. Без усиленного условия — $\kappa = 1 + O(e^{2R(\delta)} \lambda \tau_{\text{relax}})$, что для конечных δ, σ, λ

даёт мультипликативную поправку, но не отменяет качественной структуры (8a) (см. также S2.7 для дополнительных источников non-diagonality). Подстановка в (7) при условии $I(M^{\text{stale}}; X_E | M^{\text{refr}}) \rightarrow 0$ (Лемма S1) даёт асимптотически

$$\nu^{\text{theor}}(t) = 1 - \frac{I(M_{\leq t}^{\text{refr}}; X_E^{[t, t+\tau]})}{I_{\text{pred}}^{\text{opt}}(t, \tau)} \geq 1 - c \cdot (1 + o(1)), \quad (\text{S2.6})$$

что и есть утверждение (8a) Леммы 2 с явной константой $\kappa = 1 + o(1)$.

S2.7 Обсуждение пределов: скоррелированные координаты

При нарушении независимости координат OU (кросс-стрелочный дрейф с non-diagonal Σ в (S2.1)) per-bit-uniformity требует уточнения. Помимо межстрочной корреляции *prior*, второй источник non-diagonality — within-row Fisher coupling через softmax-нормировку (S2.2): число обусловленности Fisher-блока $\kappa(\mathcal{F}_{\text{free}}^{(i)}) = \max_j p_{ij} / \min_j p_{ij}$ контролирует отклонение от точной аддитивности (S2.2a, S2.2b) и входит мультипликативно в финальную поправку (S2.6). Оба источника объединяются в общем condition-number аргументе. Качественно более сильное нарушение — *избыточное/паритетное кодирование*, где взаимная информация принципиально не аддитивна (совместная MI не равна сумме по координатам): per-bit-uniformity там не выполняется даже приближённо, и пол (8a) к такому классу неприменим — это явная граница области применимости.

Пусть $\kappa(\Sigma_{\text{post}})$ — условное число (отношение максимального к минимальному собственному значению) совместной ковариации апостериора, объединяющее межстрочные prior-корреляции (S2.1, при non-diagonal Σ_{prior}) и within-row Fisher-корреляции (S2.2). Через гауссово представление MI $I(\hat{\theta}_v; \theta_v) = (1/2) \ln \det(\Sigma_{\text{prior}} \Sigma_{\text{post}}^{-1}) = (1/2) \ln \det(I + \mathcal{F} \Sigma_{\text{prior}})$ (где $\mathcal{F} = \Sigma_{\text{post}}^{-1} - \Sigma_{\text{prior}}^{-1}$ — наблюдаемая Fisher-информация, и $\Sigma_{\text{post}}^{-1} = \Sigma_{\text{prior}}^{-1} + \mathcal{F}$) и неравенство Hadamard $\det(\Sigma) \leq \prod_i \Sigma_{ii}$ получается верхняя граница, которая в худшем случае мажорируется $\kappa(\Sigma_{\text{post}})$ раз большим значением, чем аддитивная сумма. В терминах константы Замечания 5:

$$\kappa \leq \kappa(\Sigma_{\text{post}}) \cdot (1 + o(1)). \quad (\text{S2.7})$$

Для диагональной Σ_{post} (независимые координаты) $\kappa(\Sigma_{\text{post}}) = 1$ и (S2.7) редуцируется к $\kappa = 1 + o(1)$. Для скоррелированных координат граница ослабляется мультипликативно на $\kappa(\Sigma_{\text{post}})$; численная оценка для конкретной кросс-параметризации — предмет отдельного исследования. В OU-параметризации § 5.2 с независимыми W_{ij} и диагональным анкером $\theta_{ii} \equiv 0$ по построению диагонализуются *prior* Σ_{prior} ; *posterior* Σ_{post} наследует within-row Fisher-связь softmax (S2.2), дающую поправку $\kappa = 1 + O(e^{2R(\delta)} \lambda \tau_{\text{relax}})$. При параметрах § 6.2 ($R(\delta) \approx 8,8$) строгая аналитическая граница вырождена, и $\kappa \approx 1$ держится *эмпирически* по реализациям OU; аналитическое замыкание per-bit-uniformity при реализованных параметрах — открытая задача (§ 8.5 main). Лемма 2 при этом остаётся валидной как *условное* утверждение $\nu^{\text{theor}} \geq 1 - \kappa c$.

S3. Расширенная таблица нотации

Глоссарий обозначений работы с указанием размерности и уравнения определения; «б/р» — безразмерная. Сокращения: «МІ» — взаимная информация (Cover and Thomas 2006, гл. 2); «TV» — total variation; «KL» — Kullback–Leibler. Контексты определения — § X.Y и формулы (N) основного текста.

S3.1 Эффективность и информационный поток

Символ	Размерность/тип	Определение	Верхняя теоретическая граница
$\eta_v(t)$	б/р, $\in [0, 1]$	Предсказательная эффективность само моделирования $I_{\text{pred}}/I_{\text{mem}}$; (1) § 2.1	1 (по построению; DPI-безусловно — для концепт. числителя, § 2.1)
$\eta_v^{(\tau_w)}(t)$	б/р, $\in [0, 1]$	Эффективность с оценщиком на скользящем окне τ_w ; § 5.2, § 6.1	1 (по построению нормировки)
η_v^{stat}	б/р	Стационарный предел η_v ($I_{\text{mem}} \rightarrow 0$); § 5.3, (Andriishin 2026, § 2.1)	1 (по построению)
$I_{\text{pred}}(t, \tau)$	наты	Одношаговая predictive information при $\dot{P}(t)$; (4) § 3.1	$\ln k$ (одношаговая, $k = \Omega $); операционально $\leq I_{\text{mem}}$ по построению (§ 3.1)
$I_{\text{pred}}^{\text{stat}}(\tau)$	наты	Стационарный предел I_{pred} ; § 2.2	$\ln k$ (одношаговая)
$I_{\text{pred}}^{\text{opt}}(t, \tau) \equiv I_{\text{opt}}$	наты	М1 идеального наблюдателя с доступом к $\theta_v(t)$; (7) § 4.1	$\ln k$ (одношаговая, $X_t, X_{t+\tau}$ дискретны)
$I_{\text{pred}}^{\text{Bialek}}(X_E, \tau)$	наты	Классическая predictive information (Bialek et al. 2001); § 2.1 (Andriishin 2026)	E (excess entropy, Crutchfield and Feldman 2003)
$I_{\text{mem}}(t)$	наты	Память: истинная $I_{\text{mem}}^{\text{true}} = I(M_t; X_E^{\leq t})$ (насыщается при фикс. ёмкости) / MDL-оценщик $(K/2) \ln N_{\text{obs}}$; знаменатель η_v ; (1) § 2.1, § 6	$H(M_t)$ (истинная); оценщик растёт с числом наблюдений
$I_{\text{mem}}^{(\tau_w)}(t)$	наты	Память оценщика на скользящем окне τ_w ($N_{\text{obs}} = \min(t, \tau_w)$); § 5.2, § 6.1	$(K/2) \ln \tau_w$ (насыщается при заполнении окна)
$L_{\text{excess}}(t)$	наты	Кумулятивная excess-loss обучателя; (S8.1) § S8	асимптотика $(K/2) \ln(\lambda t)$ — открытая гипотеза (S8.2), в скане не достигнута

Различение типов теоретических границ. (i) Одношаговая граница $\ln k$ — стандартная capacity дискретного канала с алфавитом Ω (Cover and Thomas 2006); контролирует мгновенную информационную ёмкость через один шаг среды. (ii) DPI-граница $I_{\text{pred}} \leq I_{\text{mem}}$ — безусловный потолок на цепи $M_t \rightarrow X_E^{\leq t} \rightarrow X_E^{[t, t+\tau]}$: модель не может нести больше предсказательной информации, чем хранит о прошлом среды; именно она гарантирует $\eta_v(t) \in [0, 1]$ (DPI-потолок числителя). (iii) Excess entropy E (Crutchfield and Feldman 2003) — суммарная predictive information между прошлым и будущим стационарного процесса (для используемых здесь классов OU/PSP на конечном алфавите — конечная). Различение: $\ln k$ — для одношаговой $I_{\text{pred}}(t, \tau)$; I_{mem} — знаменатель эффективности и DPI-потолок числителя; E — для interval-MI типа $I_{\text{pred}}^{\text{Bialek}}$. В численных иллюстрациях § 6 память оценщика K -параметрической модели по N_{obs} наблюдениям растёт как $I_{\text{mem}}(t) = (K/2) \ln(\max(N_{\text{obs}}, e))$ нат (MDL / байесовская стохастическая сложность), что и реализует знаменатель η_v .

S3.2 Энергетические потоки

Символ	Размерность/тип	Определение
$E_{\text{actual}}^{\text{curr}}(t)$	Дж	Текущая операционная диссипация; § 2.2
$E_{\text{store}}(t)$	Дж	Кумулятивная стоимость удержания старой памяти; § 2.3
$E_{\text{grow}}(t)$	Дж	Кумулятивная стоимость расширения памяти; § 2.4
$\dot{E}_{\text{store}}(t)$	Вт	Мгновенная мощность удержания; Лемма 1 § 2.3
$\dot{E}_{\text{grow}}(t)$	Вт	Мгновенная мощность расширения; § 2.4
$\dot{E}_{\text{store}}^{\text{nostalg}}(t)$	Вт	Мощность удержания ностальгической фракции; (8) § 4.2
$E_{\text{store}}^{(1)}(t)$	Дж	Минимальная диссипация на удержание одного бита; (3) Лемма 1
$E_{\text{grow}}^{(1)}$	Дж	Минимальная диссипация на создание одного бита ёмкости; (3'') § 2.4
η_{ex}	б/р	Эксергетический КПД метаболизма; (Andriishin 2026, § 3.5)

S3.3 Память и её слои

Символ	Размерность/тип	Определение
M_t	биты (размер); конфигурация	Актуальный (обновляемый) слой памяти; § 3.1
$M_{<t}$	биты; конфигурация	Архивный слой памяти; § 3.1
$M_{\leq t} = (M_t, M_{<t})$	биты; конфигурация	Полная память системы; § 3.1
$M_{\leq t}^{\text{refr}}$	биты	Refresh-фракция (обновлена за интервал τ_E); § 4.4
$M_{\leq t}^{\text{stale}}$	биты	Stale-фракция (не обновлена за τ_E); § 4.4
$ M_{\leq t} $	биты	Размер активной части памяти; § 4.4, (11) § 5.3
$ M_{\leq t}^{\text{cap}} $	биты	Структурный лимит ёмкости памяти; (12) § 5.3
$\dot{M}_{\text{refresh}}(t)$	биты/с	Темп обновления памяти; § 4.4, (13) § 7
$\dot{M}_{\text{grow}}(t)$	биты/с	Темп роста ёмкости памяти; (13) § 7
$\dot{M}_{\text{refresh}}^{\text{eff}}(t)$	биты/с	Эффективный темп refresh для Роббинс–Монро; § 6.2

S3.4 Латентные параметры и оценки

Символ	Размерность/тип	Определение
$\theta_v(t)$	$\mathbb{R}^K$	Истинные логиты матрицы переходов среды; § 5.2
$\hat{\theta}_v(t)$	$\mathbb{R}^K$	Оценка логитов обучателем; § 6.2
$\theta_{ij}(t)$	$\mathbb{R}$	Координата логита, $i \neq j$; § 5.2
$P(t)$	$k \times k$ стохастическая	Матрица переходов среды; § 5.2
$\hat{P}(t)$	$k \times k$ стохастическая	Оценка матрицы переходов обучателем; § 3.1
X_t	$\in \Omega$	Состояние среды в момент t ; § 3.1
$X_E^{[t, t+\tau]}$	траектория	Реализация среды на окне $[t, t + \tau]$; (1a) (Andriishin 2026)

S3.5 Параметры моделей и временные шкалы

Символ	Размерность/тип	Определение
k	целое; $ \Omega $	Размер алфавита состояний среды; § 5.2, § 6.1
$K = k(k - 1)$	целое	Размерность логитов OU-параметризации; § 5.2
Ω	конечное множество	Алфавит состояний марковской цепи; § 3.1
λ	$1/c$	Темп OU-релаксации; обратная характерному времени дрейфа τ_E ; в PSP (§ 6.1) — интенсивность пуассоновского потока смен матрицы, отождествление $\tau_E = 1/\lambda$ — определение; § 5.2
σ	$\sqrt{1/c}$	Амплитуда OU-шума; § 5.2
α	б/р	Параметр Dirichlet для PSP; § 6.1
τ	с	Горизонт предсказания одношаговой I_{pred} ; (4) § 3.1
τ_d	с	Характерное время диссипации/отклика системы; § 2.1 (Andriishin 2026)
τ_w	с	Ширина скользящего окна оценщика; § 6.1, § 5.2
$\tau_E = 1/\lambda$	с	Характерное время дрейфа среды; § 5.2
τ_{relax}	с	Время релаксации марковской цепи на срезе; § 5.2, § 6.1
$\tau_{1/2}$	с	Время полураспада точности чтения бита; Лемма 1 § 2.3
τ_{reset}^*	с	Оптимальный интервал сброса памяти; (12) § 5.3
T	К	Температура термостата-приёмника; § 2.1 (Andriishin 2026)
ε	б/р, $\in (0, 1/2)$	Порог точности чтения бита; Лемма 1 § 2.3
γ	$1/c$	Симметричная переходная скорость в Лемме 1; § 2.3
η_t	б/р	Шаг Роббинс–Монро обучателя; § 6.2

S3.6 Ностальгия и режимный порог

Символ	Размерность/тип	Определение
$\nu(t)$	$\mathfrak{b}/\mathfrak{p}, \in [0, 1]$	Ностальгия (общий символ, контекст определяет вариант); § 4.1
$\nu^{\text{theor}}(t)$	$\mathfrak{b}/\mathfrak{p}, \in [0, 1]$	Теоретическая ностальгия через $I_{\text{pred}}^{\text{opt}}$; (7) § 4.1
$\nu^{\text{op}}(t)$	$\mathfrak{b}/\mathfrak{p}, \in [0, 1]$	Операциональная ностальгия через $\hat{E}$; (7') § 4.1
ν_c	$\mathfrak{b}/\mathfrak{p}, \in (0, 1)$	Критическое значение / порог режимного перехода; (11) § 5.3
ν_c^{theor}	$\mathfrak{b}/\mathfrak{p}, \in (0, 1)$	Теоретическая критическая ностальгия; (11) § 5.3
ν_c^{op}	$\mathfrak{b}/\mathfrak{p}, \in (0, 1)$	Операциональная критическая ностальгия (эмпирический прокси из § 6.1, PSP-симуляция); § 6.1, § 8.6 П.1
c	$\mathfrak{b}/\mathfrak{p}$	Вычисляемая константа $\dot{M}_{\text{refresh}}\tau_E/ M_{\leq t} $; (*) § 4.4
η_M	$\mathfrak{b}/\mathfrak{p}$	Memory-balance ratio $\dot{M}_{\text{refresh}}\tau_{1/2}/ M_{\leq t} $; (11) § 5.3
κ	$\mathfrak{b}/\mathfrak{p}, \geq 1$	Per-bit-uniformity константа Замечания 5; § 4.4, § S2.6
$\rho(t)$	$\mathfrak{b}/\mathfrak{p}$	Метрика информационного омоложения; (13) § 7

S3.7 Информационная сложность и диагностические прокси

Символ	Размерность/тип	Определение
$C_v^{\text{static}}(t)$	биты	Структурная память через статистическую сложность C_μ (прокси I_{mem}); § 4.3
$C_v^{\text{predictive}}(t)$	биты	Динамическая предсказательная сила; (9) § 4.3
C_μ	биты	Statistical complexity Crutchfield–Feldman (Crutchfield and Feldman 2003)
$\hat{E}(t, \tau)$	наты	Эмпирическая оценка excess entropy E (предсказательный потолок I_{opt} ; наты — как и E в S3.1, числитель I_{pred} (7') в натах); (7') § 4.1
h_μ	биты/символ	Энтропийная скорость; § 4.3

S3.8 Active inference (§ 7)

Символ	Размерность/тип	Определение
$G[\pi]$	наты	Expected free energy политики π : агент выбирает π , минимизируя G ; при минимизации максимизируется ожидаемый информационный выигрыш за вычетом отклонения от предпочтений (см. S7.1); § 7 / S7
$G^{\text{epist}}[\pi]$	наты	Эпистемическая компонента EFE, $-\mathbb{E}_q[D_{\text{KL}}(q(s' o', \pi) \ q(s' \pi))]$ — ожидаемый выигрыш в информации о скрытых состояниях; минимизация G её максимизирует (см. S7.1); § 7 / S7
$G^{\text{prag}}[\pi]$	наты	Прагматическая компонента EFE, $-\mathbb{E}_q[\ln p(o' C)]$ — близость ожидаемых наблюдений к предпочтениям C (см. S7.1); § 7 / S7
$q(s, o, \pi)$	плотность	Generative model / аппроксимирующий апостериор агента (приближение к истинному posterior по скрытым состояниям; Friston et al. 2017a; Parr et al. 2022); см. S7.1, S7.3; § 7 / S7
$p(o', s' C)$	плотность	Распределение предпочтений с целевым параметром C : кодирует цели агента как желаемые наблюдения o' (см. S7.1); § 7 / S7
$\beta_v = 1/(k_B T)$	1/Дж	Обратная температура для перевода нат в Дж, $E_{[\text{энергия}]} = k_B T \cdot (\text{нат})$ — мост между информационной и энергетической шкалами (голая E зарезервирована за excess entropy S3.1; см. S7.1, конверсия единиц); (S7.1) § 7 / S7

S3.9 Фундаментальные постоянные

Символ	Размерность	Значение / определение
k_B	Дж/К	Постоянная Больцмана
$k_B T \ln 2$	Дж	Минимальная плата за одно стирание (Landauer 1961)
$\ln 2$	б/р	Множитель перевода нат $\rightarrow$ биты

S4. Параметры симуляций для воспроизводимости

Раздел собирает технические параметры численных иллюстраций § 6.1 (PSP), § 6.2 (OU) и § S8.3 (адиабатический скан). Реализация — `andriishin/landauer-nostalgia-oa`, директории `simulations/markov_drift{,_ou,_ou_iinf_adiab}/`. Зерно `SEED = 20260524` с `per-run-offsets`; запуск `python main.py` в каждой директории восстанавливает приведённые численные значения с точностью до версии используемых библиотек.

S4.1 PSP-симуляция (§ 6.1)

Класс модели. Кусочно-стационарный марковский процесс с пуассоновскими сменами матрицы переходов. Алфавит $\Omega = \{1, \dots, k\}$, $k = 8$. На интервале $[T_i, T_{i+1})$ матрица переходов $P^{(i)}$ постоянна; моменты смены $\{T_i\}$ — пуассоновский поток с интенсивностью λ . В момент T_i матрица обновляется до случайной стохастической $P^{(i)}$ с независимыми строками, каждая строка — Dirichlet с параметром $\alpha = 0, 3$.

Базовые параметры. $k = 8$, $\alpha = 0, 3$, $\lambda = 10^{-3}$ (для режимов с дрейфом), горизонт предсказания $\tau = 1$ шаг.

Темп релаксации. $\langle \tau_{\text{relax}} \rangle \approx 2\text{--}3$ шагов при $\alpha = 0, 3$; $\lambda \tau_{\text{relax}} \approx 3 \cdot 10^{-3} \ll 1$ — slow-driving выполнено с запасом.

Три режима (§ 5.3):

Режим	λ	τ_w	T_{total}	Реализаций
Стационар	0	∞	10^4	80
Дрейф без сброса	10^{-3}	∞	10^5	60
Дрейф со сбросом	10^{-3}	$\{100, 500, 2000\}$	10^5	60

Сетка τ_w для Рис. 2. Восемь точек $\tau_w \in \{50, 100, 200, 500, 10^3, 2 \cdot 10^3, 5 \cdot 10^3, 10^4\}$, $\lambda = 10^{-3}$, $T_{\text{total}} = 5 \cdot 10^4$, 40 реализаций на точку.

Оценщик MI. Взаимная информация в марковской модели считается **точно** по переходной структуре (замкнутая форма) через KL-detuned proxy $\hat{I}_{\text{pred}}(t, \tau) = I_{\text{opt}}(P(t), \tau) - \mathbb{E}_{X_t \sim \pi(t)}[D_{KL}(P(t)^\tau(\cdot | X_t) \| \hat{P}(t)^\tau(\cdot | X_t))]$ с отсечением снизу нулём; выборочного оценщика симуляция не использует. Выборочные оценщики — дискретный plug-in с коррекцией Treves—Panzeri (Treves and Panzeri 1995) и непрерывный KSG-оценщик с k -NN, $k_{NN} = 3$ (Kraskov et al. 2004) — предназначены для данных реальных систем (§ 3).

Знаменатель эффективности I_{mem} . Знаменатель $\eta_v = I_{\text{pred}}/I_{\text{mem}}$ — память оценщика: $I_{\text{mem}}(t) = (K/2) \ln(\max(N_{\text{obs}}, e))$ нат, где $K = k(k-1) = 56$ — число свободных внедиагональных параметров k -состояний матрицы переходов, N_{obs} — число удержанных в памяти переходов (заполненность окна $\min(t, \tau_w)$). Это стандартная заученная (model↔data) информация MDL/байесовского оценщика K -параметрической модели по N наблюдениям, $I \sim (K/2) \ln N$ нат (байесовская стохастическая сложность). По построению $I_{\text{pred}} \leq I_{\text{mem}}$ (DPI), и $\eta_v \in [0, 1]$ безусловно; в коде выполняется явное усечение $I_{\text{pred}} \leftarrow \min(I_{\text{pred}}, I_{\text{mem}})$.

Объём вычислений. Сложность на реализацию $O(T_{\text{total}} \cdot k^2 \cdot \tau_w)$; базовая стационарная параметризация ($T_{\text{total}} = 10^4$, $\tau_w \rightarrow \infty$, $k = 8$) — $\sim 6 \cdot 10^7$ операций.

Ключевые численные результаты (поздневременные средние, последние 40% прогона, из фактических прогонов `results_summary.txt`). Стационар: $\langle I_{\text{pred}} \rangle = 0,658 \pm 0,012$ нат, $\langle \nu^{\text{op}} \rangle = 0,006$, $\eta_v \approx 2,6 \cdot 10^{-3}$ ($\nu^{\text{still}} \approx 0,997$; $I_{\text{mem}} \approx 251$ нат при $N_{\text{obs}} = 8000$). Дрейф без сброса: $\langle I_{\text{pred}} \rangle = 0,0007 \pm 0,0002$ нат — коллапс в ≈ 940 раз (ratio 0,0011), $\langle \nu^{\text{op}} \rangle = 0,999 \pm 0,0002$, $\nu^{\text{still}} \rightarrow 1,000$. Дрейф со сбросом: $\langle I_{\text{pred}} \rangle = 0,41/0,47/0,27$ нат и $\langle \nu^{\text{op}} \rangle = 0,382/0,298/0,600$ при $\tau_w = 100/500/2000$. Сетка τ_w : оптимум по $\langle I_{\text{pred}} \rangle$ при $\tau_w^* \approx 200$ ($\langle I_{\text{pred}} \rangle^* = 0,467 \pm 0,006$ нат), оптимум по $\langle \eta_v \rangle$ — при $\tau_w \approx 100$ ($\langle \eta_v \rangle^* \approx 3,2 \cdot 10^{-3}$). Эффективность $\eta_v \approx 10^{-3}$ во всех режимах с растущей памятью **структурно мала** (учитель запоминает $\gg$ предсказывает), а не свидетельствует о «высокой эффективности»; различающей режимы шкалой служит ν^{op} , не η_v . Инварианты провалидированы на всех $1,36 \cdot 10^5$ точках: $\eta_v \in [0, 0,006] \subset [0, 1]$, DPI-нарушений ($I_{\text{pred}} > I_{\text{mem}}$) — ноль.

Команда воспроизведения и выходы. python simulations/markov_drift/main.py; время прогона ~ 5 –10 минут; выходы — results_summary.{txt,json}, run.log, фигуры paper/figs/fig{1,2,3}*.png.

S4.2 OU-симуляция (§ 6.2)

Класс модели. Марковская цепь с непрерывным OU-дрейфом логитов матрицы переходов. $k = 8$, $K = k(k-1) = 56$ свободных параметров. Уравнения OU $d\theta_{ij} = -\lambda(\theta_{ij} - \theta_{ij}^*) dt + \sigma dW_{ij}$ с $\theta_{ij}^* = 0$, независимыми W_{ij} для $i \neq j$, и фиксированным $\theta_{ii} \equiv 0$ как softmax-анкер. Дискретизация Эйлера—Маруямы с $\Delta t = 1$.

Базовые параметры. $k = 8$, $\lambda = 10^{-3}$, $\sigma = 0,1$, $T_{\text{total}} = 2 \cdot 10^4$ шагов, 50 независимых реализаций OU-процесса; начальные логиты $\theta_v(0) \sim \mathcal{N}(0, 0,1^2)$.

Безразмерные параметры. $\sigma^2/\lambda = 10$; стационарная дисперсия логитов $\sigma^2/(2\lambda) = 5$ — сильный режим флуктуаций (не OU-concentration). Транзиентное окно $1/\sigma^2 = 10^2$ шагов.

Два обучателя на одной траектории. Центральный контраст § 6.2 — два онлайн-обучателя, потребляющих одну и ту же реализацию цепи x_t и видящих

одну и ту же истинную $P(t)$ (контраст «замерзание против отслеживания» не смешан с выборкой). Оба используют один градиент условного log-правдоподобия $\hat{\theta}_{x_t,j}(t+1) = \hat{\theta}_{x_t,j}(t) + \eta_t \cdot (\mathbb{K}[x_{t+1} = j] - \hat{P}_{x_t,j}(t))$ для $j \neq x_t$ (диагональ $\theta_{ii} \equiv 0$ не обновляется), различаясь лишь расписанием шага:

- **Роббинс–Монро** — затухающий шаг $\eta_t = c_0/\sqrt{t}$, $c_0 = 3$: скорость $1/\sqrt{t}$ соответствует концентрации апостериора и асимптотически Bayes-оптимальна для *стационарных* регулярных моделей (Clarke and Barron 1990, § 3). Под *нестационарной* мишенью шаг затухает быстрее, чем дрейфует среда, оценка перестаёт отслеживать $\theta_v(t)$ — обучатель **замерзает**, и ν^{op} монотонно растёт к высокому уровню.
- **Постоянный шаг** $\eta_t = s$ (рабочая точка $s = 0,3$, валидированно близкая к оптимуму при $\sigma = 0,1$): бесконечно **отслеживает** движущуюся мишень, оплачивая остаточный пол запаздывания/шума (задаётся s и σ); ν^{op} оседает на конечном *полу* вместо роста.

Оба обучателя накапливают наблюдения без забывания: после t шагов каждый видел $N_{\text{obs}} = t$ переходов (скользящего окна нет), так что знаменатель эффективности один и тот же: $I_{\text{mem}}(t) = (K/2) \ln(\max(N_{\text{obs}}, e))$ нат, $N_{\text{obs}} = t$. По DPI $I_{\text{pred}} \leq I_{\text{mem}}$ (явное усечение в коде), $\eta_v \in [0, 1]$. Знаменатель — информационная память $I_{\text{mem}}(t) = (K/2) \ln N_{\text{obs}}$.

Каноническая ностальгия и связь с ()*. Ведущая мера фигур § 6.2 — операциональная $\nu^{\text{op}}(t) = 1 - I_{\text{pred}}/I_{\text{opt}}$ (различает замерзание и отслеживание); структурный балласт $\nu^{\text{Still}} = 1 - \eta_v \approx 1$ для обоих обучателей (память фиксированного размера $|M| = K$, но $I_{\text{mem}} \gg I_{\text{pred}}$) и режимы *не* различает. Темп refresh связан с константой (*) Леммы 2 через тот же механизм: постоянный шаг даёт большую обновляемую фракцию s (отсюда низкий пол ν^{op}), затухающий шаг — убывающую $\dot{M}_{\text{refresh}}^{\text{eff}} \sim K c_0 / (\tau_E \sqrt{t}) \rightarrow 0$ (отсюда $\nu^{\text{op}} \rightarrow 1$ в пределе; замерзание).

Ключевые численные результаты (поздневременные средние, последние 50% прогона, из фактических прогонов `results_summary.txt`). Общй потолок $\langle I_{\text{opt}} \rangle = 0,757 \pm 0,005$ нат, $\langle I_{\text{mem}} \rangle = 268,7$ нат при $N_{\text{obs}} = 1,5 \cdot 10^4$. **Роббинс–Монро**: $\langle I_{\text{pred}} \rangle = 0,146 \pm 0,004$ нат, $\langle \nu^{\text{op}} \rangle = 0,821 \pm 0,005$ (замерзание: ν^{op} растёт $0,567 \rightarrow 0,747 \rightarrow 0,892$ в $t = 2200, 10200, 20000$), $\eta_v \approx 5 \cdot 10^{-4}$. **Постоянный шаг** $s = 0,3$: $\langle I_{\text{pred}} \rangle = 0,529 \pm 0,005$ нат (в 3,6 раза выше RM), $\langle \nu^{\text{op}} \rangle = 0,316 \pm 0,003$ (пол отслеживания: $0,283 \rightarrow 0,305 \rightarrow 0,331$), $\eta_v \approx 2 \cdot 10^{-3}$. Слип размера постоянного шага при $\sigma = 0,1$: внутренний оптимум $s^* \approx 0,6$, $\langle \nu^{\text{op}} \rangle = 0,290 \pm 0,004$ — малый шаг ($s = 0,02$: $\nu^{\text{op}} = 0,861$) запаздывает, большой ($s = 1,0$: $\nu^{\text{op}} = 0,339$) переобучается на шуме; все точки слипа быют замёрзший RM ($\nu^{\text{op}} = 0,820$). Слип по σ : RM держится плоско-высоко ($\nu^{\text{op}} \approx 0,82\text{--}0,86$ во всём $\sigma \in [0,03, 0,4]$, нечувствителен к дрейфу — замёрз), постоянный шаг отзывчив (ν^{op} от 0,670 при $\sigma = 0,03$ до 0,322 при $\sigma = 0,1$). Инварианты провалидированы на всех $5 \cdot 10^4$ точках обоих обучателей: $\eta_v \in [0, 0,008] \subset [0, 1]$ (нарушений $I_{\text{pred}} > I_{\text{mem}}$ — ноль); $\nu^{\text{op}} \in [0,010, 1,000] \subset [0, 1]$ (нарушений $I_{\text{pred}} > I_{\text{opt}}$ — ноль).

Команда воспроизведения и выходы. `python simulations/markov_drift_ou/main.py`; время прогона ~ 1 минута; выходы — `results_summary.{txt,json}`, `run.log`, фигуры `paper/figs/fig{4,5}_ou_*.png`.

S4.3 Адиабатический скан (§ S8.3)

Класс модели. ОУ-параметризация § 6.2 без изменений ($k = 8$, $\lambda = 10^{-3}$, $K = 56$, Эйлер–Маруяма $\Delta t = 1$, Роббинс–Монро $\eta_t = c_0/\sqrt{t}$, $c_0 = 3$). Измеряемая величина — кумулятивная excess-loss $L_{\text{excess}}(t)$ по (S8.1) с прямым доступом к ground truth $\theta_v(s)$.

Параметрический скан. Три значения σ при фиксированном $\lambda = 10^{-3}$:

σ	σ^2/λ	$1/\sigma^2$	T_{total}	Реализаций
0,01	10^{-1}	10^4	$5 \cdot 10^4$	25
0,003	$9 \cdot 10^{-3}$	$1,1 \cdot 10^5$	$5 \cdot 10^4$	25
0,001	10^{-3}	10^6	$2 \cdot 10^5$	25


Время симуляции T_{total} выбрано в пределах транзитного окна $1/\sigma^2$ для каждой σ .

Совместная подгонка. $L_{\text{excess}}(t) = A \cdot t + B \cdot \ln(\lambda t) + C$ на окне $t \in [10^3, 10^4]$ (фиксированном для прямого сопоставления между σ).


Отрицательный контроль с расширенным окном. Дополнительный фит с расширенным окном $[10^3, T_{\text{total}}]$: при $\sigma^2/\lambda = 10^{-3}$ и $T_{\text{total}} = 2 \cdot 10^5$ коэффициент $B/(K/2)$ растёт до 2,0 — артефакт Роббинс–Монро $1/\sqrt{t}$ -смещения обучателя на длинных горизонтах, не часть BNT-эффекта. Этот контроль фиксирует чувствительность результата к выбору окна и предотвращает интерпретацию монотонного тренда $B/(K/2)$ как результата выборочного предъявления.

Ключевые численные результаты. $B/(K/2) = \{0,54, 0,78, 0,85\}$ при $\sigma^2/\lambda \in \{10^{-1}, 9 \cdot 10^{-3}, 10^{-3}\}$ соответственно; $R^2 \geq 0,9995$ во всех точках; drift-share $A \cdot t/L_{\text{excess}}(t)$ при $t = 10^4$ падает с 76% до 10%. Монотонный рост B при $\sigma^2/\lambda \rightarrow 0$ согласуется с гипотезой § S8.1, но не доказывает сходимости $B \rightarrow K/2$; необходимы 5–6 точек скана с явной аналитической формой finite- σ correction $B(\epsilon) = (K/2)(1 - g(\epsilon))$.

Команда воспроизведения и выходы. python simulations/markov_drift_ou_iinf_adiab/main.py; время прогона ~ 1 минута; выходы — results_summary.{txt,json}, run.log, фигуры simulations/markov_drift_ou_iinf_adiab/fig_adiab_*.png; фигуры статьи —



И



S4.4 Воспроизводимость: зависимости и архивация

Зерно и зависимости. Глобальное SEED = 20260524 установлено в начале `main.py` каждого скрипта; `per-run-offsets` обеспечивают независимость реализаций. Зависимости — `numpy`, `scipy`, `scikit-learn` (KSG), `matplotlib`; точные версии — в `requirements.txt` каждой директории.

Полный набор команд. В корне репозитория последовательно `python simulations/markov_drift{,_ou,_ou_iinf_adiab}/main.py`; суммарное время прогона на ноутбуке среднего класса ~ 7–12 минут.

Zenodo-архивация. Версионированный снимок с DOI заархивирован на Zenodo (DOI: 10.5281/zenodo.21039182, релиз v1.0-submission); воспроизведение возможно также через клонирование `andriishin/landauer-nostalgia-oa` на теге v1.0-submission (тот же снимок, заархивированный на Zenodo).

S5. Полный аппарат § 5 main: Замечания 1–6 к Лемме 2, протокол § 5.2, ν_c и τ_{reset}^*

Раздел собирает формальные детали § 5 main, вынесенные сюда для разгрузки основного изложения. Структура: S5.1 — шесть Замечаний к Лемме 2 (§ 4.4 main фиксирует формулировку (8a) и краткое утверждение; здесь — полная их развёртка); S5.2 — пункт 5 протокола § 5.2 main (запрет на пересмотр определения объекта измерения) с обоснованием через (Wolpert 1996) no-free-lunch; S5.3 — балансовое условие существования ν_c через (11) и обсуждение его структурного статуса; S5.4 — оптимальный τ_{reset}^* (12), связь с dynamic regret bounds (Besbes et al. 2015); S5.5 — аналогия со спин-стёклами через (Hopfield 1982; Amit et al. 1985; Engel and Van den Broeck 2001).

S5.1 Шесть Замечаний к Лемме 2

Замечание 1 (стационарный предел). Стационарный предел Леммы 2 задаётся *не* $\tau_E \rightarrow \infty$ (этот переход нарушает условие $c < 1$ по (*) main), а формулой (1) main при $\dot{E}_{\text{store}} = \dot{E}_{\text{grow}} = 0$ (§ 2.2 main): в этом режиме ностальгические биты не несут платы, и шкала ν^{theor} через (7) main теряет термодинамический смысл (то же для ν^{op} при $\hat{P} \rightarrow P_0$). Таким образом, Лемма 2 не противоречит стационарному результату о сносе памяти (Andriishin 2026, § 2.1), а *дополняет* его на новый режим: при $\dot{E}_{\text{store}} > 0$ или $\dot{E}_{\text{grow}} > 0$ актуально условие (8a), а в стационарном пределе оно вырождается через обнуление обеих ставок.

Замечание 2 (вычислимость и фальсифицируемость (*)). Константа c из (*) main — *вычисляемая* функция трёх измеримых параметров $(M_{\text{refresh}}, \tau_E, |M_{\leq t}|)$, не свободный параметр теории. Лемма 2 применима при измеренных $c < 1$; при $c \geq 1$ система переходит в режим *скользящего окна*: за интервал τ_E полностью обновляется вся память, архивного слоя нет, и нестационарная теория вырождается. Тест на c — эмпирическое условие применимости, разделяющее системы с архивным слоем и без него. LLM с длинным контекстом и M_t -слоем порядка 10^5 – 10^6 токенов на инференсе дают $M_{\text{refresh}}\tau_E \gg |M_t|$, $c \gg 1$, и Лемма 2 относит их к скользящему окну — теория по собственному условию выводит этот слой из области применимости (§ 8.3 main).

Замечание 3 (содержательность (8a) сверх определения). Доля $1 - c$ — арифметическая (отношение числа необновлённых битов к полному размеру памяти), а ν^{theor} по (7) main — информационно-теоретическая (нормированный дефицит MI). Содержательная часть Леммы 2 — доказательство, что MI-вклад необновлённого бита в $I_{\text{pred}}(t, \tau)$ асимптотически обнуляется по DPI через decorrelation OU-латента с характерным временем τ_E (ковариация латента; условная MI по S1.5a затухает вдвое быстрее, с $\tau_E/2$, поскольку $I \approx \frac{1}{2}\rho^2$; подробное доказательство — S1 supplementary через MI-тензоризацию по независимым координатам OU, § S1.5). Требуются три условия: (i) декорреляция оптимальной статистики с τ_E ; (ii) идеальный наблюдатель в знаменателе (7) main; (iii)

FIFO-refresh. При нарушении любого из (i)–(iii) неравенство (8a) не выводится из арифметического c .

Замечание 4 (распространение на общий нестационарный класс). Базовая Лемма 2 доказана для OU-параметризации логитов (§ 5.2 main, S1–S2 supplementary). PSP-суррогат (§ 6.1 main) и мультимасштабный дрейф воспроизводят результат *иллюстративно* при $\lambda\tau_{\text{relax}} \ll 1$ через единый механизм декорреляции с эффективным τ_E , но строгого доказательства для не-OU классов в настоящей работе нет; см. § 8.5 main, открытая задача. Wolpert no-free-lunch (Wolpert 1996) даёт фундаментальное обоснование сужения класса § 5.2: универсальная теория нестационарной обучаемости без априорного ограничения класса невозможна; class slow-driving — необходимое сужение, не методологический выбор.

Замечание 5 (per-bit-uniformity). Переход от арифметической доли обновлённых битов c к информационно-теоретическому неравенству $\nu^{\text{theor}} \geq 1 - c$ (на шкале недобора прогноза, нормированной на оптимум среды $I_{\text{pred}}^{\text{opt}}$ — именно там пол содержателен; на балластной шкале $\nu^{\text{Still}} \rightarrow 1$ тривиально) требует аддитивности МП по независимо обновляемым битам:

$$I(M^{\text{refr}}; X_E^{[t, t+\tau]}) \leq c \cdot I_{\text{pred}}^{\text{opt}} \cdot (1 + o(1)).$$

Нормировка на $I_{\text{pred}}^{\text{opt}}$ (а не на I_{mem}) существенна: пол утверждает, что обновлённая за τ_E фракция захватывает не более доли c *оптимально предсказуемого* будущего среды. В slow-driving пределе refresh-фракция не накапливает кросс-битовой избыточности (Clarke and Barron 1990); полное доказательство для OU-параметризации — S2 supplementary. При нарушении условия $c \rightarrow \kappa c$, $\kappa \geq 1$, и Лемма 2 формулируется с мультипликативной поправкой $\nu^{\text{theor}} \geq 1 - \kappa c$; в OU-классе с независимыми W_{ij} и диагональным анкером $\theta_{ii} \equiv 0$ по построению диагонализует prior, тогда как posterior несёт within-row Fisher-поправку (S2.7), эмпирически $\kappa \approx 1$ в реализациях § 6.2 (аналитическое замыкание при реализованных параметрах — открытая задача § 8.5 main).

Замечание 6 (softmax-regularity для OU). Перенос OU-декорреляции с автоковариации логитов $\theta_v(t)$ на любой ограниченный измеримый функционал $\xi(\theta_v)$ (в частности, на элементы матрицы переходов $P_{ij}(\theta_v)$ и на любую достаточную статистику предсказания) обеспечивается Lipschitz-непрерывностью softmax по total variation на множестве логитов с конечной стационарной дисперсией $\sigma^2/(2\lambda)$. Через МП-тензоризацию по независимым координатам OU (§ S1.5) и DPI экспоненциальное затухание $\mathbb{E}[\theta_v(t)\theta_v(s)] \propto e^{-(t-s)/\tau_E}$ переносится на ковариацию любого ограниченного ξ с тем же характерным временем τ_E ; условная же МП (S1.5a, S1.6) затухает вдвое быстрее — с $\tau_E/2$ (показатель $2/\tau_E$), поскольку $I \approx \frac{1}{2}\rho^2$ при малой корреляции. Полное доказательство — S1 supplementary (пять шагов: Lipschitz softmax в ℓ_∞ ; перенос на TV матрицы переходов; ограниченность OU-траектории на шаре $R(\delta)$ с вероятностью $1-\delta$; перенос затухания на ковариацию ξ ; перевод TV-границы в границу для условной МП через χ^2 и DPI).

Лемма 2 в свете Замечаний 1–6 конструктивна: при (*) указывает явный механизм возникновения ностальгии (рассинхронизация оптимального признака через OU-декорреляцию) и физическое препятствие к её нулю (конечный темп

обновления памяти при FIFO-планировании). Совместное действие Замечаний 5–6 — структурное обоснование заявленной асимптотики $\nu^{\text{theor}} \geq 1 - c$ на шкале недобора прогноза в OU-классе § 5.2 main; Замечание 2 фиксирует область применимости через измеримое условие $c < 1$.

S5.2 Протокол § 5.2 main, пункт 5: запрет на пересмотр определения объекта измерения

Пункт 5 протокола (§ 5.2 main) — обязательство предрегистрации, защищающее фальсифицируемость: операциональное определение измеряемой величины фиксируется *до* данных и не пересматривается под прежним именем теории после их получения. При систематическом расхождении предсказания и измерения остаются два честных хода: (а) опровергнуть теорию; (б) явно сменить её имя, оставив старое имя за исходным определением. Правило симметрично — оно одинаково связывает теоретика и эмпирика.

Зачем это нужно. Стандартный ответ на провал эмпирического теста — либо отвергнуть теорию, либо сузить условия её применимости (добавить оговорки); оба хода легитимны и сохраняют тест строгим. Пункт 5 закрывает лишь третий, методологически сомнительный путь — пересмотр самого *операционального определения* объекта измерения с сохранением имени теории (классическое *ad hoc* спасение в смысле Поппера, замаскированное под техническое уточнение операционализации). Симметрия делает дисциплину честной в обе стороны: эмпирик не «уточняет» определение измеряемой величины *post hoc*, чтобы данные сошлись с теорией; теоретик не «уточняет» определение предсказываемой величины *post hoc*, чтобы они разошлись.

Как это исполнено в работе. Кумулятивная excess-loss $L_{\text{excess}}(t)$ (S8.1) удержана в § S8 как отдельный, явно помеченный counterfactual-диагностик, а не используется как операционально измеримая I_{pred} : L_{excess} требует доступа к ground truth $\theta_v(s)$, недоступному в реальных биологических системах, поэтому отождествление её с одношаговой МП (4) main под именем «predictive information» было бы *post hoc* пересмотром объекта измерения. Теоретические конструкции (Лемма 2, ν_c , $C_v^{\text{predictive}}$) опираются на ν^{theor} по (7) main; операциональные предсказания (§ 8.6 main, П.1, П.2) — на ν^{op} по (7') main. Подмена под одним именем исключена; раздельное счетоводство двух величин — нет.

S5.3 Существование ν_c : балансовое условие (11) на шкале ν^{op}

Режимный порог ν_c определяется на шкале *недобора прогноза* $\nu^{\text{op}}/\nu^{\text{theor}}$ (нормированной на оптимум среды I_{opt}) — той самой, на которой содержателен пол (8a) Леммы 2 и которая различает режимы в фигурах § 6 (балластная шкала $\nu^{\text{Still}} \approx 1$ порога не несёт). Балансовая оценка из условия равенства прироста $\dot{I}_{\text{pred}}$ и потерь от устаревания (формула (11) main):

$$\nu_c^{\text{theor}} \cdot |M_{\leq t}|/\tau_{1/2} = (1 - \nu_c^{\text{theor}}) \cdot \dot{M}_{\text{refresh}}.$$

Безразмерный $\eta_M := \dot{M}_{\text{refresh}}\tau_{1/2}/|M_{\leq t}|$ даёт формально $\nu_c^{\text{theor}} = \eta_M/(1 + \eta_M)$. Явная подстановка (*воспроизводимая*). Возьмём рабочую идентификацию $\tau_{1/2} \sim$

$\tau_E = 1/\lambda = 10^3$ шагов (полураспад точности бита задаётся корреляционным временем среды). (i) *Режим со сбросом* (FIFO-окно τ_w): всё окно обновляется за τ_w , так что $\dot{M}_{\text{refresh}} \approx |M_{\leq t}|/\tau_w$ и $\eta_M \approx \tau_{1/2}/\tau_w = \tau_E/\tau_w$. Для $\tau_w = \{100, 500, 2000\}$: $\eta_M \approx \{10, 2, 0,5\}$, откуда $\nu_c^{\text{theor}} = \eta_M/(1 + \eta_M) \approx \{0,91, 0,67, 0,33\}$ — тогда как наблюдаемая $\langle \nu^{\text{op}} \rangle = \{0,382, 0,298, 0,600\}$ (§ 6.1 main): не только числа, но и монотонность по τ_w не совпадают. (ii) *Режим накопления* (дрейф без сброса, $\tau_w \rightarrow \infty$): память растёт неограниченно, $|M_{\leq t}| \sim I_{\text{mem}} = (K/2) \ln t \approx 322$ нат при $t = 10^5$, а эффективный refresh затухает, $\dot{M}_{\text{refresh}} \sim K/t = 56/10^5$; тогда $\eta_M \approx (K/t) \cdot \tau_E/|M_{\leq t}| = (5,6 \cdot 10^{-4} \cdot 10^3)/322 \approx 1,7 \cdot 10^{-3}$ и $\nu_c^{\text{theor}} \approx 1,7 \cdot 10^{-3}$, тогда как наблюдаемая $\langle \nu^{\text{op}} \rangle \rightarrow 0,999$ — расхождение более чем на два порядка. Прямая подстановка простейшей формы (11), таким образом, даёт численные значения, не согласующиеся с наблюдаемой ν^{op} -шкалой PSP-симуляции § 6.1 main, где ν^{op} ограничена при сбросе (0,30–0,60) и уходит к 0,999 при накоплении памяти — расхождение с балансовой подстановкой более чем на порядок.

Структурный статус (11). (11) трактуется как *структурное балансовое условие*, не количественный предсказатель: работа постулирует существование $\nu_c^{\text{theor}} \in (0, 1)$ как неподвижной точки баланса прироста информации и потерь от устаревания на шкале недобора прогноза. Расхождение с операциональной ν^{op} -шкалой поддерживает это решение — прямая подстановка простейшей формы (11) отвергается, что и фиксируется как граница её интерпретативной силы. Вывод количественной формулы $\nu_c^{\text{theor}}(\lambda, \sigma, K, \tau_{1/2}, \dot{M}_{\text{refresh}})$ — открытая задача § 8.5 main.

Активная часть памяти. В (11) $|M_{\leq t}|$ — *активная* часть памяти, не структурный лимит ёмкости $|M_{\leq t}^{\text{cap}}|$. В § 6.1 main модель оценщика имеет $K = k(k-1) = 56$ свободных внедиагональных параметров; в системах с расширяющейся памятью активная часть растёт со временем, и численное значение ν_c^{theor} зависит от времени. Операциональный порог на ν^{op} -шкале — это ν_c^{op} по (7') main, не ν_c^{theor} ; рабочее допущение § 4.1 main о стабильности режимного порога под сменой нормировки обеспечивает переход между ними с возможным численным сдвигом.

S5.4 Оптимальный τ_{reset}^* и связь с dynamic regret

Оптимальный τ_{reset}^* максимизирует поздневременную предсказательную информацию $\langle I_{\text{pred}} \rangle$ (эквивалентно — минимизирует недобор прогноза $\langle \nu^{\text{op}} \rangle$): частый сброс выбрасывает ещё-полезную память, редкий ведёт к ностальгическому коллапсу (§ 5.3 main). Структурная оценка:

$$\tau_{\text{reset}}^* \sim \tau_E \cdot \log(|M_{\leq t}^{\text{cap}}|/\dot{M}_{\text{refresh}}\tau_E),$$

где $|M_{\leq t}^{\text{cap}}|$ — структурный лимит ёмкости памяти. *Вывод оптимума (3–4 строки)*. После сброса свежезагруженная память предсказывает с ценностью, экспоненциально устаревающей с возрастом a (дрейф среды рассинхронизирует память): плотность полезной информации $I(a) = I_0 e^{-a/\tau_E}$. Сброс/перезагрузка ёмкости $|M_{\leq t}^{\text{cap}}|$ при темпе обновления $\dot{M}_{\text{refresh}}$ стоит мёртвого времени $T_c = |M_{\leq t}^{\text{cap}}|/\dot{M}_{\text{refresh}}$ (линейная плата за refresh). Долгосрочно-средняя полезная информация на цикл длины τ_{reset} :

$$\langle I \rangle(\tau_{\text{reset}}) = \frac{\int_0^{\tau_{\text{reset}}} I_0 e^{-a/\tau_E} da}{\tau_{\text{reset}} + T_c} = \frac{I_0 \tau_E (1 - e^{-\tau_{\text{reset}}/\tau_E})}{\tau_{\text{reset}} + T_c}.$$

Условие $d\langle I \rangle/d\tau_{\text{reset}} = 0$ даёт трансцендентное $e^{\tau_{\text{reset}}/\tau_E} = 1 + \tau_{\text{reset}}/\tau_E + T_c/\tau_E$, чьё решение при большом $T_c/\tau_E = |M_{\leq t}^{\text{cap}}|/(\dot{M}_{\text{refresh}}\tau_E) \gg 1$ есть $\tau_{\text{reset}}^*/\tau_E \approx \ln(T_c/\tau_E)$, т.е. приведённая выше логарифмическая форма. Логарифмическая зависимость — стандартная форма оптимума для процессов с экспоненциальным устареванием и линейной платой за обновление.

Биологическая аналогия. Время поколения таксона коррелирует с темпом изменения эконисе — эмпирическая закономерность популяционной биологии, согласующаяся с (12) main с точностью до логарифмического множителя. У млекопитающих в раннем эмбриогенезе и герминальной линии происходит почти полное стирание метилирования ДНК с повторной установкой (Reik 2007); это можно трактовать как механизм τ_{reset}^* на поколенческой шкале — периодический сброс ностальгического слоя ради восстановления $\nu^{\text{op}} \rightarrow 0$ в новом поколении.

Связь с dynamic regret bounds. В non-stationary stochastic optimization (Besbes et al. 2015) (Theorem 2, stochastic setting) regret-оптимальная длина restart-эпохи имеет *степенную* структуру: оптимальная длина $\propto (T/V_T)^{2/3}$, где V_T — вариация цели на горизонте T . Это отлично от логарифмической формы $\tau_{\text{reset}}^* \sim \tau_E \log(\cdot)$ main §8.4(b): главный текст даёт *логарифмическую* форму через линейную плату за обновление с экспоненциальным устареванием, тогда как BGZ regret-optimal restart — *степенную* $(T/V_T)^{2/3}$. Совпадает лишь монотонность по τ_E (медленнее дрейф — реже сброс), не функциональная форма. В no-free-lunch (Wolpert 1996) универсальный τ_{reset}^* невозможен, что согласуется с условностью (12) main относительно класса § 5.2 main.

S5.5 Аналогия со спин-стёклами

- (11) main — баланс среднего поля, структурно аналогичный реплика-симметрии в статистической механике обучения (Engel and Van den Broeck 2001). В классической модели Хопфилда (Hopfield 1982) критическая нагрузка $\alpha_c \approx 0,138$ (Amit et al. 1985) — порог, за которым ассоциативная память теряет способность извлекать запомненные паттерны без ошибок. Наш ν_c^{theor} есть аналог в неравновесной обучающейся системе: порог, за которым ностальгическая фракция превышает критическую долю и предсказательная сила $I_{\text{pred}}(t)$ (а с ней $\eta_v(t)$) коллапсирует.

Количественная связь между ν_c^{theor} и α_c Хопфилда — отдельная задача: α_c — отношение числа запомненных паттернов к числу нейронов в эквilibrium-ной системе с фиксированным набором мишеней, ν_c^{theor} — пороговое отношение ностальгической фракции в неравновесной системе с дрейфующим латентным параметром. Структурное соответствие — обе величины отражают предельную нагрузку на ёмкость памяти в системах с фиксированным числом степеней свободы; динамические же характеристики существенно различны.

S6. Полные технические детали § 6 main: PSP-параметры, Роббинс–Монро learner, контроль с расширенным окном

Раздел собирает технические детали численных иллюстраций § 6.1 (PSP) и § 6.2 (OU) main, которые в основном тексте оставлены в виде краткой формулировки результатов с cross-ref сюда. Структура: S6.1 — полные параметры PSP-симуляции (§ 6.1 main) и оценщик MI; S6.2 — псевдокод симуляции и сравнительный анализ оценщиков; S6.3 — Роббинс–Монро online learner OU-симуляции (§ 6.2 main) и его асимптотическая Bayes-оптимальность; S6.4 — численная оценка s для Роббинс–Монро и расхождение с предсказанием (8a); S6.5 — отрицательный контроль с расширенным окном адиабатического скана и расхождение $C_v^{\text{static}}/C_v^{\text{predictive}}$; S6.6 — эмпирический ν_c^{op} и его статус.

Все параметры воспроизводимости (зерно, версии библиотек, директории) — S4 supplementary (параметры симуляций для воспроизводимости); этот раздел сосредоточен на методологическом обосновании выбора параметров и интерпретации результатов.

S6.1 PSP-симуляция (§ 6.1 main): полные параметры и оценщик

Модель. Конечно-состояний марковский процесс с пуассоновскими сменами матрицы переходов. Алфавит $\Omega = \{1, \dots, k\}$, $k = 8$. Матрица $P(t)$ кусочно-постоянна на интервалах $[T_i, T_{i+1})$; моменты смены $\{T_i\}$ — пуассоновский поток с интенсивностью λ . В момент T_i матрица обновляется до случайной стохастической $P^{(i)} \sim \text{Dirichlet}(\alpha = 0,3)$ по строкам. $\alpha = 0,3$ даёт $\langle \tau_{\text{relax}} \rangle \approx 2\text{--}3$ шагов и $\lambda \tau_{\text{relax}} \approx 3 \cdot 10^{-3} \ll 1$ с запасом — slow-driving выполнено.

Память наблюдателя. Система-наблюдатель удерживает память M_t , состоящую из оценки текущей матрицы переходов $\hat{P}(t)$ по скользящему окну длины τ_w с Laplace-сглаживанием (псевдоотсчёт 1 на ячейку). Структурная размерность модели — $K = k(k-1) = 56$ свободных внедиагональных параметров матрицы переходов (каждая строка имеет $k-1$ свободных ячеек). Знаменатель эффективности — *информация* памяти: $I_{\text{mem}}(t) = (K/2) \ln(\max(N_{\text{obs}}, e))$ нат, где N_{obs} — число удержанных в памяти переходов (заполненность окна $\min(t, \tau_w)$). Это байесовская стохастическая сложность K -параметрической модели по N наблюдениям; по DPI $I_{\text{pred}} \leq I_{\text{mem}}$, и $\eta_v = I_{\text{pred}}/I_{\text{mem}} \in [0, 1]$ безусловно.

Параметры трёх режимов. Стационарный режим: $\lambda = 0$ (матрица не меняется), $\tau_w \rightarrow \infty$, $T_{\text{total}} = 10^4$ шагов, усреднение по 80 реализациям. Дрейф без сброса: $\lambda = 10^{-3}$ (среднее $\tau_E = 10^3$ шагов между сменами), $\tau_w \rightarrow \infty$ (память не очищается, $\hat{P}(t)$ усредняется по всей истории), $T_{\text{total}} = 10^5$ шагов, 60 реализаций. Дрейф со сбросом: $\lambda = 10^{-3}$, $\tau_w \in \{100, 500, 2000\}$, $T_{\text{total}} = 10^5$, 60 реализаций.

Сетка τ_w для Рис. 2. Восемь точек $\tau_w \in \{50, 100, 200, 500, 10^3, 2 \cdot 10^3, 5 \cdot 10^3, 10^4\}$ при $\lambda = 10^{-3}$, $T_{\text{total}} = 5 \cdot 10^4$, 40 реализаций на точку.

S6.2 Псевдокод симуляции и сравнительный анализ МІ-оценщиков

Псевдокод *PSP-симуляции*.

для каждого условия (λ, τ_w) :

```
инициализировать P_0, выбрать T_1 ~ Exp( $\lambda$ )

инициализировать память: counts = матрица нулей ( $k \times k$ ); FIFO-буфер длины  $\tau_w$ 

для t = 1, 2, ..., T:

    если t >= T_i: обновить P до случайной  $P^{(i)} \sim \text{Dirichlet}(\alpha=0,3, k \text{ строк})$ ,
        выбрать T_{i+1}

    X_t = сэмпл из P_t[X_{t-1}, :]

    # скользящее окно: при заполненном буфере вытеснить старейший переход
    если  $\tau_w < \infty$  и буфер полон: counts[вытесненный переход] -= 1
    counts[X_{t-1}, X_t] += 1; буфер <- (X_{t-1}, X_t)

    если t mod measure_every == 0:

        P_hat(t) = (counts + Laplace) нормировать по строкам
        N_obs(t) = counts.sum() # = min(t,  $\tau_w$ )
        I_mem(t) = (K/2) ln(max(N_obs, e)) # K = k(k-1) = 56
        I_pred(t,  $\tau$ ) = I_opt(P_t,  $\tau$ ) - E_{x \sim \pi}[KL(P_t^\tau(\cdot | x) || P_hat^\tau(\cdot | x))], усечено снизу 0
        I_pred(t,  $\tau$ ) = min(I_pred, I_mem) # конечно-выборочный guard (не
        ↪ DPI-теорема, § 3.1)
         $\eta(t)$  = I_pred(t,  $\tau$ ) / I_mem(t)
         $\nu_{op}(t)$  = 1 - I_pred(t,  $\tau$ ) / I_opt(P_t,  $\tau$ ) # ведущая ностальгия
         $\nu_{Still}(t)$  = 1 -  $\eta(t)$  # балласт (вторично)
```

для каждого набора (λ, τ_w) : построить графики $I_{pred}(t)$, $\nu_{op}(t)$, $\nu_{Still}(t)$

Оценщик МІ: KL-detuned proxy. При горизонте предсказания τ численная оценка ядрового определения (4) main проводится через

$$\hat{I}_{pred}(t, \tau) = I_{opt}(P(t), \tau) - \mathbb{E}_{X_t \sim \pi(t)} [D_{KL}(P(t)^\tau(\cdot | X_t) || \hat{P}(t)^\tau(\cdot | X_t))],$$

отсечённый снизу нулём. Здесь $I_{opt}(P, \tau) = H(\pi) - \sum_i \pi_i H(P_{i,\cdot}^\tau)$ — predictive information оптимального наблюдателя с точной моделью; вычитается КЛ-штраф за несоответствие $\hat{P}$ истинному P . Связь с (4) main: неравенство, связывающее КЛ-штраф с условной МІ. Перепишем прокси в кросс-энтропийной форме. Раскрывая $D_{KL}(P^\tau || \hat{P}^\tau) = H_\times(P^\tau, \hat{P}^\tau) - H(P^\tau)$ (кросс-энтропия минус энтропия) и подставляя $I_{opt} = H(\pi_{t+\tau}) - \mathbb{E}_i[H(P_{i,\cdot}^\tau)]$:

$$\hat{I}_{pred}(t, \tau) = H(\pi_{t+\tau}) - \mathbb{E}_{i \sim \pi} [H_\times(P_{i,\cdot}^\tau, \hat{P}_{i,\cdot}^\tau)].$$

Пусть теперь $I(X_t; X_{t+\tau} | \hat{P}(t)) = I_{\text{opt}} - \Delta$, где $\Delta \geq 0$ — *фактическая* потеря предсказательной МІ из-за подмены $P \rightarrow \hat{P}$ (сокращение зависимости между X_t и $X_{t+\tau}$, видимой через модель $\hat{P}$). Ключевой шаг: эта потеря мажорируется KL-мисматчем,

$$\Delta \leq \mathbb{E}_{i \sim \pi} [D_{\text{KL}}(P_{i,\cdot}^\tau \| \hat{P}_{i,\cdot}^\tau)],$$

поскольку KL «переоценивает» потерю: он штрафует полное распределительное расхождение P^τ и $\hat{P}^\tau$, тогда как убыль МІ видит лишь ту его часть, что снижает предсказательную зависимость (доминирование по Пинскеру/DPI — убыль МІ ограничена дивергенцией модели). Следовательно

$$\hat{I}_{\text{pred}}(t, \tau) = I_{\text{opt}} - \mathbb{E}_i[D_{\text{KL}}] \leq I_{\text{opt}} - \Delta = I(X_t; X_{t+\tau} | \hat{P}(t)),$$

т.е. прокси мажорируется условной МІ сверху; отсечение снизу нулём обеспечено тем, что условная МІ неотрицательна. На эргодическом плато $\hat{P}(t) \rightarrow P(t)$ KL-штраф обнуляется ($\Delta \rightarrow 0$), и $\hat{I}_{\text{pred}} \rightarrow I_{\text{opt}} = I(X_t; X_{t+\tau} | P_0)$, что согласовано с (4) main в стационарном пределе.

Точный расчёт МІ. Взаимная информация в марковской модели считается **точно** по переходной структуре (замкнутая форма), без выборочного оценщика, поэтому наблюдаемые качественные паттерны (Рис. 1–3 main) не зависят от метода оценки МІ. Выборочные оценщики — дискретный plug-in с коррекцией смещения (Treves and Panzeri 1995) и непрерывный KSG-оценщик с k -NN, $k_{NN} = 3$ (Kraskov et al. 2004) — предназначены для данных реальных систем (§ 3).

Куполообразная зависимость $\langle I_{\text{pred}} \rangle(\tau_w)$. Диагностически ведущая кривая Рис. 2 main — $\langle I_{\text{pred}} \rangle$ как функция τ_w — куполообразна с максимумом $\langle I_{\text{pred}} \rangle^* = 0,467 \pm 0,006$ нат при $\tau_w^* \approx 200$ шагов; это нестационарный аналог bias-variance компромисса классической теории обучения: малый τ_w — высокая дисперсия оценщика $\hat{P}$ (недостаточно данных), большой τ_w — смещение из-за усреднения по неактуальным режимам; оптимум τ_w^* — баланс, аналогичный structural risk minimization. Вторичная ось $\langle \eta_v \rangle = \langle I_{\text{pred}}/I_{\text{mem}} \rangle$ структурно мала ($\langle \eta_v \rangle^* \approx 3,2 \cdot 10^{-3}$) и её собственный оптимум по τ_w смещён к ≈ 100 (более короткое окно даёт меньший I_{mem} , отсюда больший η_v); это диагностика балласта, не качества прогноза, поэтому ведущей кривой служит $\langle I_{\text{pred}} \rangle$, а не $\langle \eta_v \rangle$.

Положение максимума $\tau_w^* \approx 0,2 \tau_E < \tau_E = 1000$ согласуется с (12) main с точностью до логарифмического множителя; точное значение оптимума зависит от мелких параметров оценщика (Laplace-сглаживание, α Dirichlet).

S6.3 Роббинс–Монро online learner OU-симуляции (§ 6.2 main)

Поддержание онлайн-оценки. В OU-симуляции (§ 6.2 main) обучатель поддерживает онлайн-оценку $\hat{\theta}_v(t)$ через максимизацию условного логарифма правдоподобия с убывающим шагом $\eta_t = c_0/\sqrt{t}$ ($c_0 = 3$): на каждом шаге при наблюдении ($x_t \rightarrow x_{t+1}$) выполняется

$$\hat{\theta}_{x_t,j}(t+1) = \hat{\theta}_{x_t,j}(t) + \eta_t \cdot [\mathbb{K}[x_{t+1} = j] - \hat{P}_{x_t,j}(t)]$$

для $j \neq x_t$. Это диффузионно-prior-Bayes-аппроксимация байесовского обновления по OU-латенту в смысле § 5.2 main; скорость $1/\sqrt{t}$ соответствует concentration апостериора по каждому из K направлений и асимптотически Bayes-оптимальна для регулярных параметрических моделей (Clarke and Barron 1990, § 3).

Polyak–Ruppert averaging note. Стандартное улучшение Роббинс–Монро — усреднение итераций Polyak–Ruppert даёт асимптотически эффективную оценку с меньшей дисперсией; в настоящей реализации не использовано, поскольку наблюдаемые качественные паттерны (Рис. 4–5 main) робастны к выбору варианта Роббинс–Монро в пределах log-факторов на финальную дисперсию. Использование Polyak–Ruppert изменило бы количественные значения $\eta_v(t)$ на константный множитель, но не качественную картину коллапса.

Структурная эквивалентность Bayes. Роббинс–Монро с указанной скоростью $\eta_t \propto 1/\sqrt{t}$ структурно эквивалентна online-аппроксимации байесовского обновления по OU-латенту § 5.2 main в следующем смысле: посткумулятивное распределение оценок $\hat{\theta}_v(t)$ при $t \rightarrow \infty$ концентрируется вокруг условного среднего апостериора с ковариацией порядка $\mathcal{F}^{-1}/t$, где $\mathcal{F}$ — Fisher information matrix параметрической модели (Clarke and Barron 1990). Это обоснование выбора $\eta_t \propto 1/\sqrt{t}$ как функционально эквивалентного байесовскому обучателю **в стационарном случае**.

Срыв Bayes-оптимальности под дрейфом и второй обучатель. Та же асимптотическая Bayes-оптимальность Роббинс–Монро — причина его срыва под нестационарной мишенью: затухание шага $\eta_t \rightarrow 0$ означает, что после некоторого t обновление слабее, чем накопленный за шаг дрейф OU-латента, и оценка **замерзает** относительно движущегося $\theta_v(t)$. Поэтому § 6.2 main сравнивает Роббинс–Монро со вторым обучателем — **постоянным шагом** $\eta_t = s$ (рабочая точка $s = 0,3$). Оба бегут на одной траектории и видят один и тот же переход; различается лишь расписание шага. Постоянный шаг не замерзает: он бесконечно отслеживает дрейф, оплачивая остаточный пол запаздывания/шума порядка $\sim s\sigma^2/(2\lambda)$ на координату вместо ухода $\nu^{\text{op}} \rightarrow 1$. Рабочая точка $s = 0,3$ выбрана по свипу Рис. 5 (валидированно близка к внутреннему оптимуму $s^* \approx 0,6$ при $\sigma = 0,1$): малый шаг недо-отслеживает (запаздывание), большой переобучается на шуме OU. Этот контраст — *урок дизайна*, а не по-го: под нестационарностью оптимальный оценщик — не асимптотически-оптимальный стационарный.

S6.4 Численная оценка s для обоих обучателей и пол (8a) на шкале ν^{op}

Пол ставится на шкале недобора прогноза. Пол (8a) Леммы 2 — $\liminf \nu^{\text{theor}}(t) \geq 1 - s$ — содержателен именно на шкале *недобора прогноза* $\nu^{\text{theor}}/\nu^{\text{op}}$ (нормировка на оптимум среды I_{opt}): он говорит, что не более доли s оптимально-предсказуемого будущего извлекается из памяти, обновлённой за корреляционный интервал среды. На балластной шкале $\nu^{\text{still}} = 1 - I_{\text{pred}}/I_{\text{mem}}$ соответствующее

неравенство тривиально ($\nu^{\text{Still}} \rightarrow 1$ структурно для накапливающей память системы) и режима не различает. В симуляциях § 6.2, где истинное значение известно по построению, $\nu^{\text{theor}} = \nu^{\text{op}}$, и численная проверка (8a) идёт на этой шкале.

Роббинс–Монро — замерзающий предел $c \rightarrow 0$. Затухающий шаг $\eta_t = c_0/\sqrt{t}$ даёт убывающий эффективный темп refresh $\dot{M}_{\text{refresh}}^{\text{eff}}(t) \sim Kc_0/(\tau_E\sqrt{t})$, то есть $c(t) = \dot{M}_{\text{refresh}}^{\text{eff}} \tau_E/|M_{\leq t}| \approx Kc_0/(|M_{\leq t}|\sqrt{t}) \rightarrow 0$ при $t \rightarrow \infty$ ($|M_{\leq t}| = K$). Соответственно пол $1 - c \rightarrow 1$, и ν^{op} замёрзшего RM монотонно растёт к единице: наблюдаемое $\nu^{\text{op}}(t) = 0,567 \rightarrow 0,747 \rightarrow 0,892$ ($t = 2200, 10200, 20000$), позднеременное $0,821 \pm 0,005$ — качественно согласуется с $\nu^{\text{op}} \rightarrow 1$ при $c \rightarrow 0$. Конечность горизонта ($t \leq 2 \cdot 10^4$) и приближённость per-bit-uniformity Замечания 5 (softmax-нелинейность, Замечание 6) объясняют, почему наблюдаемое 0,82 ещё не достигло единицы.

Постоянный шаг — конечная c, конечный пол. Постоянный шаг $\eta_t = s$ удерживает ненулевой темп refresh, c конечна и велика, поэтому пол $1 - c$ конечен и низок: наблюдаемое $\nu^{\text{op}} \approx 0,316 \pm 0,003$ (пол отслеживания $0,283 \rightarrow 0,305 \rightarrow 0,331$, не растёт). Это прямая иллюстрация структуры Леммы 2: пол $1 - c$ тем ниже, чем выше темп refresh относительно τ_E . Количественная проверка $1 - c$ как *точного* предсказания на конкретной ОУ-параметризации с контролируемым τ_E — открытая задача § 8.5 main (требуется явный вывод c из (σ, λ, s) и сходимости коэффициента per-bit-uniformity).

S6.5 Отрицательный контроль с расширенным окном и расхождение $C_v^{\text{static}}/C_v^{\text{predictive}}$

Отрицательный контроль с расширенным окном. При расширении окна совместной подгонки адиабатического скана (§ S8.3) до $[10^3, T_{\text{total}}]$ (вместо фиксированного $[10^3, 10^4]$) фит вырождается: при $\sigma^2/\lambda = 10^{-3}$ и $T_{\text{total}} = 2 \cdot 10^5$ коэффициент $B/(K/2)$ растёт до 2,0 — артефакт Роббинс–Монро $1/\sqrt{t}$ -bias обучателя на длинных горизонтах, не часть BNT-эффекта. Окно $[10^3, 10^4]$ выбрано для прямого сопоставления между точками адиабатической серии и согласовано с transient-условием $t \ll 1/\sigma^2$. Этот контроль фиксирует чувствительность результата к выбору окна фита и предотвращает интерпретацию монотонного тренда $B/(K/2)$ как результата выборочного предъявления.

Численный scan $B/(K/2) \in \{0,54, 0,78, 0,85\}$. Полные результаты — § S8.3 (таблица B , $B/(K/2)$, R^2 , drift-share); S4.3 supplementary (параметры скана).

Расхождение $C_v^{\text{static}}/C_v^{\text{predictive}}$. В режиме «дрейф без сброса» (§ 6.1 main) при $\nu^{\text{op}}(t) \rightarrow 0,999$ имеем $C_v^{\text{predictive}}(t) = (1 - \nu^{\text{op}}(t)) \cdot C_v^{\text{static}}(t) \rightarrow 0$ (в (9) main стоит ν^{theor} ; в симуляциях § 6 $\nu^{\text{op}} = \nu^{\text{theor}}$), тогда как C_v^{static} остаётся ограниченным снизу размером накопленной памяти $\hat{P}(t)$. Отношение $C_v^{\text{static}}/C_v^{\text{predictive}} \rightarrow \infty$ — численная иллюстрация диагностического сигнала ностальгии (§ 4.3 main): два прокси, согласующиеся в стационарном режиме, расходятся при наблюдаемом дрейфе. Это операционализирует Предсказание 1 § 8.6 main: пересечение ν_c^{op} диагностируется через расхождение двух прокси, без прямого измерения $\nu^{\text{op}}(t)$.

S6.6 Эмпирический ν_c^{op} и его статус

Эмпирический режимный порог формулируется на *операциональной* шкале недобора прогноза $\nu^{\text{op}} = 1 - I_{\text{pred}}/I_{\text{opt}}$ — той самой, что различает режимы в фигурах § 6.1 (балластная шкала $\nu^{\text{Still}} \approx 1$ режима не различает). В валидированной PSP-симуляции ν^{op} принимает ограниченные значения в режимах со сбросом ($\langle \nu^{\text{op}} \rangle = 0,382/0,298/0,600$ при $\tau_w = 100/500/2000$; минимум на оптимальном окне $\tau_w^* \approx 200$) и уходит к $\langle \nu^{\text{op}} \rangle = 0,999$ в режиме коллапса (дрейф без сброса). Порог ν_c^{op} лежит, таким образом, *между* минимумом по τ_w ($\approx 0,30$, адаптивный режим) и единицей (коллапс): он отделяет окна, при которых забывание ещё спасает прогноз, от накопления памяти, при котором прогноз бесполезен.

Честная оговорка о численном значении. В режиме коллапса эффективность $\eta_v = I_{\text{pred}}/I_{\text{mem}}$ монотонна (пика нет), так что момент полураспада η_v не определён, а определение «полураспад η_v » неприменимо; единого универсального числа ν_c^{op} из валидированных прогонов не извлекается, и оно здесь **не постулируется**. Структурное утверждение § 5.3 main о существовании $\nu_c \in (0, 1)$, разделяющего адаптивный режим и коллапс, поддержано данными (ν^{op} ограничена при сбросе, $\rightarrow 1$ при накоплении), но конкретное пороговое число зависит от оперативного определения и параметров PSP-суррогата.

Расхождение с (11). Прямая балансовая подстановка $\nu_c^{\text{theor}} = \eta_M/(1 + \eta_M)$ в простейшей форме (11) main даёт значения, не согласующиеся с наблюдаемой ν^{op} -шкалой PSP. Явно (полная арифметика — S5.3 supplementary, рабочая идентификация $\tau_{1/2} \sim \tau_E = 10^3$): в режиме накопления $\eta_M \approx (K/t) \tau_E/|M_{\leq t}| \approx 1,7 \cdot 10^{-3}$ даёт $\nu_c^{\text{theor}} \approx 1,7 \cdot 10^{-3}$ против наблюдаемой $\langle \nu^{\text{op}} \rangle \rightarrow 0,999$ (расхождение > 2 порядков); в режиме со сбросом $\eta_M \approx \tau_E/\tau_w = \{10, 2, 0,5\}$ даёт $\nu_c^{\text{theor}} \approx \{0,91, 0,67, 0,33\}$ против $\langle \nu^{\text{op}} \rangle = \{0,382, 0,298, 0,600\}$ — несовпадение чисел и монотонности. Это поддерживает решение § 5.3 main / S5.3 supplementary трактовать (11) как структурное балансовое условие, не количественный предсказатель. Вывод универсальной формулы $\nu_c^{\text{theor}}(\lambda, \sigma, K, \tau_{1/2}, M_{\text{refresh}})$ — открытая задача § 8.5 main.

Стабильность под сменой нормировки. По DPI $\nu^{\text{op}}(t) \leq \nu^{\text{theor}}(t)$ pointwise (§ 4.1 main; меньший знаменатель $\dot{E} \leq I_{\text{pred}}^{\text{opt}}$ в (7')) даёт больший фрагмент и меньшую ностальгию; следовательно эмпирический порог на ν^{op} -шкале — это ν_c^{op} , оценка снизу для ν_c^{theor} . Рабочее допущение § 4.1 main о монотонности режимного порога под сменой нормировки обеспечивает применимость операционального ν_c^{op} как суррогата теоретического ν_c^{theor} с возможным численным сдвигом, но без качественного смещения порога.

S7. Active inference: полное формальное соответствие η_v и EFE, $\rho(t)$, оговорки

Раздел собирает формальные детали § 7 main, вынесенные сюда для разгрузки основного изложения. Структура: S7.1 — heuristic correspondence $\Delta G^{\text{epist}} \leftrightarrow$

— ΔI_{pred} (S7.1), полное обоснование с переводом единиц; S7.2 — conjecture (S7.2) с явным гипотетическим статусом и обсуждение направления формализации; S7.3 — категориальная оговорка $I_q(s'; o') \neq I(X_t; X_{t+\tau})$ через достаточность $\hat{P}(t)$; S7.4 — контекст sophisticated inference (Friston et al. 2021) и Pearl/Friston-blanket (Bruineberg et al. 2018; Bruineberg et al. 2022) демаркация; S7.5 — парирование Andrews (2021) / Williams (2020) через cross-ref на paper #1; S7.6 — метрика информационного омоложения $\rho(t)$ подробно с эмпирической интерпретацией.

S7.1 Heuristic correspondence: полное обоснование

В формулировке active inference (Friston et al. 2017a, ур. 3; Parr2022, гл. 7) expected free energy политики π исчисляется в натах и есть

$$G[\pi] = \mathbb{E}_{q(o', s' | \pi)} [\ln q(s' | \pi) - \ln p(o', s' | C)],$$

где $p(o', s' | C)$ — распределение предпочтений с параметром C , кодирующим цели агента. *Вывод разложения (воспроизведение Friston et al. 2017a, одна строка алгебры).* Факторизуя $p(o', s' | C) = p(o' | C) q(s' | o', \pi)$ (предпочтения по наблюдениям, апостериор по состояниям аппроксимирует $q(s' | o', \pi)$) и подставляя,

$$G = \mathbb{E}_q [\ln q(s' | \pi) - \ln q(s' | o', \pi)] - \mathbb{E}_q [\ln p(o' | C)] = -\mathbb{E}_{q(o' | \pi)} [D_{\text{KL}}(q(s' | o', \pi) \| q(s' | \pi))] - \mathbb{E}_q [\ln p(o' | C)],$$

где первый член свернулся в (отрицательную) ожидаемую KL-дивергенцию апостериор $\leftrightarrow$ приор по состояниям. Итого $G = -\mathbb{E}_q [D_{\text{KL}}(q(s' | o', \pi) \| q(s' | \pi))] - \mathbb{E}_q [\ln p(o' | C)]$: эпистемическая ценность (информационный выигрыш о скрытых состояниях; знак минус — минимизация G её максимизирует) плюс прагматическая ценность (близость к предпочтениям).

Конверсия единиц. И G , и I_{pred} измеряются в **натах** (Приложение A main). Конверсия в энергетические единицы через $\beta_v = 1/(k_B T)$ даёт $E_G = k_B T \cdot G_{[\text{нат}]}$ и, аналогично, $E_{I_{\text{pred}}} = k_B T \cdot (I_{\text{pred}})_{[\text{нат}]}$. Для приращения за окно политики Δt :

$$k_B T \cdot \Delta G^{\text{epist}}[\pi] \big|_{\Delta t} \approx -k_B T \cdot \Delta I_{\text{pred}} \big|_{\Delta t}, \quad (\text{S7.1})$$

с точностью до аддитивной константы, поглощающей прагматический вклад и не зависящей от π . Обе стороны имеют размерность энергии (Дж); знак минус отражает соглашение « G минимизируется при максимизации I_{pred} »; эквивалентная безразмерная форма получается делением на $k_B T$.

Гипотетический статус. (S7.1) фиксируется как *heuristic correspondence*, не как доказанное неравенство. Доказательство строгого неравенства требует (i) аккуратной работы с временными производными в нестационарной generative model; (ii) демонстрации, что прагматический вклад действительно не зависит от π на временной шкале Δt ; (iii) учёта поправок от категориальной оговорки S7.3. Все три ингредиента отсутствуют в существующей литературе по active inference в нестационарном режиме.

S7.2 Conjecture: гипотетический статус

Гипотетическая теорема — направление, в котором (S7.1) может быть превращено в строгое неравенство:

$$k_B T \cdot \Delta G^{\text{epist}}[\pi] \Big|_{\Delta t}^{\text{conj.}} \geq -k_B T \cdot \Delta I_{\text{pred}} \Big|_{\Delta t}, \quad (\text{S7.2})$$

где пометка «conj.» отмечает гипотетический статус. Формальная доказательность (S7.2) — открытая задача, требующая аккуратной работы с временными производными и нестационарной generative model в расширенном active inference framework (Parr et al. 2022).

Sophisticated inference как направление формализации. Sophisticated inference (Friston et al. 2021) расширяет стандартный active inference на политики, учитывающие пост-наблюдательные обновления будущих априорных распределений; это естественная рамка для аккуратной работы с временными производными в нестационарной generative model. Доказательство (S7.2) в sophisticated inference framework — естественный следующий шаг расширения настоящей работы.

S7.3 Категориальная оговорка $I_q(s'; o') \neq I(X_t; X_{t+\tau})$

Эпистемическая ценность в (Friston2017) — взаимная информация $I_q(s'; o' \mid \pi)$ между скрытым состоянием s' и наблюдением o' , тогда как $I_{\text{pred}}(t, \tau)$ по (4) main — МІ между двумя последовательными наблюдениями X_t и $X_{t+\tau}$. Это категориально различные объекты: первое — МІ в одной точке времени между латентом и наблюдением, второе — МІ между двумя моментами времени по наблюдаемой траектории.

Мост через достаточность $\hat{P}(t)$. При интерпретации $s' = \theta_v(t + \tau)$, $o' = X_{t+\tau}$ и условии $X_{t+\tau} \perp \theta_v(t) \mid \hat{P}(t)$ (статистическая достаточность $\hat{P}(t)$: текущая оценка экранирует устаревший латент от будущего наблюдения) мост выводится через chain rule МІ и DPI. Обусловим на $\hat{P}(t)$. Генеративная модель делает $X_{t+\tau}$ зависящим от прошлого — в частности от X_t — *только* через текущий латент $\theta_v(t + \tau)$, задающий переходную структуру; это марковская цепь

$$X_t \rightarrow \theta_v(t + \tau) \rightarrow X_{t+\tau} \quad (\text{при условии } \hat{P}(t)).$$

По data-processing inequality на этой цепи (Cover and Thomas 2006, гл. 2.8) обусловленная МІ не возрастает при огрублении $\theta_v(t + \tau) \rightarrow X_t$:

$$I_{\text{pred}}(t, \tau) = I(X_t; X_{t+\tau} \mid \hat{P}(t)) \leq I(\theta_v(t+\tau); X_{t+\tau} \mid \hat{P}(t)) = I_q(\theta_v(t+\tau); X_{t+\tau} \mid \hat{P}(t)).$$

Достаточность $\hat{P}(t)$ гарантирует, что единственный канал латентной связи с $X_{t+\tau}$ — через $\theta_v(t + \tau)$ (устаревший $\theta_v(t)$ экранирован), так что цепь замкнута и DPI применима. Правая часть — эпистемическая ценность (S7.1); левая — операциональная одношаговая I_{pred} (4) main.

Минимизация эпистемической части $G[\pi]$ при фиксированном информационном знаменателе $I_{\text{mem}}(t)$ *эвристически соответствует* локальной максимизации $\eta_v(t) = I_{\text{pred}}/I_{\text{mem}}$ (в смысле heuristic correspondence § S7.1; строгое следствие не

доказано — мост даёт верхнюю границу на I_{pred} , не равенство). Прагматическая компонента через предпочтение C — *вне* термодинамической шкалы; полная эквивалентность η_v и G требовала бы кодирования предпочтения через минимизацию $\dot{E}_{\text{actual}}$ — нетривиальное расширение FER.

Условие соответствия — $M_{\leq t}$ включает $q(s)$ и историю наблюдений (расширение generative model на episodic уровень через иерархическую/мотивированную active inference (Pezzulo et al. 2018; Parr et al. 2022, гл. 7–8), где высшие уровни иерархии удерживают медленно дрейфующий контекст; parametric predictive coding (Bogacz 2017) не вводит отдельного эпизодического слоя).

S7.4 Pearl/Friston-blanket демаркация и нестационарный режим

Связь между η_v и принципом свободной энергии Фристона (Friston 2010; Friston et al. 2017a) сформулирована в (Andriishin 2026, § 4.4): требование self-payment превращает FER в дискриминационный критерий, а η_v операционально закрывает зазор между общим формализмом и требованием принадлежности энергии моделирующему контуру. Опора — разведение Pearl-blanket (эпистемический инструмент) и Friston-blanket (онтологическое свойство с требованием self-payment) (Bruineberg et al. 2018; Bruineberg et al. 2022).

В нестационарном режиме демаркация релевантна: соответствие η_v и EFE имеет смысл только для систем, проходящих тест самооплаты ($S = 1$); self-payment — *альтернативная* онтология, не конституирующая Friston-blanket (Andriishin 2026, § 4.4). Для систем без самооплаты (LLM-as-agent в стандартной архитектуре, $S = 0$) соответствия нет. Это согласуется со структурой § 2.7 main: self-payment как критерий применимости η_v переносится на нестационарный режим и на каждое из трёх слагаемых (1) main.

Destructive argument Bruineberg. Аргумент (Bruineberg et al. 2018; Bruineberg et al. 2022) против онтологизации FER без self-payment-критерия — структурный аргумент в пользу настоящей рамки: η_v операционализирует требование self-payment и тем самым отвечает на критику Bruineberg в смысле, развёрнутом в (Andriishin 2026, § S4.4a).

S7.5 Andrews (2021) / Williams (2020) cross-ref на paper #1

Парирование возражений Andrews (2021) (FER как пустая тавтология при отсутствии независимых критериев) и Williams (2020) (FER как корректная, но неинформативная характеристика любой неравновесной системы) развёрнуто в (Andriishin 2026, § S4.4a); в настоящей работе оно не повторяется, но структурное соответствие сохраняется: нестационарный $\eta_v(t)$ закрывает тот же зазор, что и стационарный η_v — требование принадлежности диссипативного потока моделирующему контуру через self-payment. Категория соответствия — *функциональное* (общая структура «оптимизация predictive information под бюджетом»), не онтологическое (полное тождество EFE и η_v как объектов).

S7.6 Метрика информационного омоложения $\rho(t)$: подробно

Метрика информационного омоложения — отношение темпов обновления и роста памяти:

$$\rho(t) = \frac{\dot{M}_{\text{refresh}}(t)}{\dot{M}_{\text{grow}}(t)}.$$

Интерпретация полюсов. $\rho \gg 1$ — обновление обгоняет рост ёмкости: refresh-фракция доминирует, ностальгия ν остаётся низкой (адаптивный режим § 5.3 main). $\rho \ll 1$ — рост ёмкости обгоняет обновление: архивный слой $M_{<t}$ накапливается быстрее, чем успевает обновляться актуальный слой, и ностальгия монотонно растёт (режим ностальгического коллапса).

Эпистемический статус ρ . (13) main — диагностика, независимая от прямого измерения $\nu(t)$: $\dot{M}_{\text{refresh}}$ и $\dot{M}_{\text{grow}}$ измеримы операционально в системах, где прямая оценка $\nu(t)$ через (7) main недоступна. У бактерии $\dot{M}_{\text{refresh}}$ — частота CheB-опосредованного деметилирования рецепторов; $\dot{M}_{\text{grow}}$ — частота репликации с добавлением новых копий рецепторов. У LLM-corp $\dot{M}_{\text{refresh}}$ — частота continual pre-training или RAG-обновления индекса; $\dot{M}_{\text{grow}}$ — частота расширения корпоративного корпуса.

Эмпирическая калибровка. Численные пороги ρ_c — отдельное исследование. В первом приближении $\rho \sim 1$ соответствует балансовому условию (11) main; точное соотношение $\rho_c(\lambda, \sigma, K, \tau_{1/2})$ зависит от той же параметрической структуры, что и ν_c^{theor} (S5.3 supplementary), и наследует её открытый статус.

Эпистемо-прагматическая декомпозиция (опционально). В терминах active inference $\rho(t)$ можно интерпретировать как баланс эпистемического импульса (увеличение эпистемической ценности через $\dot{M}_{\text{refresh}}$) и прагматической инвестиции (расширение горизонта политики через $\dot{M}_{\text{grow}}$). Эта декомпозиция — естественное следствие соответствия S7.1; её формальная разработка требует sophisticated inference framework S7.2.

S8. Адиабатическая асимптотика L_{excess} (открытая гипотеза)

Раздел содержит полную развёртку *открытой, неподтверждённой* гипотезы об адиабатической асимптотике кумулятивной excess-loss. Численный скан S8.3 поддерживает функциональную форму $(K/2) \ln(\lambda t)$, но подгоночный коэффициент не достигает $K/2$ — поведение, скорее указывающее на структурную недостижимость предела (адиабатический логарифм реализуется лишь транзитивно, затем L_{excess} выходит на плато), чем на недобор точек. Гипотеза изложена как вторичная надстройка, не входящая в ядро работы; статус её достижимости остаётся открытым. Структура: S8.1 — постановка гипотезы и теоретическая мотивация; S8.2 — условия применимости и разделение двух адиабатических режимов; S8.3 — параметрический скан и численная поддержка.

Конверсия единиц для L_{excess} (наты $\leftrightarrow$ биты) — Приложение A main: L_{excess} измеряется в **натах** (BNT-форма $(K/2) \ln N$; в оригинале (Bialek et al. 2001, § IV) — в битах, $(K/2) \log_2 N$); явная конверсия $L_{\text{excess}}^{[\text{бит}]}(t) = L_{\text{excess}}^{[\text{нат}]}(t) / \ln 2$ применяется при сравнении с основным текстом.

S8.1 Постановка гипотезы и теоретическая мотивация

Альтернативная теоретическая характеристика накопления информации обучающейся системой о латентном параметре среды — кумулятивная excess-loss обучателя относительно оракула:

$$L_{\text{excess}}(t) := \sum_{s \leq t} [\ln p(X_s | X_{s-1}, \theta_v(s)) - \ln \hat{p}(X_s | X_{s-1}, \hat{\theta}_v(s))]. \quad (\text{S8.1})$$

Здесь $\theta_v(s)$ — истинное значение латентного параметра среды на шаге s , $\hat{\theta}_v(s)$ — оценка обучателя по истории наблюдений; $L_{\text{excess}}(t)$ измеряется в натах. Операциональный статус (S8.1): эта величина непосредственно вычислима в симуляциях с известной ground truth $\theta_v(s)$, но в реальных системах (биосфера, LLM-corp, бактерия) латентный параметр $\theta_v(s)$ принципиально недоступен — L_{excess} остаётся контрфактической, теоретически родственной операционально измеримой одношаговой $I_{\text{pred}}(t, \tau)$ (4) main, но не эквивалентной ей.

Связь с (4) main и термодинамикой памяти. $L_{\text{excess}}(t)$ — кумулятивный Bayesian regret обучателя относительно оракула в смысле (Rissanen 1986; Clarke and Barron 1990); для регулярных параметрических моделей он асимптотически связан с $I(M_{\leq t}; \theta_v(t))$ через теорему о достаточной статистике в смысле (Cover and Thomas 2006, гл. 2.9). *Вывод regret $\leftrightarrow$ накопленная MI*. Заменяя точечную оценку байесовской смесевой предсказательной плотностью $\hat{p}(X_s | X_{<s}) = \int p(X_s | X_{s-1}, \theta) \pi(\theta | X_{<s}) d\theta$, ожидаемая пошаговая избыточная лог-потеря есть условный информационный выигрыш о латенте:

$$\mathbb{E}[\ln p(X_s | X_{s-1}, \theta_v) - \ln \hat{p}(X_s | X_{<s})] = I(X_s; \theta_v | X_{<s}).$$

Суммируя по $s \leq t$ и применяя chain rule для взаимной информации, кумулятивный regret телескопируется в полную MI между данными и латентом:

$$\mathbb{E}[L_{\text{excess}}(t)] = \sum_{s \leq t} I(X_s; \theta_v | X_{<s}) = I(X_{1:t}; \theta_v) = I(M_{\leq t}; \theta_v),$$

где последнее равенство — достаточность $M_{\leq t}$ как статистики истории для θ_v . Именно поэтому L_{excess} измеряет *накопленную* информацию памяти о латенте и в регулярном K -параметрическом случае растёт как $(K/2) \ln(\cdot)$ (мотивация (S8.2)). Различие: L_{excess} — *интегральная* информация о латенте, накопленная к моменту t ; (4) main — *плотность* информационного потока через текущий шаг, ограниченная $\ln k$.

Гипотеза S8.1 (адиабатическая асимптотика). В адиабатическом OU-пределе $\sigma^2/\lambda \ll 1$ при идеальном байесовском обучении кумулятивная excess-loss $L_{\text{excess}}(t)$ (S8.1) растёт как $(K/2) \ln(\lambda t)$ — Class II асимптотика (Bialek et al. 2001, § IV):

$$L_{\text{excess}}^{\text{Bialek}}(t) \sim \frac{K}{2} \ln(\lambda t), \quad (\text{S8.2})$$

где $K = k(k-1)$ — размерность логитов. Скорость накопления вторичной метрики в ведущем порядке при $t \rightarrow \infty$ в адиабатическом OU-пределе $\sigma^2/\lambda \ll 1$ при идеальном байесовском обучателе:

$$\dot{L}_{\text{excess}}(t) \sim \frac{K}{2t}. \quad (\text{S8.3})$$

Статус гипотезы. (S8.2) — известная Class II асимптотика BNT (Bialek et al. 2001) для регулярных параметрических моделей; коэффициент $K/2$ возникает в нескольких парадигмах статистической теории обучения для регулярных параметрических моделей размерности K : MDL (Rissanen 1986; Grünwald 2007) и BIC (Schwarz 1978) через Laplace approximation на posterior; PAC-Bayes (McAllester 1999; Catoni 2007) для гауссова prior; online Newton-step regret (Cesa-Bianchi and Lugosi 2006; Hazan et al. 2007) для exp-concave loss (формальный класс, к которому применима логарифмическая граница (Hazan et al. 2007); self-concordant — более узкое свойство, не использованное в Hazan et al. 2007). (S8.3) — её прямое дифференцирование. Важно: L_{excess} — *вторичная, контрфактическая* метрика (требует доступа к ground truth $\theta_v(s)$); она **не** отождествляется с операционально измеримой эффективностью $\eta_v = I_{\text{pred}}/I_{\text{mem}}$ (1) main и не делится на какой-либо энергетический бюджет: L_{excess} — самостоятельный контрфактический объект (BNT-избыток потерь), а не нормированная на Rt величина. Гипотетический статус относится к двум аспектам: (i) сходимости подгоночного коэффициента к $K/2$ — численный скан (S8.3) показывает монотонный рост $B/(K/2)$ без достижения предела, что скорее указывает на структурную недостижимость (реализуемость лишь транзитивно, затем плато), чем на недобор точек; аналитическое значение $K/2$ остаётся тождеством предела $\epsilon_{\text{track}} \rightarrow 0$, не достижимым законом. (ii) переносимости адиабатической Class II картины на операционально измеримую $\eta_v(t)$ (1) main, ограниченную $\ln k$ на шаг и потому *не* растущую как $\ln(\lambda t)$. Оба аспекта остаются открытыми; работа *не* заявляет асимптотику как результат.

S8.2 Условия применимости и разделение двух адиабатических режимов

Гипотеза S8.1 требует *одновременного* выполнения двух условий (см. § 5.2 main):

1. **Slow-driving** $\lambda \tau_{\text{relax}} \ll 1$ — необходимо для применимости Леммы 2 § 4.4 main и квазистационарной интерпретации $\theta_v(t)$.
2. **OU-concentration** $\sigma^2/\lambda \ll 1$ — необходимо именно для (S8.2), не для (4) main: концентрация апостериора по $\theta_v(t)$ должна обгонять собственный дрейф $\theta_v(t)$.

Дополнительно: (iii) ограниченно растущая память (Class II BNT-режим требует регулярной K -параметрической модели фиксированной размерности,

$|M_{\leq t}| = o(t/\ln t)$); (iv) OU-параметризация именно логитов (softmax-форма обеспечивает регулярность параметрической модели); (v) идеальный байесовский обучатель (плата за обновление — в $\dot{E}_{\text{actual}}^{\text{curr}}$, не в ностальгическом слое).

S8.3 Параметрический скан и численная поддержка гипотезы

Численное исследование (S8.2) — параметрический скан OU-симуляции по σ^2/λ с прямым измерением (S8.1). Реализация — `simulations/markov_drift_ou_iinf_adiab/`.

Модель. OU-параметризация § 5.2 / § 6.2 main без изменений ($k = 8$, $\lambda = 10^{-3}$, $K = 56$, Эйлер—Маруяма $\Delta t = 1$); идеальный байесовский обучатель аппроксимирован Роббинс—Монро $\eta_t = c/\sqrt{t}$, $c = 3$. Измеряется $L_{\text{excess}}(t)$ по (S8.1) напрямую — не ограничена $\ln k$, асимптотически растёт как (S8.2).

Параметрический скан. Три значения σ при фиксированном $\lambda = 10^{-3}$: $\sigma \in \{0,01, 0,003, 0,001\}$, дающие $\sigma^2/\lambda \in \{0,1, 9 \cdot 10^{-3}, 10^{-3}\}$ соответственно. Transient-окно $1/\sigma^2 \in \{10^4, 1,1 \cdot 10^5, 10^6\}$; время симуляции $T_{\text{total}} \in \{5 \cdot 10^4, 5 \cdot 10^4, 2 \cdot 10^5\}$ в пределах transient-окна для всех случаев. Каждая точка — среднее по 25 независимым реализациям OU-процесса; зерно SEED = 20260524. Совместная подгонка $L_{\text{excess}}(t) = A \cdot t + B \cdot \ln(\lambda t) + C$ на окне $t \in [10^3, 10^4]$ (фиксированном для прямого сопоставления между σ).

Результаты. Рис. 6: B против σ^2/λ (`paper/figs/Fig6.pdf`). Рис. 7: семейство $L_{\text{excess}}(t)$ для трёх σ (`paper/figs/Fig7.pdf`).

σ	σ^2/λ	B	$B/(K/2)$	R^2	drift-share при $t = 10^4$
0,01	10^{-1}	15,15	0,54	0,9998	76%
0,003	$9 \cdot 10^{-3}$	21,85	0,78	0,9996	27%
0,001	10^{-3}	23,84	0,85	0,9995	10%

Коэффициент B монотонно растёт при $\sigma^2/\lambda \rightarrow 0$, давая $B/(K/2) = 0,54, 0,78, 0,85$ соответственно; $R^2 \geq 0,9995$ во всех точках, drift-share $A \cdot t/L_{\text{excess}}(t)$ падает с 76% до 10%.

Отрицательный контроль с расширенным окном. При расширении окна совместной подгонки до $[10^3, T_{\text{total}}]$ (вместо фиксированного $[10^3, 10^4]$) фит вырождается: при $\sigma^2/\lambda = 10^{-3}$ и $T_{\text{total}} = 2 \cdot 10^5$ коэффициент $B/(K/2)$ растёт до 2,0 — артефакт Роббинс—Монро $1/\sqrt{t}$ -bias обучателя на длинных горизонтах, не часть BNT-эффекта. Окно $[10^3, 10^4]$ выбрано для прямого сопоставления между точками адиабатической серии и согласовано с transient-условием $t \ll 1/\sigma^2$. Этот контроль фиксирует чувствительность результата к выбору окна фита и предотвращает интерпретацию монотонного тренда $B/(K/2)$ как результата выборочного предъявления.

Интерпретация. Функциональная форма $L_{\text{excess}}(t) = A \cdot t + B \ln(\lambda t) + C$ привлекается с $R^2 \geq 0,9995$; коэффициент B монотонно растёт от 0,54 до $0,85 \cdot K/2$

при σ^2/λ от 10^{-1} до 10^{-3} . **Это не доказательство сходимости** $B \rightarrow K/2$: монотонный рост $B/(K/2)$ не достигает единицы, и это поведение согласуется скорее с тем, что предел *структурно недостижим* (адиабатический логарифм реализуется лишь транзитивно, после чего L_{excess} выходит на плато), чем с недобором точек скана.

Работа поэтому *не* заявляет асимптотику $(K/2) \ln(\lambda t)$ как достижимый закон: подтверждена лишь функциональная *форма*, а её статус как асимптотического предела остаётся открытым (см. § 8.5 main).

Воспроизводимость. Полная реализация — `simulations/markov_drift_ou_iinf_adiab/` (`model.py`, `main.py`, `README.md`); графики в `paper/figs/Fig6.pdf` и `paper/figs/Fig7.pdf`; сводный лог — `simulations/markov_drift_ou_iinf_adiab/results_summary.{txt,json}` и `run.log`. Зерно SEED = 20260524; запуск `python main.py` (~1 минута на современном ноутбуке) восстанавливает все численные значения.

S9. Детали §§ 2.1 и 2.3 main: three-faces-сопоставление и majority-vote-деривация

Раздел собирает плотный стат-механический аппарат, вынесенный из §§ 2.1–2.3 main для разгрузки основного изложения. S9.1 — полное сопоставление декомпозиции (1) main с three-faces / Hatano–Sasa классификацией entropy production; S9.2 — полный вывод majority-vote-варианта Леммы 1 (формула (3') main); S9.3 — безусловная граница $\eta_v \leq 1$ из DPI, активный случай и Bennett-оговорка (детали § 2.1 main); S9.4 — мгновенная против горизонтной ностальгии, кумулятивный бонд как сумма пошаговых вкладов и стационарный предел (детали §§ 2.2, 2.5 main).

S9.1 Сопоставление декомпозиции (1) main с three-faces / Hatano–Sasa

Декомпозиция (1) main *тематически параллельна* three-faces-разложению entropy production (Esposito and Van den Broeck 2010) и Hatano–Sasa-декомпозиции (Hatano and Sasa 2001), но не сводится к ней автоматически. В канонической трактовке housekeeping-компонента поддерживает фиксированный NESS при стационарных управляющих параметрах, excess-компонента — изменение NESS под медленным изменением параметров. Соответствие компонент (1) main:

- $\dot{E}_{\text{store}}$ для удержания конкретного информационного состояния против релаксации к симметричному равновесию относится к *excess*-классу (relaxation-driven), а не к housekeeping: поддерживается не фиксированный NESS, а конкретное

неравновесное информационное состояние, релаксирующее к симметричному равновесию.

- $\dot{E}_{\text{actual}}^{\text{curr}}$ при перенастройке $\hat{P}(t)$ под дрейф среды также относится к excess-классу (изменение целевого состояния под медленным дрейфом параметров).
- refresh-операции Леммы 1 — серия неравновесных протоколов поверх этого, не сводимая ни к чисто housekeeping, ни к чисто excess.
- $\dot{E}_{\text{grow}}$ — структурная перестройка (constraint-driven), выходящая за рамки канонической трёхчастной декомпозиции: добавление новых степеней свободы меняет само пространство состояний, а не только распределение на нём.

Точное вложение нестационарной информационной декомпозиции в three-faces-аппарат — открытая задача (§ 8.5 main).

S9.2 Полный вывод majority-vote-варианта Леммы 1 (формула (3') main)

В пределе $\varepsilon \rightarrow 0$ полиномиальная граница (3) main $\sim 1/\varepsilon$ заменяется majority-vote-вариантом через избыточное кодирование. Для n копий бита с независимыми ошибками $\varepsilon < 1/2$ majority-vote ошибается, лишь когда не менее $n/2$ копий перевернуты; вероятность этого хвоста биномиала $\text{Bin}(n, \varepsilon)$ ограничивается границей Чернова

$$\varepsilon^{\text{eff}} = \Pr[\text{Bin}(n, \varepsilon) \geq n/2] \leq \exp(-n D(\tfrac{1}{2} \parallel \varepsilon)), \quad D(\tfrac{1}{2} \parallel \varepsilon) = \tfrac{1}{2} \ln \frac{1}{4\varepsilon(1-\varepsilon)},$$

где $D(\tfrac{1}{2} \parallel \varepsilon)$ — KL-дивергенция Бернулли $\text{Ber}(1/2)$ от $\text{Ber}(\varepsilon)$. Здесь ε в $D(\tfrac{1}{2} \parallel \varepsilon)$ — *сырая покопийная ошибка* (вероятность переворота на одну копию бита, физический параметр носителя), тогда как ε^{eff} — *целевая* (достигаемая) эффективная ошибка декодированного бита после majority-vote; именно различие этих двух величин и обеспечивает экспоненциальное подавление $\varepsilon^{\text{eff}} \leq e^{-nD(\tfrac{1}{2} \parallel \varepsilon)}$ при фиксированном $\varepsilon < 1/2$. Отсюда для достижения целевой эффективной ошибки ε^{eff} достаточно

$$n \sim \frac{\ln(1/\varepsilon^{\text{eff}})}{D(\tfrac{1}{2} \parallel \varepsilon)}$$

копий — *логарифмическое* по $1/\varepsilon^{\text{eff}}$ число копий (а не линейное по $1/\varepsilon$, как в naive refresh). Каждая из n копий деградирует независимо с тем же $\tau_{1/2}$, поэтому темп refresh для majority-vote сохраняет фактор $t/\tau_{1/2}$ (число refresh-циклов), но плата на цикл — логарифмическая по $1/\varepsilon$, а не полиномиальная:

$$E_{\text{store}}^{(1), \text{maj}}(t) \geq C \cdot \frac{t}{\tau_{1/2}} \cdot k_B T \ln(1/\varepsilon), \quad C = O(1), \quad (3')$$

с константой C , зависящей от схемы majority-vote (Sagawa–Ueda расширение Sagawa and Ueda 2009; Parrondo et al. 2015). Структурно (3) main и (3') совпадают по линейному росту с $t/\tau_{1/2}$ — числу refresh-циклов; различие — по

зависимости от ε : полиномиальная в *naïve* / логарифмическая в *majority-vote*. Класс систем-камертонов, к которым применима исходная (3) *main*: ферромагнитные домены тёплых сред и системы с *naïve refresh*; для биологических систем с *feedback-репарацией* используется (3') с логарифмической зависимостью от ε . *Feedback-assisted refresh* (DNA mismatch repair) дополнительно смягчает границу по Sagawa–Ueda $\langle W \rangle \geq k_B T (\Delta S - I_{\text{meas}})$ (Sagawa and Ueda 2009): обнуляется *структурированный* бит с условной энтропией $H(\varepsilon) = -\varepsilon \ln \varepsilon - (1 - \varepsilon) \ln(1 - \varepsilon) \ll \ln 2$ при $\varepsilon \ll 1$, и в пределе идеального измерения цена *refresh* уходит к нулю — асимптотика автономных демонов Максвелла (Koski et al. 2014; Mandal and Jarzynski 2012; Barato and Seifert 2014; Bauer et al. 2014).

S9.3 $\eta_v \leq 1$: безусловное следствие DPI; активный случай; Bennett-оговорка

Граница $\eta_v = I_{\text{pred}}/I_{\text{mem}} \in [0, 1]$ (1) *main* — прямое следствие неравенства об обработке данных (data processing inequality, DPI) для **пассивного** самодекодирования; это чисто информационное утверждение, не требующее шага через термодинамику (принцип Ландауэра, аргумент о стирании). Термодинамика входит отдельно — бондом Still (§ 2.2 *main*). Обе линии разведены явно.

Безусловная граница (пассивный случай). Память формируется из прошлого среды с внутренним шумом $M_{\leq t} = f(X_E^{\leq t}, \zeta_v)$, где ζ_v не несёт информации о будущем среды сверх содержащейся в прошлом: $\zeta_v \perp X_E^{[t, t+\tau]} \mid X_E^{\leq t}$. Тогда тройка образует марковскую цепь

$$M_{\leq t} \rightarrow X_E^{\leq t} \rightarrow X_E^{[t, t+\tau]},$$

и по DPI взаимная информация не возрастает вдоль цепи,

$$I_{\text{pred}} = I(M_{\leq t}; X_E^{[t, t+\tau]}) \leq I(M_{\leq t}; X_E^{\leq t}) = I_{\text{mem}},$$

откуда $\eta_v \in [0, 1]$ и $\nu = 1 - \eta_v \in [0, 1]$. Утверждение **безусловно**: оно следует из марковости и DPI и не требует конечности памяти, стационарности, эргодичности или ландауэровского шага. В нестационарном режиме настоящей работы оно держится для каждого t при растущем $I_{\text{mem}}(t)$ — рост знаменателя не нарушает DPI, а лишь гонит $\eta_v(t) \rightarrow 0$, $\nu(t) \rightarrow 1$ (§ 2.1 *main*). Точная посылка — условная независимость шума $\zeta_v \perp X_E^{[t, t+\tau]} \mid X_E^{\leq t}$, а не более сильное требование «отсутствия обратной связи»; разведение этих двух условий — в активном случае ниже.

Активный случай (открытая задача). Когда внутреннее состояние каузально действует на среду (моторная петля свободно плывущей *E. coli*, агенты *active inference* § 7 *main*), цепь $M_{\leq t} \rightarrow X_E^{\leq t} \rightarrow X_E^{[t, t+\tau]}$ рвётся: действие $a = \pi(M_{\leq t})$ делает память каузальной причиной будущего среды, и формально I_{pred} может превысить I_{mem} — агент сам создаёт корреляцию с будущим, которой нет в его памяти о прошлом. Conditioning на фиксированную политику марковости не восстанавливает. Корректная величина — **направленная** (transfer) информация $T_{M \rightarrow X_E}$; полный термодинамический учёт *feedback* даётся обобщённым вторым

началом $\langle \Sigma \rangle \geq -\langle \Delta I \rangle$ (Sagawa and Ueda 2010; Horowitz and Esposito 2014; Parrondo et al. 2015). Это **открытая задача** (§ 7 main), как и в стационарном случае (Andriishin 2026, § 2.1).

Интервенционная (do) редукция: легитимность пассивного измерения. Открытость активного случая не обесценивает операциональное измерение η_v на иммобилизованном препарате: иммобилизация реализует **do-интервенцию** в смысле Пирла (Pearl 2009). Экзогенный зажим действия $\text{do}(a)$ разрывает причинную стрелку $M_{\leq t} \rightarrow a \rightarrow X_E$ и восстанавливает марковскую цепь $M_{\leq t} \rightarrow X_E^{\leq t} \rightarrow X_E^{[t, t+\tau]}$, так что по DPI

$$\eta_v^{\text{do}} := \frac{I(M_{\leq t}; X_E^{[t, t+\tau]} | \text{do}(a))}{I_{\text{mem}}} \in [0, 1].$$

Числитель здесь интервенционный, знаменатель остаётся наблюдательным I_{mem} : зажим $\text{do}(a)$ в настоящем и будущем не меняет уже сформированную корреляцию памяти с прошлым среды. Для *E. coli* физическая реализация $\text{do}(a)$ — **иммобилизация**: припшпиленная клетка не движет концентрацию лиганда, и иммобилизованный FRET-протокол (§ 2.1, § 8.6 main) измеряет именно $\eta_v^{\text{do}} \in [0, 1]$, а не активную величину. Подчеркнём статус: η_v^{do} — **не новая теорема**, а стандартная do-редукция активного контура к пассивному (Pearl 2009; Andriishin 2026, § 2.1); она фиксирует лишь точный смысл легитимности пассивного $[0, 1]$ -измерения и **не** утверждает ограниченность активного η_v .

Bennett-оговорка. Бонд Still (как и любая ландауэровская оценка) относится к **необратимому** режиму реализации. В Bennett-асимптотике глобально обратимых вычислений (Bennett 1973; 1982; 1989) плата на бит уходит ниже ландауэровской, и термодинамический пол на удержание ностальгии (§ 2.2 main) теряет интерпретативную силу: time/space-tradeoff Bennett (1989) эмулирует необратимое вычисление обратимо ценой логарифмического роста памяти симуляции. В этом режиме якорь переопределяется через число *логически*, а не стираемых битов — операционально другая величина, требующая отдельной калибровки. **Информационная же граница $\eta_v \leq 1$ сохраняется без изменений**, поскольку держится на DPI и не опирается на стирание. Операциональный признак необратимого режима — измеримое тепловыделение $\dot{Q} > 0$ при выполнении информационной операции; обнаружение системы в Bennett-режиме указывает на границу области определения термодинамического якоря, не на нарушение информационного результата $\eta_v \leq 1$.

S9.4 Мгновенная и горизонтная ностальгия; кумулятивный бонд; стационарный предел

Мгновенность против горизонтности. Бонд Still (2) main несёт мгновенную ностальгию на шаге обновления памяти $k \rightarrow k+1$,

$$I_{\text{nonpred}}^{\text{инст}}(k) := I(M_k; X_{E,k}) - I(M_k; X_{E,k+1}) = I_{\text{mem}}^{\text{инст}}(k) - I_{\text{pred}}^{\text{инст}}(k) = \nu^{\text{инст}}(k) I_{\text{mem}}^{\text{инст}}(k) \geq 0,$$

где неотрицательность — DPI на марковской цепи среды $M_k \rightarrow X_{E,k} \rightarrow X_{E,k+1}$. Её следует отличать от **горизонтной** ностальгии (1) main, $\nu(t) = 1 - I_{\text{pred}}(t, \tau)/I_{\text{mem}}(t)$, нормированной на *кумулятивную* память $I_{\text{mem}}(t)$. Это разные шкалы: мгновенная нормируется на одношаговую $I_{\text{инст}}^{\text{mem}}(k)$, горизонтная — на накопленную $I_{\text{mem}}(t)$, растущую во времени. Подстановка горизонтной величины $\nu(t) I_{\text{mem}}(t)$ в пошаговый бонд — формальная ошибка; бонд несёт сумму мгновенных вкладов.

Кумулятивный бонд как сумма пошаговых вкладов. За историю $[0, t]$ каждый шаг обновления оплачивается отдельно, и кумулятивная диссипация ограничена снизу **суммой** пошаговых вкладов, а не произведением $k_B T \nu(t) I_{\text{mem}}(t)$:

$$\left\langle W_{\text{diss}}^{[0,t]} \right\rangle \geq k_B T \sum_{k \leq t} I_{\text{nonpred}}^{\text{инст}}(k)$$

(формула (2-кум) main). Аддитивность — потому что каждый refresh-шаг есть отдельный неравновесный протокол с собственным неотрицательным релаксационным членом (ур. (18) Still); вклады не интерферируют и складываются.

Стационарный предел. При $\dot{I}_{\text{mem}} \rightarrow 0$ (§ 2.5 main) горизонтная $\nu(t)$ выходит на постоянный уровень, но мгновенная $I_{\text{nonpred}}^{\text{инст}}(k)$ при дрейфующей среде ($h_\mu > 0$) остаётся строго положительной: конечно-памятный трекер обязан стирать устаревший бит каждый шаг. Поэтому кумулятивная диссипация (2-кум) продолжает расти **линейно** с положительной удельной скоростью

$$\frac{1}{t} \left\langle W_{\text{diss}}^{[0,t]} \right\rangle \geq k_B T \overline{I_{\text{nonpred}}^{\text{инст}}} > 0,$$

где $\overline{I_{\text{nonpred}}^{\text{инст}}}$ — среднее мгновенной непредсказательной информации по стационарному распределению. Это строгий термодинамический смысл неустранимости платы за удержание даже в стационаре (§ 2.5 main): эффективность η_v стабильна, а диссипация удержания не обнуляется.

Список литературы

- Amit, D.J., Gutfreund, H., Sompolinsky, H.: Storing infinite numbers of patterns in a spin-glass model of neural networks. *Phys. Rev. Lett.* **55**(14), 1530–1533 (1985) <https://doi.org/10.1103/PhysRevLett.55.1530>
- Andrews, M.: The math is not the territory: navigating the free energy principle. *Biology & Philosophy* **36**(3), 30 (2021) <https://doi.org/10.1007/s10539-021-09807-0>
- Andriishin, A.: Vitality as the Efficiency of Self-Paid Self-Modeling. Companion paper submitted simultaneously to *Theory in Biosciences* (Springer); preprint deposited on Zenodo. Public open-access mirror: <https://github.com/andriishin/landauer-self-modeling-oa>. (2026). <https://doi.org/10.5281/zenodo.21039160>

- Alon, U., Surette, M.G., Barkai, N., Leibler, S.: Robustness in bacterial chemotaxis. *Nature* **397**(6715), 168–171 (1999) <https://doi.org/10.1038/16483>
- Bauer, M., Abreu, D., Seifert, U.: Efficiency of a Brownian information machine. *J. Phys. A: Math. Theor.* **47**(29), 292002 (2014) <https://doi.org/10.1088/1751-8113/47/29/292002>
- Bruineberg, J., Dołęga, K., Dewhurst, J., Baltieri, M.: The Emperor’s new Markov blankets. *Behav. Brain Sci.* **45**, 183 (2022) <https://doi.org/10.1017/S0140525X21002351>
- Bennett, C.H.: Logical reversibility of computation. *IBM J. Res. Dev.* **17**(6), 525–532 (1973) <https://doi.org/10.1147/rd.176.0525>
- Bennett, C.H.: The thermodynamics of computation—a review. *Int. J. Theor. Phys.* **21**(12), 905–940 (1982) <https://doi.org/10.1007/BF02084158>
- Bennett, C.H.: Time/space trade-offs for reversible computation. *SIAM Journal on Computing* **18**(4), 766–776 (1989) <https://doi.org/10.1137/0218053>
- Bifet, A., Gavalda, R.: Learning from time-changing data with adaptive windowing. In: *Proceedings of the 2007 SIAM International Conference on Data Mining*, pp. 443–448 (2007). <https://doi.org/10.1137/1.9781611972771.42>
- Besbes, O., Gur, Y., Zeevi, A.: Non-stationary stochastic optimization. *Oper. Res.* **63**(5), 1227–1244 (2015) <https://doi.org/10.1287/opre.2015.1408>
- Belkin, M., Hsu, D., Ma, S., Mandal, S.: Reconciling modern machine-learning practice and the classical bias–variance trade-off. *Proc. Natl. Acad. Sci. USA* **116**(32), 15849–15854 (2019) <https://doi.org/10.1073/pnas.1903070116>
- Bruineberg, J., Kiverstein, J., Rietveld, E.: The anticipating brain is not a scientist: The free-energy principle from an ecological-enactive perspective. *Synthese* **195**, 2417–2444 (2018) <https://doi.org/10.1007/s11229-016-1239-1>
- Boyd, A.B., Mandal, D., Crutchfield, J.P.: Leveraging environmental correlations: The thermodynamics of requisite variety. *J. Stat. Phys.* **167**(6), 1555–1585 (2017) <https://doi.org/10.1007/s10955-017-1776-0>
- Borgeaud, S., Mensch, A., Hoffmann, J., Cai, T., Rutherford, E., Millican, K., Driessche, G., Lespiau, J.-B., Damoc, B., Clark, A., *et al.*: Improving language models by retrieving from trillions of tokens. In: *Proceedings of the 39th International Conference on Machine Learning (ICML)*, vol. 162, pp. 2206–2240 (2022)
- Bialek, W., Nemenman, I., Tishby, N.: Predictability, complexity, and learning. *Neural Comput.* **13**(11), 2409–2463 (2001) <https://doi.org/10.1162/089976601753195969>

- Bogacz, R.: A tutorial on the free-energy framework for modelling perception and learning. *J. Math. Psychol.* **76**, 198–211 (2017) <https://doi.org/10.1016/j.jmp.2015.11.003>
- Boyd, R.: Realism, anti-foundationalism and the enthusiasm for natural kinds. *Philosophical Studies* **61**(1–2), 127–148 (1991) <https://doi.org/10.1007/BF00385837>
- Barato, A.C., Seifert, U.: Stochastic thermodynamics with information reservoirs. *Phys. Rev. E* **90**(4), 042150 (2014) <https://doi.org/10.1103/PhysRevE.90.042150>
- Bricken, T., Templeton, A., Batson, J., Chen, B., Jermyn, A., Conerly, T., Turner, N., Anil, C., Denison, C., Aspell, A., et al.: Towards monosemanticity: Decomposing language models with dictionary learning. *Transformer Circuits Thread*, Anthropic. <https://transformer-circuits.pub/2023/monosemantic-features/> (2023)
- Catoni, O.: PAC-Bayesian Supervised Classification: The Thermodynamics of Statistical Learning. *IMS Lecture Notes Monograph Series*, vol. 56. Institute of Mathematical Statistics, ??? (2007). <https://doi.org/10.1214/074921707000000391>
- Clarke, B.S., Barron, A.R.: Information-theoretic asymptotics of Bayes methods. *IEEE Trans. Inf. Theory* **36**(3), 453–471 (1990) <https://doi.org/10.1109/18.54897>
- Cesa-Bianchi, N., Lugosi, G.: *Prediction, Learning, and Games*. Cambridge University Press, ??? (2006). <https://doi.org/10.1017/CBO9780511546921>
- Crutchfield, J.P., Feldman, D.P.: Regularities unseen, randomness observed: levels of entropy convergence. *Chaos* **13**(1), 25–54 (2003) <https://doi.org/10.1063/1.1530990>
- Cleland, C.E.: *The Quest for a Universal Theory of Life: Searching for Life As We Don't Know It*. Cambridge University Press, Cambridge (2019). <https://doi.org/10.1017/9781139046893>
- Crooks, G.E.: Entropy production fluctuation theorem and the nonequilibrium work relation for free energy differences. *Phys. Rev. E* **60**(3), 2721–2726 (1999) <https://doi.org/10.1103/PhysRevE.60.2721>
- Cover, T.M., Thomas, J.A.: *Elements of Information Theory*, 2nd edn. Wiley-Interscience, Hoboken, NJ (2006)
- Cummins, R.: Functional analysis. *The Journal of Philosophy* **72**(20), 741–765 (1975) <https://doi.org/10.2307/2024640>
- Dhingra, B., Cole, J.R., Eisenschlos, J.M., Gillick, D., Eisenstein, J., Cohen, W.W.: Time-aware language models as temporal knowledge bases. *Trans. Assoc. Comput. Linguist.* **10**, 257–273 (2022) https://doi.org/10.1162/tacl_a_00459
- Decaestecker, E., Gaba, S., Raeymaekers, J.A.M., Stoks, R., Van Kerckhoven, L.,

- Ebert, D., De Meester, L.: Host–parasite “Red Queen” dynamics archived in pond sediment. *Nature* **450**(7171), 870–873 (2007) <https://doi.org/10.1038/nature06291>
- Errington, J.: Regulation of endospore formation in *bacillus subtilis*. *Nature Reviews Microbiology* **1**(2), 117–126 (2003) <https://doi.org/10.1038/nrmicro750>
- Engel, A., Broeck, C.: *Statistical Mechanics of Learning*. Cambridge University Press, ??? (2001)
- Esposito, M., Broeck, C.: Three faces of the second law. I. Master equation formulation. *Phys. Rev. E* **82**(1), 011143 (2010) <https://doi.org/10.1103/PhysRevE.82.011143>
- Endres, R.G., Wingreen, N.S.: Precise adaptation in bacterial chemotaxis through “assistance neighborhoods”. *Proc. Natl. Acad. Sci. USA* **103**(35), 13040–13044 (2006) <https://doi.org/10.1073/pnas.0603101103>
- Finn, C., Abbeel, P., Levine, S.: Model-agnostic meta-learning for fast adaptation of deep networks. In: *Proceedings of the 34th International Conference on Machine Learning (ICML)*, vol. 70, pp. 1126–1135 (2017)
- Friston, K., Da Costa, L., Hafner, D., Hesp, C., Parr, T.: Sophisticated inference. *Neural Comput.* **33**(3), 713–763 (2021) https://doi.org/10.1162/neco_a_01351
- Friston, K., FitzGerald, T., Rigoli, F., Schwartenbeck, P., Pezzulo, G.: Active inference: a process theory. *Neural Comput.* **29**(1), 1–49 (2017) https://doi.org/10.1162/NECO_a_00912
- Friston, K., Lin, M., Frith, C.D., Pezzulo, G., Hobson, J.A., Ondobaka, S.: Active inference, curiosity and insight. *Neural Comput.* **29**(10), 2633–2683 (2017) https://doi.org/10.1162/neco_a_00999
- Friston, K.: The free-energy principle: a unified brain theory? *Nat. Rev. Neurosci.* **11**(2), 127–138 (2010) <https://doi.org/10.1038/nrn2787>
- Gama, J., Medas, P., Castillo, G., Rodrigues, P.P.: Learning with drift detection. In: *Advances in Artificial Intelligence – SBIA 2004*, pp. 286–295 (2004). https://doi.org/10.1007/978-3-540-28645-5_29
- Goodfellow, I.J., Mirza, M., Xiao, D., Courville, A., Bengio, Y.: An empirical investigation of catastrophic forgetting in gradient-based neural networks (2014)
- Grünwald, P.D.: *The Minimum Description Length Principle*. MIT Press, ??? (2007)
- Godfrey-Smith, P.: *Darwinian Populations and Natural Selection*. Oxford University Press, Oxford (2009)
- Goldt, S., Seifert, U.: Stochastic thermodynamics of learning. *Phys. Rev. Lett.* **118**(1), 010601 (2017) <https://doi.org/10.1103/PhysRevLett.118.010601>

- Garg, S., Tsipras, D., Liang, P., Valiant, G.: What can transformers learn in-context? A case study of simple function classes. In: *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, pp. 30583–30598 (2022)
- Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., Bouchachia, A.: A survey on concept drift adaptation. *ACM Comput. Surv.* **46**(4), 44–14437 (2014) <https://doi.org/10.1145/2523813>
- Hazan, E., Agarwal, A., Kale, S.: Logarithmic regret algorithms for online convex optimization. *Mach. Learn.* **69**(2–3), 169–192 (2007) <https://doi.org/10.1007/s10994-007-5016-8>
- Hartich, D., Barato, A.C., Seifert, U.: Stochastic thermodynamics of bipartite systems: transfer entropy inequalities and a maxwell’s demon interpretation. *J. Stat. Mech.*, 02016 (2014) <https://doi.org/10.1088/1742-5468/2014/02/P02016>
- Horowitz, J.M., Esposito, M.: Thermodynamics with continuous information flow. *Physical Review X* **4**(3), 031015 (2014) <https://doi.org/10.1103/PhysRevX.4.031015>
- Hopfield, J.J.: Neural networks and physical systems with emergent collective computational abilities. *Proc. Natl. Acad. Sci. USA* **79**(8), 2554–2558 (1982) <https://doi.org/10.1073/pnas.79.8.2554>
- Hatano, T., Sasa, S.-i.: Steady-state thermodynamics of Langevin systems. *Phys. Rev. Lett.* **86**(16), 3463–3466 (2001) <https://doi.org/10.1103/PhysRevLett.86.3463>
- Hazan, E., Seshadhri, C.: Efficient learning algorithms for changing environments. In: *Proceedings of the 26th International Conference on Machine Learning (ICML)*, pp. 393–400 (2009). <https://doi.org/10.1145/1553374.1553425>
- Izacard, G., Lewis, P., Lomeli, M., Hosseini, L., Petroni, F., Schick, T., Dwivedi-Yu, J., Joulin, A., Riedel, S., Grave, E.: Atlas: Few-shot learning with retrieval augmented language models. *J. Mach. Learn. Res.* **24**(251), 1–43 (2023)
- Jarzynski, C.: Nonequilibrium equality for free energy differences. *Phys. Rev. Lett.* **78**(14), 2690–2693 (1997) <https://doi.org/10.1103/PhysRevLett.78.2690>
- Karnin, Z., Anava, O.: Multi-armed bandits: Competing with optimal sequences. In: *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 29, pp. 199–207 (2016)
- Khalidi, M.A.: *Natural Categories and Human Kinds: Classification in the Natural and Social Sciences*. Cambridge University Press, Cambridge (2013). <https://doi.org/10.1017/CBO9781139022507>
- Kussell, E., Leibler, S.: Phenotypic diversity, population growth, and information in

- fluctuating environments. *Science* **309**(5743), 2075–2078 (2005) <https://doi.org/10.1126/science.1114383>
- Khandelwal, U., Levy, O., Jurafsky, D., Zettlemoyer, L., Lewis, M.: Generalization through memorization: Nearest neighbor language models. In: *International Conference on Learning Representations (ICLR)* (2020)
- Koski, J.V., Maisi, V.F., Sagawa, T., Pekola, J.P.: Experimental observation of the role of mutual information in the nonequilibrium dynamics of a Maxwell demon. *Phys. Rev. Lett.* **113**(3), 030601 (2014) <https://doi.org/10.1103/PhysRevLett.113.030601>
- Kirkpatrick, J., Pascanu, R., Rabinowitz, N., Veness, J., Desjardins, G., Rusu, A.A., Milan, K., Quan, J., Ramalho, T., Grabska-Barwinska, A., Hassabis, D., Clopath, C., Kumaran, D., Hadsell, R.: Overcoming catastrophic forgetting in neural networks. *Proc. Natl. Acad. Sci. USA* **114**(13), 3521–3526 (2017) <https://doi.org/10.1073/pnas.1611835114>
- Kraskov, A., Stögbauer, H., Grassberger, P.: Estimating mutual information. *Phys. Rev. E* **69**(6), 066138 (2004) <https://doi.org/10.1103/PhysRevE.69.066138>
- Landauer, R.: Irreversibility and heat generation in the computing process. *IBM J. Res. Dev.* **5**(3), 183–191 (1961) <https://doi.org/10.1147/rd.53.0183>
- Landenmark, H.K.E., Forgan, D.H., Cockell, C.S.: An estimate of the total DNA in the biosphere. *PLoS Biol.* **13**(6), 1002168 (2015) <https://doi.org/10.1371/journal.pbio.1002168>
- Lazaridou, A., Kuncoro, A., Gribovskaya, E., Agrawal, D., Liska, A., Terzi, T., Gimenez, M., Masson d’Autume, C., Kocisky, T., Ruder, S., *et al.*: Mind the gap: Assessing temporal generalization in neural language models. In: *Advances in Neural Information Processing Systems*, vol. 34, pp. 29348–29363 (2021)
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., Kiela, D.: Retrieval-augmented generation for knowledge-intensive NLP tasks. In: *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, pp. 9459–9474 (2020)
- Lopez-Paz, D., Ranzato, M.: Gradient episodic memory for continual learning. In: *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30 (2017)
- Levin, D.A., Peres, Y., Wilmer, E.L.: *Markov Chains and Mixing Times*, 2nd edn. American Mathematical Society, Providence, RI (2017)
- Lan, G., Sartori, P., Neumann, S., Sourjik, V., Tu, Y.: The energy–speed–accuracy trade-off in sensory adaptation. *Nat. Phys.* **8**(5), 422–428 (2012) <https://doi.org/10.1038/nphys2276>

- McCloskey, M., Cohen, N.J.: Catastrophic interference in connectionist networks: the sequential learning problem. In: Bower, G.H. (ed.) *Psychology of Learning and Motivation* vol. 24, pp. 109–165. Academic Press, ??? (1989). [https://doi.org/10.1016/S0079-7421\(08\)60536-8](https://doi.org/10.1016/S0079-7421(08)60536-8)
- McAllester, D.A.: PAC-Bayesian model averaging. In: *Proceedings of the Twelfth Annual Conference on Computational Learning Theory (COLT)*, pp. 164–170 (1999). <https://doi.org/10.1145/307400.307435>
- Mandal, D., Jarzynski, C.: Work and information processing in a solvable model of Maxwell’s demon. *Proc. Natl. Acad. Sci. USA* **109**(29), 11641–11645 (2012) <https://doi.org/10.1073/pnas.1204263109>
- Mossio, M., Montévil, M., Longo, G.: Theoretical principles for biology: Organization. *Progress in Biophysics and Molecular Biology* **122**(1), 24–35 (2016) <https://doi.org/10.1016/j.pbiomolbio.2016.07.005>
- Mehta, P., Schwab, D.J.: Energetic costs of cellular computation. *Proc. Natl. Acad. Sci. USA* **109**(44), 17978–17982 (2012) <https://doi.org/10.1073/pnas.1207814109>
- Maynard Smith, J., Szathmáry, E.: *The Major Transitions in Evolution*. Oxford University Press, Oxford (1995)
- Maturana, H.R., Varela, F.J.: *Autopoiesis and Cognition: The Realization of the Living*. D. Reidel, Dordrecht (1980)
- Olsson, C., Elhage, N., Nanda, N., Joseph, N., DasSarma, N., Henighan, T., Mann, B., Askell, A., Bai, Y., Chen, A., et al.: In-context learning and induction heads. *Transformer Circuits Thread*, Anthropic. <https://transformer-circuits.pub/2022/in-context-learning-and-induction-heads/> (2022)
- Pavliotis, G.A.: *Stochastic Processes and Applications: Diffusion Processes, the Fokker–Planck and Langevin Equations*. Texts in Applied Mathematics, vol. 60. Springer, New York (2014). <https://doi.org/10.1007/978-1-4939-1323-7>
- Power, A., Burda, Y., Edwards, H., Babuschkin, I., Misra, V.: *Grokking: Generalization beyond overfitting on small algorithmic datasets* (2022)
- Pearl, J.: *Causality: Models, Reasoning, and Inference*, 2nd edn. Cambridge University Press, Cambridge (2009)
- Parrondo, J.M.R., Horowitz, J.M., Sagawa, T.: Thermodynamics of information. *Nat. Phys.* **11**(2), 131–139 (2015) <https://doi.org/10.1038/nphys3230>
- Parisi, G.I., Kemker, R., Part, J.L., Kanan, C., Wermter, S.: Continual lifelong learning with neural networks: A review. *Neural Netw.* **113**, 54–71 (2019) <https://doi.org/10.1016/j.neunet.2019.01.012>

- Parr, T., Pezzulo, G., Friston, K.J.: Active Inference: The Free Energy Principle in Mind, Brain, and Behavior. MIT Press, ??? (2022). <https://doi.org/10.7551/mitpress/12441.001.0001>
- Pradeu, T.: The Limits of the Self: Immunology and Biological Identity. Oxford University Press, New York (2012)
- Pezzulo, G., Rigoli, F., Friston, K.J.: Hierarchical active inference: A theory of motivated control. *Trends Cogn. Sci.* **22**(4), 294–306 (2018) <https://doi.org/10.1016/j.tics.2018.01.009>
- Riemer, M., Cases, I., Ajemian, R., Liu, M., Rish, I., Tu, Y., Tesauero, G.: Learning to learn without forgetting by maximizing transfer and minimizing interference. In: International Conference on Learning Representations (ICLR) (2019)
- Reik, W.: Stability and flexibility of epigenetic gene regulation in mammalian development. *Nature* **447**(7143), 425–432 (2007) <https://doi.org/10.1038/nature05918>
- Rissanen, J.: Stochastic complexity and modeling. *Ann. Statist.* **14**(3), 1080–1100 (1986) <https://doi.org/10.1214/aos/1176350051>
- Rosen, R.: Life Itself: A Comprehensive Inquiry Into the Nature, Origin, and Fabrication of Life. Columbia University Press, New York (1991)
- Sagawa, T.: Thermodynamic and logical reversibilities revisited. *Journal of Statistical Mechanics: Theory and Experiment* **2014**(3), 03025 (2014) <https://doi.org/10.1088/1742-5468/2014/03/P03025>
- Sourjik, V., Berg, H.C.: Receptor sensitivity in bacterial chemotaxis. *Proc. Natl. Acad. Sci. USA* **99**(1), 123–127 (2002) <https://doi.org/10.1073/pnas.011589998>
- Schwarz, G.: Estimating the dimension of a model. *Annals of Statistics* **6**(2), 461–464 (1978) <https://doi.org/10.1214/aos/1176344136>
- Schmidhuber, J.: A possibility for implementing curiosity and boredom in model-building neural controllers. In: Proceedings of the International Conference on Simulation of Adaptive Behavior: From Animals to Animats, pp. 222–227 (1991)
- Schreiber, T.: Measuring information transfer. *Phys. Rev. Lett.* **85**(2), 461–464 (2000) <https://doi.org/10.1103/PhysRevLett.85.461>
- Sharma, A., Czégel, D., Lachmann, M., Kempes, C.P., Walker, S.I., Cronin, L.: Assembly theory explains and quantifies selection and evolution. *Nature* **622**(7982), 321–328 (2023) <https://doi.org/10.1038/s41586-023-06600-9>
- Schlimmer, J.C., Granger, R.H.: Incremental learning from noisy data. In: Machine Learning vol. 1, pp. 317–354 (1986). <https://doi.org/10.1007/BF00116895>

- Still, S., Sivak, D.A., Bell, A.J., Crooks, G.E.: Thermodynamics of prediction. Phys. Rev. Lett. **109**(12), 120604 (2012) <https://doi.org/10.1103/PhysRevLett.109.120604>
- Sagawa, T., Ueda, M.: Minimal energy cost for thermodynamic information processing: measurement and information erasure. Phys. Rev. Lett. **102**(25), 250602 (2009) <https://doi.org/10.1103/PhysRevLett.102.250602>
- Sagawa, T., Ueda, M.: Generalized Jarzynski equality under nonequilibrium feedback control. Phys. Rev. Lett. **104**(9), 090602 (2010) <https://doi.org/10.1103/PhysRevLett.104.090602>
- Takahashi, K., Hayashi, Y.: Thermodynamic Limits of Physical Intelligence. arXiv:2602.05463 (2026). <https://doi.org/10.48550/arXiv.2602.05463>
- Treves, A., Panzeri, S.: The upward bias in measures of information derived from limited data samples. Neural Comput. **7**(2), 399–407 (1995) <https://doi.org/10.1162/neco.1995.7.2.399>
- Tishby, N., Pereira, F.C., Bialek, W.: The information bottleneck method (1999)
- Tsybal, A.: The problem of concept drift: definitions and related work. Technical Report TCD-CS-2004-15, Department of Computer Science, Trinity College Dublin (2004)
- Williams, D.: Predictive coding and thought. Synthese **197**(4), 1749–1775 (2020) <https://doi.org/10.1007/s11229-018-1768-x>
- Wolpert, D.H.: The lack of a priori distinctions between learning algorithms. Neural Comput. **8**(7), 1341–1390 (1996) <https://doi.org/10.1162/neco.1996.8.7.1341>
- Wolpert, D.H.: The stochastic thermodynamics of computation. J. Phys. A: Math. Theor. **52**(19), 193001 (2019) <https://doi.org/10.1088/1751-8121/ab0850>
- Yi, T.-M., Huang, Y., Simon, M.I., Doyle, J.: Robust perfect adaptation in bacterial chemotaxis through integral feedback control. Proc. Natl. Acad. Sci. USA **97**(9), 4649–4653 (2000) <https://doi.org/10.1073/pnas.97.9.4649>