

Supplementary Material: Нестационарная ландауэровская эффективность

Александр Андришин^{1*}

^{1*}Independent Researcher, Москва, Россия.

Corresponding author(s). E-mail(s): alexander@andriishin.com;

1 S1. Полное доказательство Замечания 6 (softmax-regularity для OU)

Замечание 6 (§ 4.4) утверждает: в OU-классе § 5.2 экспоненциальная декорреляция автоковариации логитов $\theta(t)$ переносится через softmax на любой ограниченный измеримый функционал $\xi(\theta)$ (в частности, на элементы матрицы переходов $P_{ij}(\theta)$ и на любую достаточную статистику предсказания). Доказательство — пять шагов: (i) Lipschitz softmax в ℓ_∞ ; (ii) перенос на TV матрицы переходов; (iii) ограниченность OU-траектории на шаре $R(\delta)$ с вероятностью $1-\delta$; (iv) перенос затухания на ковариацию ξ ; (v) перевод TV-границы в границу для условной МЛ.

1.1 S1.1 Шаг 1. Lipschitz-непрерывность softmax

Пусть $\text{softmax} : \mathbb{R}^k \rightarrow \Delta^{k-1}$ — стандартное отображение $\text{softmax}_i(\theta) = \exp \theta_i / \sum_j \exp \theta_j$. Якобиан имеет вид $\partial \text{softmax}_i / \partial \theta_j = \text{softmax}_i(\delta_{ij} - \text{softmax}_j)$; диагональные элементы $p_i(1-p_i) \geq 0$, недиагональные $-p_i p_j \leq 0$, при этом сумма модулей по столбцу не превышает $2p_j$. Стандартное следствие — оценка в ℓ_1/ℓ_∞ парности:

$$\|\text{softmax}(\theta) - \text{softmax}(\theta')\|_1 \leq 2 \|\theta - \theta'\|_\infty. \quad (\text{S1.1})$$

Вывод (S1.1) — интегрирование Якобиана по прямой $\theta(s) = \theta + s(\theta' - \theta)$, $s \in [0, 1]$, с применением неравенства Гёльдера к каждому компоненту градиента; константа 2 оптимальна. Стандартный результат, без дополнительных предположений о размерности k .

1.2 S1.2 Шаг 2. Перенос на total variation матрицы переходов

В ОУ-параметризации § 5.2 строки матрицы переходов задаются построчным softmax над логитами: $P_{ij}(\theta) = \exp \theta_{ij} / \sum_l \exp \theta_{il}$, причём по соглашению $\theta_{ii} \equiv 0$. Для каждой строки i применяя (S1.1) к векторам $(\theta_{ij})_{j=1}^k$ и $(\theta'_{ij})_{j=1}^k$:

$$\|P_{i,\cdot}(\theta) - P_{i,\cdot}(\theta')\|_1 \leq 2 \max_j |\theta_{ij} - \theta'_{ij}|.$$

В терминах TV-расстояния между распределениями $P_{i,\cdot}(\theta)$ и $P_{i,\cdot}(\theta')$ (половина ℓ_1 -расстояния, $\|\mu - \nu\|_{TV} = \frac{1}{2} \|\mu - \nu\|_1$) получается

$$\|P_{i,\cdot}(\theta) - P_{i,\cdot}(\theta')\|_{TV} \leq \max_j |\theta_{ij} - \theta'_{ij}| \leq \|\theta - \theta'\|_\infty. \quad (\text{S1.2})$$

Это даёт row-wise Lipschitz-константу $L = 1$ для softmax-параметризации матрицы переходов. Координатное ограничение (вместо полной $\|\theta - \theta'\|_\infty$ по всем строкам) существенно для шага S1.4: $K = k(k-1)$ компонент логитов ОУ-системы независимы (диагональный анкер $\theta_{ii} \equiv 0$), и каждая строка матрицы зависит лишь от своей подсистемы из $k-1$ компонент.

1.3 S1.3 Шаг 3. Ограниченность траектории ОУ с высокой вероятностью

ОУ-процесс на каждой координате θ_{ij} в стационарном режиме гауссов, $\mathcal{N}(0, \sigma^2/(2\lambda))$; автоковариация $\mathbb{E}[\theta_{ij}(t)\theta_{ij}(s)] = (\sigma^2/(2\lambda)) e^{-|t-s|/\tau_E}$ с $\tau_E = 1/\lambda$. По неравенству концентрации липшицевых функционалов гауссовой меры (Борелла—Чирельсона, стандартный результат теории гауссовых процессов) для одной координаты $\Pr[\sup_{[0,T]} |\theta_{ij}(t)| > R] \leq 2 \exp(-R^2 \lambda / \sigma^2)$; union bound по K координатам даёт радиус

$$R(\delta) = \sigma \sqrt{\ln(2K/\delta)/\lambda}, \quad (\text{S1.3})$$

обеспечивающий $\Pr[\sup_{[0,T], ij} |\theta_{ij}(t)| > R(\delta)] \leq \delta$. На событии $\{\|\theta(t)\|_\infty \leq R(\delta)\}$ применима локальная Lipschitz-константа softmax (S1.2), а через произведение мер — для пары моментов (s, t) одновременно.

1.4 S1.4 Шаг 4. Перенос экспоненциального затухания на ξ

Пусть $\xi : \mathbb{R}^K \rightarrow \mathbb{R}$ — ограниченная измеримая функция, $|\xi| \leq B$, Lipschitz по координате с константой L_ξ в ℓ_∞ -метрике: $|\xi(\theta) - \xi(\theta')| \leq L_\xi \|\theta - \theta'\|_\infty$ (для row-wise softmax-проекции $L_\xi \leq 1$ по (S1.2)). Ковариация ξ в стационарном режиме ОУ оценивается через её представление как разность произведений:

$$\text{Cov}(\xi(\theta(t)), \xi(\theta(s))) = \mathbb{E}[(\xi(\theta(t)) - \bar{\xi})(\xi(\theta(s)) - \bar{\xi})],$$

где $\bar{\xi} = \mathbb{E}[\xi(\theta)]$ под стационарной мерой. На событии шага S1.3 (вероятности $\geq 1 - \delta$) выполняется $|\xi(\theta(t)) - \bar{\xi}| \leq L_\xi \cdot 2R(\delta)$ при сравнении с детерминированным значением в $\theta = 0$ (точка симметрии стационарной меры) плюс

ограниченный вклад от смещения $\bar{\xi}$, поглощённый в $|\xi| \leq B$. Применение неравенства Коши—Шварца и стандартной оценки автоковариации ОУ $\mathbb{E}[\theta_{ij}(t)\theta_{ij}(s)] = (\sigma^2/(2\lambda))e^{-|t-s|/\tau_E}$ даёт

$$|\text{Cov}(\xi(\theta(t)), \xi(\theta(s)))| \leq 2B \cdot L_\xi \cdot \frac{\sigma^2}{2\lambda} \cdot e^{-|t-s|/\tau_E} + 2B^2\delta, \quad (\text{S1.4})$$

где второе слагаемое — поправка от события малой вероятности шага S1.3, в котором траектория выходит за шар радиуса $R(\delta)$. Выбор $\delta = e^{-|t-s|/\tau_E}$ для разнеса событий по характерному времени декорреляции делает поправку δ -членом того же порядка, что и ведущий экспоненциальный член. Окончательно: для любого ограниченного измеримого ξ с Lipschitz-константой L_ξ по координате логитов

$$|\text{Cov}(\xi(\theta(t)), \xi(\theta(s)))| \leq C_1(B, L_\xi, \sigma, \lambda) \cdot e^{-|t-s|/\tau_E}, \quad (\text{S1.4}')$$

с явной константой $C_1 = (BL_\xi\sigma^2/\lambda) + 2B^2$ (или меньшей при оптимизации выбора δ). Экспоненциальное затухание автоковариации θ переносится на ξ с тем же характерным временем τ_E — это и есть содержательное утверждение Замечания 6.

1.5 S1.5 Шаг 5. Перенос на условную взаимную информацию

Цепочка «ковариация $\xi \rightarrow \text{MI}$ » через inverse Pinsker (Sason—Verdú-типа) требует ограниченности log-density ratio $\alpha = \log \|dP/dQ\|_\infty$, что для softmax-параметризации универсально не выполнено: даже на шаре $R(\delta)$ шага S1.3 даёт $\alpha \leq 2R(\delta) + \log k$, а не просто $\log k$. Поэтому шаг S1.5 строится через *MI-tensorisation* по независимым координатам ОУ с последующим DPI на ξ — формально корректную замену. Прямая χ^2 -tensorisation здесь неприменима: χ^2 мультипликативна по независимости координат ($1 + \chi_{\text{joint}}^2 = \prod_{ij}(1 + \chi_{\text{coord}}^2)$), а не аддитивна, поэтому наивное неравенство « $\chi_{\text{joint}}^2 \leq K\chi_{\text{coord}}^2$ » неверно для χ^2 и обходится через MI-tensorisation, которая аддитивна именно потому, что MI аддитивна по независимым координатам.

Шаг 5a. $KL \leq \chi^2$ как вспомогательная оценка на координате. Стандартное неравенство (Cover and Thomas 2006, упр. 2.45): для любых P_{XY}, P_X, P_Y

$$I(X; Y) = D_{KL}(P_{XY} \| P_X \otimes P_Y) \leq \chi^2(P_{XY} \| P_X \otimes P_Y).$$

Это неравенство не требует ограниченности density ratio; оно держится в любой σ -алгебре. В шагах ниже оно применяется *только по координатно* для обоснования асимптотики $I_{\text{coord}} = \frac{1}{2}\rho^2(1 + o(1))$, не для тензоризации.

Шаг 5b. MI для бивариантной гауссовой пары на координате. Для одной координаты θ_{ij} в стационарном ОУ пара $(\theta_{ij}(t), \theta_{ij}(s))$ — гауссова с нормированной корреляцией $\rho(t, s) = e^{-|t-s|/\tau_E}$. Стандартная формула для MI бивариантного гауссова распределения с маргинальной дисперсией $\sigma_0^2 = \sigma^2/(2\lambda)$:

$$I(\theta_{ij}(t); \theta_{ij}(s)) = -\frac{1}{2} \ln(1 - \rho^2(t, s)). \quad (\text{S1.5a})$$

При $|t - s| \geq \tau_E$ имеем $\rho^2 \leq e^{-2} < 0,14$, и разложение Тейлора даёт $I_{\text{coord}} = \frac{1}{2}\rho^2 + O(\rho^4) \leq \frac{1}{2}\rho^2(1 + o(1)) \leq \frac{1}{2}e^{-2|t-s|/\tau_E}$. Альтернативное выражение через χ^2 ($\chi_{\text{coord}}^2 = \rho^2/(1 - \rho^2)$ — прямое вычисление) даёт тот же лидирующий член $\frac{1}{2}\rho^2$ через шаг 5а с показателем экспоненты $2/\tau_E$ (не $1/\tau_E$); МІ и χ^2 на координате согласуются по асимптотике.

Шаг 5с. МІ-тензоризация по K независимым координатам. МІ аддитивна по статистически независимым парам (Cover and Thomas 2006, гл. 2.5): координаты ОУ независимы по построению (шаг S2.1: W_{ij} независимы; ковариация диагональна), и поэтому

$$I(\theta(t); \theta(s)) = \sum_{ij} I(\theta_{ij}(t); \theta_{ij}(s)) \leq \frac{K}{2} \cdot e^{-2|t-s|/\tau_E} \cdot (1 + o(1)). \quad (\text{S1.5b})$$

Аддитивность МІ по независимым координатам *корректна* и обходит χ^2 -tensorisation-ловушку (мультипликативность $\prod_{ij}(1 + \chi_{\text{coord}}^2)$ против ожидаемой суммы $\sum_{ij} \chi_{\text{coord}}^2$): МІ аддитивна, χ^2 — нет, и потому переход к итоговой константе $K/2$ делается через МІ, а не через χ^2 .

Шаг 5d. DPI на ξ и итоговая граница МІ. МІ монотонна под измеримыми отображениями (Cover and Thomas 2006, гл. 2.8): огрубление вектора $\theta(\cdot)$ через ограниченный измеримый ξ не увеличивает МІ пары $(\xi(\theta(t)), \xi(\theta(s)))$ сверх МІ исходной пары $(\theta(t), \theta(s))$. Объединяя шаги 5b–5с: для $|t - s| \geq \tau_E$

$$I(\xi(\theta(t)); \xi(\theta(s))) \leq I(\theta(t); \theta(s)) \leq C_2 \cdot e^{-2|t-s|/\tau_E}, \quad (\text{S1.5})$$

с явной константой $C_2 = K/2 \cdot (1 + o(1))$. Lipschitz-структура ξ (шаг S1.4) и ограниченность $|\xi| \leq B$ при этом не используются для МІ-границы — они нужны лишь для константы в координатном масштабе ковариационной формы (S1.4'). Условие по $M_{\leq t}^{\text{refr}}$ применяется через chain-rule на МІ: обусловливание на $M_{\leq t}^{\text{refr}}$ — функцию от $\theta(\cdot)$ на $[s_0, t]$ — не увеличивает МІ пары $(\xi(\theta(t)), \xi(\theta(s)))$ сверх (S1.5); поправка стандартного концентрационного шага S1.3 (выход траектории за шар радиуса $R(\delta)$) входит в добавочное слагаемое $\delta \cdot \ln k$ итогового утверждения (S1.6).

Альтернативная цепочка. То же затухание получается через Mehler-полугрупповое представление ОУ и спектральную цель эргодической диффузии: для стационарной ОУ-меры и ограниченных измеримых ξ корреляции и МІ убывают по стандартному результату о спектральной щели гауссовых полугрупп (Bakry—Émery функциональное неравенство; см. (Pavliotis 2014, гл. 4) о спектральном разложении ОУ и экспоненциальной эргодичности; альтернативно — обзор в (Levin et al. 2017, гл. 13) для дискретного аналога mixing-times). Эта формулировка короче, но требует ссылочного аппарата за пределами § 5.2; цепочка через МІ-tensorisation (шаги 5b–5с) — формально самодостаточна в рамках данной работы.

1.6 S1.6 Итоговое утверждение

Лемма S1 (supplementary, softmax-regularity ОУ). В классе § 5.2 (ОУ-параметризация логитов $\theta(t) \in \mathbb{R}^K$ с характерным временем $\tau_E = 1/\lambda$ и

стационарной дисперсией $\sigma^2/(2\lambda)$) для любого ограниченного измеримого функционала $\xi : \mathbb{R}^K \rightarrow \mathbb{R}$ с $|\xi| \leq B$ и Lipschitz-константой L_ξ по координате логитов в ℓ_∞ -метрике, и для любого $\delta \in (0, 1)$ существует константа $C = C(\delta, B, L_\xi, \sigma, \lambda, k)$ такая, что для всех s, t с $|t - s| \geq \tau_E$ выполняется

$$I(\xi(\theta(t)); \xi(\theta(s)) \mid M_{\leq t}^{\text{refr}}) \leq C \cdot e^{-2|t-s|/\tau_E} + \delta \cdot \ln k. \quad (\text{S1.6})$$

В частности, для проекций $P_{ij}(\theta(\cdot))$ row-wise softmax-параметризации матрицы переходов выполнено $L_\xi \leq 1$ и $B \leq 1$, что даёт явную константу C , не зависящую от k при фиксированном σ^2/λ .

Лемма S1 формально замыкает шаг доказательства Леммы 2 (§ 4.4), требующий обнуления $I(M^{\text{stale}}; X_E \mid M^{\text{refr}})$ при $\Delta t \gg \tau_E$: правая часть (S1.6) суммируется по разностям возрастов в FIFO-распределении и даёт суммарный вклад stale-фракции порядка $O(c)$, что и используется в основном доказательстве Леммы 2 при подстановке в (8a) через (7). Условие $|t - s| \geq \tau_E$ — характерный масштаб, на котором экспонента не вырождена; для $|t - s| < \tau_E$ МП ограничена $H(\xi) \leq \ln k$ тривиально, что укладывается в добавочное константное слагаемое.

2 S2. Полное доказательство Замечания 5 (per-bit-uniformity для OU)

Замечание 5 (§ 4.4) утверждает аддитивность МП по независимо обновляемым координатам логитов OU-параметризации § 5.2 с константой $1 + o(1)$ — допущение Леммы 2, обеспечивающее переход от арифметической доли обновлённых битов c к информационно-теоретической границе $\nu \geq 1 - c$ в slow-driving пределе. Доказательство: (i) OU как K независимых процессов; (ii) гауссов апостериор по каждой координате; (iii) точная аддитивность МП по координатам; (iv) FIFO в K -координатной декомпозиции; (v) сравнение с оптимальным наблюдателем; (vi) итоговая граница с $\kappa = 1 + o(1)$; (vii) пределы при нарушении независимости.

2.1 S2.1 OU как K независимых процессов на координатах

В § 5.2 / § 6.2 OU-параметризация задаёт логиты $\theta_{ij}(t)$ ($i \neq j$, $K = k(k-1)$ свободных параметров) как независимые одномерные процессы:

$$d\theta_{ij} = -\lambda(\theta_{ij} - \theta_{ij}^*) dt + \sigma dW_{ij}, \quad (\text{S2.1})$$

где W_{ij} — независимые винеровские процессы, $\theta_{ij}^* = 0$ по конвенции § 6.2. Диагональные логиты $\theta_{ii} \equiv 0$ фиксированы как анкер softmax-нормировки. Совместное распределение $\theta(t) = (\theta_{ij}(t))_{ij}$ в стационарном режиме — гауссово с диагональной ковариацией $\Sigma = (\sigma^2/(2\lambda))I_K$: координаты статистически независимы.

2.2 S2.2 Гауссов апостериор по каждой координате

При наблюдении $X_E^{[0,t]}$ под истинным $P(t) = \text{softmax}(\theta(t))$ апостериор обучателя по $\theta(t)$ при регулярной параметрической оценке (MLE или Robbins—Монго приближение к байесовскому обновлению § 6.2) асимптотически нормален с ковариацией $\Sigma_{\text{post}}(t)$, элементы которой убывают как $O(1/t)$ — стандартный результат об асимптотической нормальности оценок максимального правдоподобия для регулярных семейств (Clarke and Barron 1990, § 3).

Блочная структура Фишера. Информационная матрица $\mathcal{F}(\theta)$ для ОУ с независимыми координатами и построчным softmax — блочно-диагональна *по строкам* i : разные строки дают независимый вклад в правдоподобие через независимые выборки $\{X_t \rightarrow X_{t+1}\}$ при $X_t = i$. Аддитивность по строкам — точная, не приближённая.

Within-row coupling. Внутри строки i Fisher-блок имеет вид $\mathcal{F}^{(i)}(\theta) = n_i(t) \cdot (\text{diag}(p_i) - p_i p_i^T)$, где $p_i = (P_{ij})_{j=1}^k$ — i -я строка softmax и $n_i(t)$ — число посещений состояния i к моменту t . Эта матрица softmax-Fisher **не диагональна**: softmax-нормировка связывает все j через общий знаменатель. Точная аддитивность диагонального приближения $\Sigma_{\text{post}} \approx \text{diag}(\sigma_{ij}^2)$ поэтому требует обоснования.

Спектральный анализ через формулу Шура. Матрица $\text{diag}(p) - pp^T$ — стандартный центрирующий проектор: имеет собственное значение 0 в направлении $\mathbf{1}$ (что соответствует constraint $\sum_j p_{ij} = 1$, операционально — закреплению $\theta_{ii} \equiv 0$ как softmax-анкера, см. S2.1) и собственные значения $\{p_{ij}\}_{j \neq i}$ на ортогональном подпространстве свободных параметров. Число обусловленности Fisher-блока в свободных координатах:

$$\kappa(\mathcal{F}_{\text{free}}^{(i)}) = \frac{\max_{j \neq i} p_{ij}}{\min_{j \neq i} p_{ij}}. \quad (\text{S2.2a})$$

На событии шага S1.3 (траектория ОУ в шаре $R(\delta)$ с вероятностью $\geq 1 - \delta$) для softmax выполняется $\max_j p_{ij} / \min_j p_{ij} \leq e^{2R(\delta)}$, откуда $\kappa(\mathcal{F}_{\text{free}}^{(i)}) \leq e^{2R(\delta)}$ — ограничено и зависит лишь от радиуса ОУ-шара через $R(\delta) = \sigma \sqrt{\ln(2K/\delta)/\lambda}$ (S1.3).

Поправка к диагональному приближению. Гауссово приближение апостериора даёт $\Sigma_{\text{post}}^{(i)} = (\mathcal{F}_{\text{free}}^{(i)})^{-1}$ с тем же спектром обратных собственных значений; недиагональность Σ_{post} внутри строки порождает поправку к точной аддитивности (S2.2). В slow-driving пределе $\lambda \tau_{\text{relax}} \ll 1$ поправка имеет порядок $O(\kappa(\Sigma_{\text{post}}^{(i)}) \cdot \lambda \tau_{\text{relax}})$: число обусловленности входит мультипликативно, поскольку внедиагональный вклад в МП ограничен через след $\Sigma_{\text{post}}^{(i)}$, мажорируемый κ -кратной диагональной частью. На ОУ-шаре S1.3 это даёт

$$\Sigma_{\text{post}} = \text{diag}(\sigma_{ij}^2(t)) \cdot (1 + O(e^{2R(\delta)} \cdot \lambda \tau_{\text{relax}})), \quad (\text{S2.2b})$$

что остаётся $1 + o(1)$ при усиленном slow-driving условии $e^{2R(\delta)} \cdot \lambda \tau_{\text{relax}} \ll 1$. В численных режимах § 6.2 ($\sigma = 0,1$, $\lambda = 10^{-3}$, $K = 56$, $\delta = 0,05$) получается $R(\delta) \approx 0,1 \cdot \sqrt{\ln(2240)/10^{-3}} \approx 8,8$ — слишком велико для буквального $e^{2R(\delta)} \cdot \lambda \tau_{\text{relax}} \ll 1$; однако (S2.2b) — *равномерная* верхняя оценка на $R(\delta)$ -шаре, тогда как типичная softmax-нормировка концентрирована вблизи равновесия и

$\kappa(\mathcal{F}_{\text{free}}^{(i)})$ эмпирически близок к 1 (численный контроль § 6.2 показывает $1+o(1)$ в среднем по реализациям). Аналитическое улучшение оценки (S2.2b) — через концентрацию softmax вокруг типичного логита, а не равномерную границу — оставлено как уточнение в § 8.5.

2.3 S2.3 Аддитивность МІ по независимым координатам

Для гауссова апостериора $\hat{\theta} = (\hat{\theta}_{ij})$ с диагональной ковариацией $\Sigma_{\text{post}} = \text{diag}(\sigma_{ij}^2)$ выполняется *точная* аддитивность МІ с истинным латентом:

$$I(\hat{\theta}; \theta) = \sum_{ij} I(\hat{\theta}_{ij}; \theta_{ij}). \quad (\text{S2.2})$$

Вывод: по chain rule (Cover and Thomas 2006, гл. 2.5)

$$I(\hat{\theta}; \theta) = \sum_{ij} I(\hat{\theta}_{ij}; \theta_{ij} \mid \hat{\theta}_{<ij}, \theta_{<ij});$$

независимость координат OU даёт $\theta_{ij} \perp (\theta_{<ij})$ (статистическая независимость по построению), а диагональность $\Sigma_{\text{post}} - \hat{\theta}_{ij} \perp \hat{\theta}_{<ij}$ (условная независимость апостериорных оценок при заданном истинном латенте). Условные МІ редуцируются к безусловным $I(\hat{\theta}_{ij}; \theta_{ij})$, что и даёт (S2.2).

Поправка к точной аддитивности при $\lambda\tau_{\text{relax}} = O(\epsilon)$ — слагаемое $O(\epsilon)$, поглощаемое в $1+o(1)$ при $\epsilon \rightarrow 0$.

2.4 S2.4 Refresh-фракция FIFO в K -координатной декомпозиции

В FIFO-схеме обновления памяти Леммы 2 refresh-фракция размером c обновляет долю c от K координат за интервал τ_E равномерно (определение FIFO и формулы (*)). По аддитивности (S2.2) МІ обновлённой фракции с истинным латентом среды декомпозируется:

$$I(M_{\leq t}^{\text{refr}}; X_E^{[t, t+\tau]}) = \sum_{ij \in \text{refr}} I(\hat{\theta}_{ij}^{\text{refr}}; \theta_{ij}(t+\tau)) = c \cdot K \cdot \bar{I}_{\text{coord}}(t+\tau), \quad (\text{S2.3})$$

где $\bar{I}_{\text{coord}}(t+\tau) := K^{-1} \sum_{ij} I(\hat{\theta}_{ij}; \theta_{ij}(t+\tau))$ — средняя МІ на координату при идеальной (Bayes-оптимальной для регулярного семейства) оценке. Структурно: каждая обновлённая координата вносит независимый вклад, пропорциональный $\bar{I}_{\text{coord}}$; суммарная МІ пропорциональна доле обновлённых координат c при K -кратной аддитивности.

2.5 S2.5 Сравнение с оптимальным наблюдателем

МІ оптимального наблюдателя (полная достаточная статистика по $\theta(t)$) на горизонте τ в slow-driving пределе:

$$I_{\text{pred}}^{\text{opt}}(t, \tau) = I(X_t; X_{t+\tau} | \theta(t)) = \sum_{ij} I_{\text{coord}}(t + \tau) = K \cdot \bar{I}_{\text{coord}}(t + \tau), \quad (\text{S2.4})$$

где разложение по координатам использует условную независимость переходов $X_t \rightarrow X_{t+\tau}$ по разным строкам и независимость координат логитов θ внутри одной строки в slow-driving пределе. Аппроксимация $\theta(t + \tau) \approx \theta(t)$ работает с точностью $O(\sigma^2 \tau / \lambda)$: за горизонт τ при $\lambda \tau \ll 1$ дрейф латента малый, и МП на координату $I_{\text{coord}}(t + \tau) = I_{\text{coord}}(t) \cdot (1 + O(\lambda \tau))$.

2.6 S2.6 Итоговая граница

Подставляя (S2.3) в (S2.4):

$$\frac{I(M_{\leq t}^{\text{refr}}; X_E^{[t, t+\tau]})}{I_{\text{pred}}^{\text{opt}}(t, \tau)} = \frac{c \cdot K \cdot \bar{I}_{\text{coord}}(t + \tau)}{K \cdot \bar{I}_{\text{coord}}(t + \tau)} = c \cdot (1 + O(\lambda \tau)).$$

То есть

$$I(M_{\leq t}^{\text{refr}}; X_E^{[t, t+\tau]}) \leq c \cdot I_{\text{pred}}^{\text{opt}}(t, \tau) \cdot (1 + O(\lambda \tau)). \quad (\text{S2.5})$$

При $\lambda \tau \ll 1$ (slow-driving режим, выполнено по условию класса § 5.2) и при усиленном условии $e^{2R(\delta)} \cdot \lambda \tau_{\text{relax}} \ll 1$ из S2.2 (within-row Fisher coupling) $1 + O(\lambda \tau) + O(e^{2R(\delta)} \lambda \tau_{\text{relax}}) = 1 + o(1)$, и (S2.5) даёт per-bit-uniformity с константой $\kappa = 1 + o(1)$. Без усиленного условия — $\kappa = 1 + O(e^{2R(\delta)} \lambda \tau_{\text{relax}})$, что для конечных δ, σ, λ даёт мультипликативную поправку, но не отменяет качественной структуры (8a) (см. также S2.7 для дополнительных источников non-diagonality). Подстановка в (7) при условии $I(M^{\text{stale}}; X_E | M^{\text{refr}}) \rightarrow 0$ (Лемма S1) даёт асимптотически

$$\nu^{\text{theor}}(t) = 1 - \frac{I(M_{\leq t}^{\text{refr}}; X_E^{[t, t+\tau]})}{I_{\text{pred}}^{\text{opt}}(t, \tau)} \geq 1 - c \cdot (1 + o(1)), \quad (\text{S2.6})$$

что и есть утверждение (8a) Леммы 2 с явной константой $\kappa = 1 + o(1)$.

2.7 S2.7 Обсуждение пределов: скоррелированные координаты

При нарушении независимости координат ОУ (кросс-стрелочный дрейф с non-diagonal Σ в (S2.1)) per-bit-uniformity требует уточнения. Помимо межстрочной корреляции *prior*, второй источник non-diagonality — within-row Fisher coupling через softmax-нормировку (S2.2): число обусловленности Fisher-блока $\kappa(\mathcal{F}_{\text{free}}^{(i)}) = \max_j p_{ij} / \min_j p_{ij}$ контролирует отклонение от точной аддитивности (S2.2a, S2.2b) и входит мультипликативно в финальную поправку (S2.6). Оба источника объединяются в общем condition-number аргументе.

Пусть $\kappa(\Sigma_{\text{post}})$ — условное число (отношение максимального к минимальному собственному значению) совместной ковариации апостериора, объединяющее межстрочные prior-корреляции (S2.1, при non-diagonal Σ_{prior}) и within-row Fisher-корреляции (S2.2). Через гауссово представление МП $I(\hat{\theta}; \theta) =$

$(1/2) \ln \det(\Sigma_{\text{prior}} \Sigma_{\text{post}}^{-1}) = (1/2) \ln \det(I + \mathcal{F} \Sigma_{\text{prior}})$ (где $\mathcal{F} = \Sigma_{\text{post}}^{-1} - \Sigma_{\text{prior}}^{-1}$ — наблюдаемая Fisher-информация, и $\Sigma_{\text{post}}^{-1} = \Sigma_{\text{prior}}^{-1} + \mathcal{F}$) и неравенство Hadamard $\det(\Sigma) \leq \prod_i \Sigma_{ii}$ получается верхняя граница, которая в худшем случае мажорируется $\kappa(\Sigma_{\text{post}})$ раз большим значением, чем аддитивная сумма. В терминах константы Замечания 5:

$$\kappa \leq \kappa(\Sigma_{\text{post}}) \cdot (1 + o(1)). \quad (\text{S2.7})$$

Для диагональной Σ_{post} (независимые координаты) $\kappa(\Sigma_{\text{post}}) = 1$ и (S2.7) редуцируется к $\kappa = 1 + o(1)$. Для скоррелированных координат граница ослабляется мультипликативно на $\kappa(\Sigma_{\text{post}})$; численная оценка для конкретной кросс-параметризации — предмет отдельного исследования. В OU-параметризации § 5.2 с независимыми W_{ij} и диагональным анкером $\theta_{ii} \equiv 0$ условие $\kappa(\Sigma_{\text{post}}) = 1$ выполнено по построению, и per-bit-uniformity с $\kappa = 1 + o(1)$ применима без ограничений.

3 S3. Расширенная таблица нотации

Глоссарий обозначений работы с указанием размерности и уравнения определения; «б/р» — безразмерная. Сокращения: «MI» — взаимная информация (Cover and Thomas 2006, гл. 2); «TV» — total variation; «KL» — Kullback–Leibler. Контексты определения — § X.Y и формулы (N) основного текста.

3.1 S3.1 Эффективность и информационный поток

Символ	Размерность/тип	Определение	Верхняя теоретическая граница
$\eta_L(t)$	б/р, $\in [0, 1]$	Нестационарная ландауэровская эффективность; (10) § 5.1	1 (необратимый режим, асимптотика $t \gg \tau_d$)
$\eta_L^{(\tau_w)}(t)$	б/р, $\in [0, 1]$	Эффективность со скользящим окном τ_w ; (10a) § 5.2	1 (необратимый режим)
η_L^{stat}	б/р	Стационарный предел η_L ; § 5.3, (Andriishin 2026, § 2.1)	1 (необратимый режим)
$\eta_L^{\text{excess}}(t)$	б/р	Вторичная эффективность через L_{excess} ; (S8.3) § S8	без универсального верхнего предела (вторичная метрика)
$I_{\text{pred}}(t, \tau)$	биты	Одношаговая predictive information при $\dot{P}(t)$; (4) § 3.1	$\ln k$ (одношаговая, $k = \Omega $)
$I_{\text{pred}}^{\text{stat}}(\tau)$	биты	Стационарный предел I_{pred} ; § 2.2	$\ln k$ (одношаговая); $ M_t \log 2$ (capacity)
$I_{\text{pred}}^{\text{opt}}(t, \tau)$	биты	МП идеального наблюдателя с доступом к $\theta(t)$; (7) § 4.1	$\ln k$ (одношаговая, $X_t, X_{t+\tau}$ дискретны)
$I_{\text{pred}}^{\text{Bialek}}(X_E, \tau)$	биты	Классическая predictive information (Bialek et al. 2001); § 2.2 (Andriishin 2026)	C_μ (excess entropy, Crutchfield and Feldman 2003)
$N_{\text{max}}(t)$	биты	Кумулятивный ландауэровский бюджет; (1) § 2.1	$ M_t \log 2$ на активную часть памяти; не ограничен сверху во времени
$N_{\text{max}}^{(\tau_w)}(t)$	биты	Бюджет на скользящем окне τ_w ; (10a) § 5.2	$ M_t \log 2$ на активную часть
$L_{\text{excess}}(t)$	наты	Кумулятивная excess-loss обучателя; (S8.1) § S8	асимптотика $(K/2) \ln(\lambda t)$ — гипотеза (S8.2)

Различение трёх типов теоретических границ. (i) Одношаговая граница $\ln k$ — стандартная capacity дискретного канала с алфавитом Ω (Cover and Thomas 2006); контролирует мгновенную информационную ёмкость через один шаг среды. (ii) Capacity-граница $|M_t| \log 2$ — структурный потолок для интегральной информации, которую конечная память M_t из $|M_t|$ битов может хранить. (iii) Excess entropy C_μ (Crutchfield and Feldman 2003) — суммарная predictive information между прошлым и будущим стационарного процесса, в общем случае бесконечная для нетривиальных классов. Различение: $\ln k$ — для одношаговой $I_{\text{pred}}(t, \tau)$, $|M_t| \log 2$ — для ёмкостных оценок памяти, C_μ — для interval-MI типа $I_{\text{pred}}^{\text{Bialek}}$.

3.2 S3.2 Энергетические потоки

Символ	Размерность/тип	Определение
$E_{\text{actual}}^{\text{curr}}(t)$	Дж	Текущая операционная диссипация; § 2.1
$E_{\text{store}}(t)$	Дж	Кумулятивная стоимость удержания старой памяти; § 2.1
$E_{\text{grow}}(t)$	Дж	Кумулятивная стоимость расширения памяти; § 2.1
$\dot{E}_{\text{store}}(t)$	Вт	Мгновенная мощность удержания; Лемма 1 § 2.3
$\dot{E}_{\text{grow}}(t)$	Вт	Мгновенная мощность расширения; § 2.4
$\dot{E}_{\text{store}}^{\text{nostalg}}(t)$	Вт	Мощность удержания ностальгической фракции; (8) § 4.2
$E_{\text{store}}^{(1)}(t)$	Дж	Минимальная диссипация на удержание одного бита; (2) Лемма 1
$E_{\text{grow}}^{(1)}$	Дж	Минимальная диссипация на создание одного бита ёмкости; (3) § 2.4
η_{ex}	б/р	Эксергетический КПД метаболизма; (Andriishin 2026, § 3.5)

3.3 S3.3 Память и её слои

Символ	Размерность/тип	Определение
M_t	биты (размер); конфигурация	Актуальный (обновляемый) слой памяти; § 3.1
$M_{<t}$	биты; конфигурация	Архивный слой памяти; § 3.1
$M_{\leq t} = (M_t, M_{<t})$	биты; конфигурация	Полная память системы; § 3.1
$M_{\leq t}^{\text{refr}}$	биты	Refresh-фракция (обновлена за интервал τ_E); § 4.4
$M_{\leq t}^{\text{stale}}$	биты	Stale-фракция (не обновлена за τ_E); § 4.4
$ M_{\leq t} $	биты	Размер активной части памяти; § 4.4, (11b) § 5.3
$ M_{\leq t}^{\text{cap}} $	биты	Структурный лимит ёмкости памяти; (12) § 5.3
$\dot{M}_{\text{refresh}}(t)$	биты/с	Темп обновления памяти; § 4.4, (13) § 7
$\dot{M}_{\text{grow}}(t)$	биты/с	Темп роста ёмкости памяти; (13) § 7
$\dot{M}_{\text{refresh}}^{\text{eff}}(t)$	биты/с	Эффективный темп refresh для Robbins—Mongo; § 6.2

3.4 S3.4 Латентные параметры и оценки

Символ	Размерность/тип	Определение
$\theta(t)$	$\mathbb{R}^K$	Истинные логиты матрицы переходов среды; § 5.2
$\hat{\theta}(t)$	$\mathbb{R}^K$	Оценка логитов обучателем; § 6.2
$\theta_{ij}(t)$	$\mathbb{R}$	Координата логита, $i \neq j$; § 5.2
$P(t)$	$k \times k$ стохастическая	Матрица переходов среды; § 5.2
$\hat{P}(t)$	$k \times k$ стохастическая	Оценка матрицы переходов обучателем; § 3.1
X_t	$\in \Omega$	Состояние среды в момент t ; § 3.1
$X_E^{[t, t+\tau]}$	траектория	Реализация среды на окне $[t, t + \tau]$; (1a) (Andriishin 2026)

3.5 S3.5 Параметры моделей и временные шкалы

Символ	Размерность/тип	Определение
k	целое; $ \Omega $	Размер алфавита состояний среды; § 5.2, § 6.1
$K = k(k - 1)$	целое	Размерность логитов ОУ-параметризации; § 5.2
Ω	конечное множество	Алфавит состояний марковской цепи; § 3.1
λ	$1/c$	Темп ОУ-релаксации; обратная характерному времени дрейфа τ_E ; § 5.2
σ	$\sqrt{1/c}$	Амплитуда ОУ-шума; § 5.2
α	б/р	Параметр Dirichlet для PSP; § 6.1
τ	с	Горизонт предсказания одношаговой I_{pred} ; (4) § 3.1
τ_d	с	Характерное время диссипации/отклика системы; § 2.1 (Andriishin 2026)
τ_w	с	Ширина скользящего окна оценщика; § 6.1, § 5.2
$\tau_E = 1/\lambda$	с	Характерное время дрейфа среды; § 5.2
τ_{relax}	с	Время релаксации марковской цепи на срезе; § 5.2, § 6.1
$\tau_{1/2}$	с	Время полураспада точности чтения бита; Лемма 1 § 2.3
τ_{reset}^*	с	Оптимальный интервал сброса памяти; (12) § 5.3
T	К	Температура термостата-приёмника; § 2.1 (Andriishin 2026)
ε	б/р, $\in (0, 1/2)$	Порог точности чтения бита; Лемма 1 § 2.3
γ	$1/c$	Симметричная переходная скорость в Лемме 1; § 2.3
η_t	б/р	Шаг Robbins—Монго обучателя; § 6.2

3.6 S3.6 Ностальгия и режимный порог

Символ	Размерность/тип	Определение
$\nu(t)$	б/р, $\in [0, 1]$	Ностальгия (общий символ, контекст определяет вариант); § 4.1
$\nu^{\text{theor}}(t)$	б/р, $\in [0, 1]$	Теоретическая ностальгия через $I_{\text{pred}}^{\text{opt}}$; (7) § 4.1
$\nu^{\text{op}}(t)$	б/р, $\in [0, 1]$	Операциональная ностальгия через C_{μ}^{emp} ; (7') § 4.1
ν_c	б/р, $\in (0, 1)$	Критическое значение / порог режимного перехода; (11b) § 5.3
ν_c^{theor}	б/р, $\in (0, 1)$	Теоретическая критическая ностальгия; (11b) § 5.3
ν_c^{op}	б/р, $\in (0, 1)$	Операциональная критическая ностальгия; § 8.6 П.1
ν_c^{emp}	б/р, $\in (0, 1)$	Эмпирический прокси из § 6.1 (PSP-симуляция); § 6.1
c	б/р	Вычисляемая константа $\dot{M}_{\text{refresh}}\tau_E/ M_{\leq t} $; (*) § 4.4
η_M	б/р	Memory-balance ratio $\dot{M}_{\text{refresh}}\tau_{1/2}/ M_{\leq t} $; (11b) § 5.3
κ	б/р, ≥ 1	Per-bit-uniformity константа
$\rho(t)$	б/р	Замечания 5; § 4.4, § S2.6
		Метрика информационного омоложения; (13) § 7

3.7 S3.7 Информационная сложность и диагностические прокси

Символ	Размерность/тип	Определение
$C_v^{\text{static}}(t)$	биты	Структурная сложность (Lempel—Ziv, assembly); § 4.3
$C_v^{\text{predictive}}(t)$	биты	Динамическая предсказательная сила; (9) § 4.3
C_{μ}	биты	Statistical complexity Crutchfield—Feldman (Crutchfield and Feldman 2003)
$C_{\mu}^{\text{emp}}(t, \tau)$	биты	Эмпирическая excess-entropy на скользящем окне; (7') § 4.1
h_{μ}	биты/символ	Энтропийная скорость; § 4.3

3.8 S3.8 Active inference (§ 7)

Символ	Размерность/тип	Определение
$G[\pi]$	наты	Expected free energy политики π ; § 7 / S7
$G^{\text{epist}}[\pi]$	наты	Эпистемическая компонента EFE (выигрыш в информации); § 7 / S7
$G^{\text{prag}}[\pi]$	наты	Прагматическая компонента EFE (предпочтение); § 7 / S7
$q(s, o, \pi)$	плотность	Generative model в active inference (Friston et al. 2017a; Parr et al. 2022); § 7 / S7
$p(o', s' C)$	плотность	Распределение предпочтений с целевым параметром C ; § 7 / S7
$\beta = 1/(k_B T)$	1/Дж	Обратная температура для перевода нат в Дж; (S7.1) § 7 / S7

3.9 S3.9 Фундаментальные постоянные

Символ	Размерность	Значение / определение
k_B	Дж/К	Постоянная Больцмана
$k_B T \ln 2$	Дж	Минимальная плата за одно стирание (Landauer 1961)
$\ln 2$	б/р	Множитель перевода нат $\rightarrow$ биты

4 S4. Параметры симуляций для воспроизводимости

Раздел собирает технические параметры численных иллюстраций § 6.1 (PSP), § 6.2 (OU) и § S8.3 (адиабатический скан). Реализация — `andriishin/landauer-nostalgia-ou`, директории `simulations/markov_drift{,_ou,_ou_iinf_adiab}/`. Зерно `SEED = 20260524` с `per-run-offsets`; запуск `python main.py` в каждой директории восстанавливает приведённые численные значения с точностью до версии используемых библиотек.

4.1 S4.1 PSP-симуляция (§ 6.1)

Класс модели. Кусочно-стационарный марковский процесс с пуассоновскими сменами матрицы переходов. Алфавит $\Omega = \{1, \dots, k\}$, $k = 8$. На интервале $[T_i, T_{i+1})$ матрица переходов $P^{(i)}$ постоянна; моменты смены $\{T_i\}$ — пуассоновский поток

с интенсивностью λ . В момент T_i матрица обновляется до случайной стохастической $P^{(i)}$ с независимыми строками, каждая строка — Dirichlet с параметром $\alpha = 0,3$.

Базовые параметры. $k = 8$, $\alpha = 0,3$, $\lambda = 10^{-3}$ (для режимов с дрейфом), горизонт предсказания $\tau = 1$ шаг.

Темп релаксации. $\langle \tau_{\text{relax}} \rangle \approx 2-3$ шагов при $\alpha = 0,3$; $\lambda \tau_{\text{relax}} \approx 3 \cdot 10^{-3} \ll 1$ — slow-driving выполнено с запасом.

Три режима (§ 5.3):

Режим	λ	τ_w	T	Реализаций
Стационар	0	100	10^4	80
Дрейф без сброса	10^{-3}	∞	10^5	60
Дрейф со сбросом	10^{-3}	{100, 500, 2000}	10^5	60

Сетка τ_w для Рис. 2. Восемь точек $\tau_w \in \{50, 100, 200, 500, 10^3, 2 \cdot 10^3, 5 \cdot 10^3, 10^4\}$, $\lambda = 10^{-3}$, $T = 5 \cdot 10^4$, 40 реализаций на точку.

Оценщик MI. KL-detuned proxy $\hat{I}_{\text{pred}}(t, \tau) = I_{\text{opt}}(P(t), \tau) - \mathbb{E}_{X_t \sim \pi(t)}[D_{KL}(P(t)^\tau(\cdot | X_t) \| \hat{P}(t)^\tau(\cdot | X_t))]$ с отсечением снизу нулём; сопоставление с независимыми оценками: дискретный plug-in с коррекцией Treves–Panzeri (Treves and Panzeri 1995) и непрерывный KSG-оценщик с k -NN, $k_{NN} = 3$ (Kraskov et al. 2004); согласованность на сетке проверена.

Бюджет N_{max} . В симуляции принята нормировка $k_B T \ln 2 = 1$ и $N_{\text{max}}(t) = N_0 + R \cdot t$ с $R = 1$ единица в шаг (базовая операционная плата плюс плата по Лемме 1 на $|M_t| = k^2 = 64$ удерживаемых параметрах).

Объём вычислений. Сложность на реализацию $O(T \cdot k^2 \cdot \tau_w)$; базовая стационарная параметризация ($T = 10^4$, $\tau_w = 100$, $k = 8$) — $\sim 6 \cdot 10^7$ операций.

Ключевые численные результаты. Стационар: $\eta_L \approx 6,1 \cdot 10^{-5}$ при $t > 5 \cdot 10^3$. Дрейф без сброса: $\nu_\infty(t > 60000) \approx 0,999 \pm 0,001$, η_L убывает на ~ 3 декады. Сетка τ_w : оптимум $\tau_w^* \approx 200$, $\langle \eta_L \rangle \approx 1,3 \cdot 10^{-5}$. Эмпирический $\nu_c^{\text{emp}} \approx 0,44$ в момент полураспада η_L .

Команда воспроизведения и выходы. python simulations/markov_drift/main.py; время прогона $\sim 5-10$ минут; выходы — results_summary.{txt,json}, run.log, фигуры paper/figs/fig{1,2,3}*.png.

4.2 S4.2 OU-симуляция (§ 6.2)

Класс модели. Марковская цепь с непрерывным OU-дрейфом логитов матрицы переходов. $k = 8$, $K = k(k-1) = 56$ свободных параметров. Уравнения OU $d\theta_{ij} = -\lambda(\theta_{ij} - \theta_{ij}^*) dt + \sigma dW_{ij}$ с $\theta_{ij}^* = 0$, независимыми W_{ij} для $i \neq j$, и фиксированным $\theta_{ii} \equiv 0$ как softmax-анкер. Дискретизация Эйлера–Маруямы с $\Delta t = 1$.

Базовые параметры. $k = 8$, $\lambda = 10^{-3}$, $\sigma = 0,1$, $T = 2 \cdot 10^4$ шагов, 50 независимых реализаций OU-процесса; начальные логиты $\theta(0) \sim \mathcal{N}(0, 0,1^2)$.

Безразмерные параметры. $\sigma^2/\lambda = 10$; стационарная дисперсия логитов $\sigma^2/(2\lambda) = 5$ — сильный режим флуктуаций (не OU-concentration). Транзиентное окно $1/\sigma^2 = 10^2$ шагов.

Аппроксимация байесовского обучателя. Robbins—Monro online-обновление с убывающим шагом $\eta_t = c_0/\sqrt{t}$, $c_0 = 3$; на каждом шаге $\hat{\theta}_{x_t,j}(t+1) = \hat{\theta}_{x_t,j}(t) + \eta_t \cdot (\mathbb{I}[x_{t+1} = j] - \hat{P}_{x_t,j}(t))$ для $j \neq x_t$. Скорость $1/\sqrt{t}$ соответствует концентрации апостериора по каждому из K направлений и асимптотически Bayes-оптимальна для регулярных параметрических моделей (Clarke and Barron 1990, § 3).

Эффективный темп refresh. $\dot{M}_{\text{refresh}}^{\text{eff}}(t) \sim Kc_0/(\tau_E\sqrt{t})$; при $K = 56$, $\tau_E = 10^3$, $t = 2 \cdot 10^4$ даёт $\sim 0,17$ обновлений на шаг; константа (*) $c(t) = \dot{M}_{\text{refresh}}^{\text{eff}} \cdot \tau_E/|M_{\leq t}| \approx Kc_0/(|M_{\leq t}|\sqrt{t}) \approx 0,02$ при $|M_{\leq t}| = K$. Это обосновывает численный гар $\nu(t > 10^4) \approx 0,82$ против предсказания $\liminf \nu^{\text{theor}} \geq 1 - c \approx 0,98$ (§ 6.2; конечность времени наблюдения и Замечание 5 покрывают разрыв $\approx 0,16$).

Бюджет. Два варианта: (а) $N_{\text{max}} = Rt$ с $R = 1$ и (б) полный $N_{\text{max}}^{\text{full}} = Rt + \nu(t) \cdot K/\tau_{1/2}$ с $\tau_{1/2} = 100$. Кривые $\eta_L(t)$ качественно идентичны.

Ключевые численные результаты. На поздних временах ($t > 10^4$): $\nu = 0,822 \pm 0,031$; $\langle \eta_L \rangle_R \approx 1,0 \cdot 10^{-5}$, $\langle \eta_L \rangle_{\text{full}} \approx 7,3 \cdot 10^{-6}$. Фит $\eta_L \cdot t$ против $\ln(\lambda t)$ на $[10^3, 1,5 \cdot 10^4]$: $n = 71$ точек, $R^2 = 0,888$ при $N_{\text{max}} = Rt$; $R^2 = 0,906$ при полном бюджете.

Команда воспроизведения и выходы. python simulations/markov_drift_ou/main.py; время прогона ~ 1 минута; выходы — results_summary.{txt,json}, run.log, фигуры paper/figs/fig{4,5}_ou_*.png.

4.3 S4.3 Адиабатический скан (§ S8.3)

Класс модели. OU-параметризация § 6.2 без изменений ($k = 8$, $\lambda = 10^{-3}$, $K = 56$, Эйлер—Маруяма $\Delta t = 1$, Robbins—Monro $\eta_t = c_0/\sqrt{t}$, $c_0 = 3$). Измеряемая величина — кумулятивная excess-loss $L_{\text{excess}}(t)$ по (S8.1) с прямым доступом к ground truth $\theta(s)$.

Параметрический скан. Три значения σ при фиксированном $\lambda = 10^{-3}$:

σ	σ^2/λ	$1/\sigma^2$	T_{total}	Реализаций
0,01	10^{-1}	10^4	$5 \cdot 10^4$	25
0,003	$9 \cdot 10^{-3}$	$1,1 \cdot 10^5$	$5 \cdot 10^4$	25
0,001	10^{-3}	10^6	$2 \cdot 10^5$	25

Время симуляции T выбрано в пределах транзиентного окна $1/\sigma^2$ для каждой σ .

Совместная подгонка. $L_{\text{excess}}(t) = A \cdot t + B \cdot \ln(\lambda t) + C$ на окне $t \in [10^3, 10^4]$ (фиксированном для прямого сопоставления между σ).

Отрицательный контроль с расширенным окном. Дополнительный фит с расширенным окном $[10^3, T_{\text{total}}]$: при $\sigma^2/\lambda = 10^{-3}$ и $T_{\text{total}} = 2 \cdot 10^5$ коэффициент $B/(K/2)$ растёт до 2,0 — артефакт Robbins—Monro $1/\sqrt{t}$ -смещения обучателя на длинных горизонтах, не часть BNT-эффекта. Этот контроль фиксирует

чувствительность результата к выбору окна и предотвращает интерпретацию монотонного тренда $B/(K/2)$ как результата выборочного предъявления.

Ключевые численные результаты. $B/(K/2) = \{0,54, 0,78, 0,85\}$ при $\sigma^2/\lambda \in \{10^{-1}, 9 \cdot 10^{-3}, 10^{-3}\}$ соответственно; $R^2 \geq 0,9995$ во всех точках; drift-share $A \cdot t/L_{\text{excess}}(t)$ при $t = 10^4$ падает с 76% до 10%. Монотонный рост B при $\sigma^2/\lambda \rightarrow 0$ согласуется с гипотезой § S8.1, но не доказывает сходимости $B \rightarrow K/2$; необходимы 5–6 точек скана с явной аналитической формой finite- σ correction $B(\epsilon) = (K/2)(1 - g(\epsilon))$.

Команда воспроизведения и выходы. python simulations/markov_drift_ou_iinf_adiab/main.py; время прогона ~ 1 минута; выходы — results_summary.{txt,json}, run.log, фигуры simulations/markov_drift_ou_iinf_adiab/fig_adiab_*.png, скопированные в paper/figs/fig{6,7}_adiab_*.png.

4.4 S4.4 Воспроизводимость: зависимости и архивация

Зерно и зависимости. Глобальное SEED = 20260524 установлено в начале main.py каждого скрипта; per-run-offsets обеспечивают независимость реализаций. Зависимости — numpy, scipy, scikit-learn (KSG), matplotlib; точные версии — в requirements.txt каждой директории.

Полный набор команд. В корне репозитория последовательно python simulations/markov_drift_{,ou,ou_iinf_adiab}/main.py; суммарное время прогона на ноутбуке среднего класса ~ 7 –12 минут.

Zenodo-архивация. Версионированный снимок с DOI заархивирован на Zenodo (DOI: 10.5281/zenodo.20653051, релиз v1.0-submission); воспроизведение возможно также через клонирование andriishin/landauer-nostalgia-ou на теге v1.0-submission (тот же снимок, заархивированный на Zenodo).

5 S5. Полный аппарат § 5 main: Замечания 1–6 к Лемме 2, протокол § 5.2, ν_c и τ_{reset}^*

Раздел собирает формальные детали § 5 main, вынесенные сюда для разгрузки основного изложения. Структура: S5.1 — шесть Замечаний к Лемме 2 (§ 4.4 main фиксирует формулировку (8a) и краткое утверждение; здесь — полная их развёртка); S5.2 — пункт 5 протокола § 5.2 main (запрет на пересмотр определения объекта измерения) с обоснованием через (Wolpert 1996) no-free-lunch; S5.3 — балансовое условие существования ν_c через (11b) и обсуждение его структурного статуса; S5.4 — оптимальный τ_{reset}^* (12), связь с dynamic regret bounds (Besbes et al. 2015); S5.5 — аналогия со спин-стёклами через (Hopfield 1982; Amit et al. 1985; Engel and Van den Broeck 2001).

5.1 S5.1 Шесть Замечаний к Лемме 2

Замечание 1 (стационарный предел). Стационарный предел Леммы 2 задаётся *не* $\tau_E \rightarrow \infty$ (этот переход нарушает условие $c < 1$ по (*) main), а формулой (1) main при $\dot{E}_{\text{store}} = \dot{E}_{\text{grow}} = 0$ (§ 2.2 main): в этом режиме ностальгические биты не несут платы, и шкала ν^{theor} через (7) main теряет термодинамический смысл (то же для ν^{op} при $\hat{P} \rightarrow P_0$). Таким образом, Лемма 2 не противоречит стационарной лемме (Andriishin 2026, § 2.1), а *дополняет* её на новый режим: при $\dot{E}_{\text{store}} > 0$ или $\dot{E}_{\text{grow}} > 0$ актуально условие (8a), а в стационарном пределе оно вырождается через обнуление обеих ставок.

Замечание 2 (вычислимость и фальсифицируемость (*)). Константа c из (*) main — *вычисляемая* функция трёх измеримых параметров ($\dot{M}_{\text{refresh}}, \tau_E, |M_{\leq t}|$), не свободный параметр теории. Лемма 2 применима при измеренных $c < 1$; при $c \geq 1$ система переходит в режим *скользящего окна*: за интервал τ_E полностью обновляется вся память, архивного слоя нет, и нестационарная теория вырождается. Тест на c — эмпирическое условие применимости, разделяющее системы с архивным слоем и без него. LLM с длинным контекстом и M_t -слоем порядка 10^5 – 10^6 токенов на инференсе дают $\dot{M}_{\text{refresh}}\tau_E \gg |M_t|$, $c \gg 1$, и Лемма 2 относит их к скользящему окну — теория по собственному условию выводит этот слой из области применимости (§ 8.3 main).

Замечание 3 (содержательность (8a) сверх определения). Доля $1 - c$ — арифметическая (отношение числа необновлённых битов к полному размеру памяти), а ν^{theor} по (7) main — информационно-теоретическая (нормированный дефицит МП). Содержательная часть Леммы 2 — доказательство, что МП-вклад необновлённого бита в $I_{\text{pred}}(t, \tau)$ асимптотически обнуляется по DPI через decorrelation OU-латента с характерным временем τ_E (см. подробное доказательство в S1 supplementary через МП-тензоризацию по независимым координатам OU, § S1.5). Требуются три условия: (i) декорреляция оптимальной статистики с τ_E ; (ii) идеальный наблюдатель в знаменателе (7) main; (iii) FIFO-refresh. При нарушении любого из (i)–(iii) неравенство (8a) не выводится из арифметического c .

Замечание 4 (распространение на общий нестационарный класс). Базовая Лемма 2 доказана для OU-параметризации логитов (§ 5.2 main, S1–S2 supplementary). PSP-суррогат (§ 6.1 main) и мультимасштабный дрейф воспроизводят результат *иллюстративно* при $\lambda\tau_{\text{relax}} \ll 1$ через единый механизм декорреляции с эффективным τ_E , но строгого доказательства для не-OU классов в настоящей работе нет; см. § 8.5 main, открытая задача. Wolpert no-free-lunch (Wolpert 1996) даёт фундаментальное обоснование сужения класса § 5.2: универсальная теория нестационарной обучаемости без априорного ограничения класса невозможна; class slow-driving — необходимое сужение, не методологический выбор.

Замечание 5 (per-bit-uniformity). Переход от арифметической доли необновлённых битов c к информационно-теоретическому неравенству $\nu \geq 1 - c$ требует аддитивности МП по независимо обновляемым битам:

$$I(M^{\text{refr}}; X_E^{[t, t+\tau]}) \leq c \cdot I_{\text{pred}}^{\text{opt}} \cdot (1 + o(1)).$$

В slow-driving пределе refresh-фракция не накапливает кросс-битовой избыточности (Clarke and Barron 1990); полное доказательство этого утверждения для OU-параметризации — S2 supplementary. При нарушении условия $c \rightarrow \kappa c$, $\kappa \geq 1$, и Лемма 2 формулируется с мультипликативной поправкой $\nu \geq 1 - \kappa c$; в OU-классе с независимыми W_{ij} и диагональным анкером $\theta_{ii} \equiv 0$ условие per-bit-uniformity выполнено по построению с $\kappa = 1 + o(1)$ (S2.6 supplementary).

Замечание 6 (softmax-regularity для OU). Перенос OU-декорреляции с автоковариации логитов $\theta(t)$ на любой ограниченный измеримый функционал $\xi(\theta)$ (в частности, на элементы матрицы переходов $P_{ij}(\theta)$ и на любую достаточную статистику предсказания) обеспечивается Lipschitz-непрерывностью softmax по total variation на множестве логитов с конечной стационарной дисперсией $\sigma^2/(2\lambda)$. Через МТ-тензоризацию по независимым координатам OU (§ S1.5) и DPI экспоненциальное затухание $\mathbb{E}[\theta(t)\theta(s)] \propto e^{-(t-s)/\tau_E}$ переносится на любой ограниченный ξ с тем же характерным временем τ_E . Полное доказательство — S1 supplementary (пять шагов: Lipschitz softmax в ℓ_∞ ; перенос на TV матрицы переходов; ограниченность OU-траектории на шаре $R(\delta)$ с вероятностью $1-\delta$; перенос затухания на ковариацию ξ ; перевод TV-границы в границу для условной МТ через χ^2 и DPI).

Лемма 2 в свете Замечаний 1–6 конструктивна: при (*) указывает явный механизм возникновения ностальгии (рассинхронизация оптимального признака через OU-декорреляцию) и физическое препятствие к её нулю (конечный темп обновления памяти при FIFO-планировании). Совместное действие Замечаний 5–6 — структурное обоснование заявленной асимптотики $\nu \geq 1 - c$ в OU-классе § 5.2 main; Замечание 2 фиксирует область применимости через измеримое условие $c < 1$.

5.2 S5.2 Протокол § 5.2 main, пункт 5: запрет на пересмотр определения объекта измерения

Пункт 5 протокола (§ 5.2 main) — обязательство предрегистрации, защищающее фальсифицируемость: операциональное определение измеряемой величины фиксируется *до* данных и не пересматривается под прежним именем теории после их получения. При систематическом расхождении предсказания и измерения остаются два честных хода: (а) опровергнуть теорию; (б) явно сменить её имя, оставив старое имя за исходным определением. Правило симметрично — оно одинаково связывает теоретика и эмпирика.

Зачем это нужно. Стандартный ответ на провал эмпирического теста — либо отвергнуть теорию, либо сузить условия её применимости (добавить оговорки); оба хода легитимны и сохраняют тест строгим. Пункт 5 закрывает лишь третий, методологически сомнительный путь — пересмотр самого *операционального определения* объекта измерения с сохранением имени теории (классическое ad hoc спасение в смысле Поппера, замаскированное под техническое уточнение операционализации). Симметрия делает дисциплину честной в обе стороны: эмпирик не «уточняет» определение измеряемой величины post hoc, чтобы данные сошлись с теорией; теоретик не «уточняет» определение предсказываемой величины post hoc, чтобы они разошлись.

Как это исполнено в работе. Кумулятивная excess-loss $L_{\text{excess}}(t)$ (S8.1) удержана в § S8 как отдельный, явно помеченный counterfactual-диагностик, а не используется как операционально измеримая I_{pred} : L_{excess} требует доступа к ground truth $\theta(s)$, недоступному в реальных биологических системах, поэтому отождествление её с одношаговой МІ (4) main под именем «predictive information» было бы post hoc пересмотром объекта измерения. Теоретические конструкции (Лемма 2, ν_c , $C_v^{\text{predictive}}$) опираются на ν^{theor} по (7) main; операциональные предсказания (§ 8.6 main, П.1, П.2) — на ν^{op} по (7') main. Подмена под одним именем исключена; раздельное счетоводство двух величин — нет.

5.3 S5.3 Существование ν_c : балансовое условие (11b) и его структурный статус

Балансовая оценка из условия равенства прироста $\dot{I}_{\text{pred}}$ и потерь от устаревания (формула (11b) main):

$$\nu_c^{\text{theor}} \cdot |M_{\leq t}| / \tau_{1/2} = (1 - \nu_c^{\text{theor}}) \cdot \dot{M}_{\text{refresh}}.$$

Безразмерный $\eta_M := \dot{M}_{\text{refresh}} \tau_{1/2} / |M_{\leq t}|$ даёт формально $\nu_c^{\text{theor}} = \eta_M / (1 + \eta_M)$; прямая подстановка в этой простейшей форме даёт численные значения, не согласующиеся с эмпирическим прокси § 6.1 main ($\nu_c^{\text{emp}} \approx 0,44$ против $\nu_c \approx 0,016$ при η_M базовой параметризации PSP — расхождение более чем на порядок).

Структурный статус (11b). (11b) трактуется как *структурное балансовое условие*, не количественный предсказатель: работа постулирует существование $\nu_c^{\text{theor}} \in (0, 1)$ как неподвижной точки баланса прироста информации и потерь от устаревания. Расхождение с эмпирическим ν_c^{emp} поддерживает это решение — прямая подстановка простейшей формы (11b) отвергается, что и фиксируется как граница её интерпретативной силы. Вывод количественной формулы $\nu_c^{\text{theor}}(\lambda, \sigma, K, \tau_{1/2}, \dot{M}_{\text{refresh}})$ — открытая задача § 8.5 main.

Активная часть памяти. В (11b) $|M_{\leq t}|$ — *активная* часть памяти, не структурный лимит ёмкости $|M_{\leq t}^{\text{cap}}|$. В § 6.1 main: $|M_t| = k^2 = 64$ параметров оценщика; эта величина растёт с временем в системах с расширяющейся памятью, и численное значение ν_c^{theor} зависит от времени. Эмпирический прокси ν_c^{emp} § 6.1 main — это ν_c^{op} по (7') main, не ν_c^{theor} ; рабочее допущение § 4.1 main о стабильности режимного порога под сменой нормировки обеспечивает переход между ними с возможным численным сдвигом.

5.4 S5.4 Оптимальный τ_{reset}^* и связь с dynamic regret

Оптимальный τ_{reset}^* максимизирует $\langle \eta_L \rangle$: частый сброс увеличивает плату, редкий ведёт к ностальгическому коллапсу (§ 5.3 main). Структурная оценка:

$$\tau_{\text{reset}}^* \sim \tau_E \cdot \log(|M_{\leq t}^{\text{cap}}| / \dot{M}_{\text{refresh}} \tau_E),$$

где $|M_{\leq t}^{\text{cap}}|$ — структурный лимит ёмкости памяти. Логарифмическая зависимость — отражение стандартной формы оптимума для процессов с экспоненциальным устареванием и линейной платой за обновление.

Биологическая аналогия. Время поколения таксона коррелирует с темпом изменения эконисе — эмпирическая закономерность популяционной биологии, согласующаяся с (12) main с точностью до логарифмического множителя. У млекопитающих в раннем эмбриогенезе и герминальной линии происходит почти полное стирание метилирования ДНК с повторной установкой (Reik 2007); это можно трактовать как механизм τ_{reset}^* на поколенческой шкале — периодический сброс ностальгического слоя ради восстановления $\nu \rightarrow 0$ в новом поколении.

Связь с dynamic regret bounds. В non-stationary stochastic optimization (Besbes et al. 2015) (Theorem 2, stochastic setting) regret-оптимальная длина restart-эпохи имеет *степенную* структуру: оптимальная длина $\propto (T/V_T)^{2/3}$, где V_T — вариация цели на горизонте T . Это отлично от логарифмической формы $\tau_{\text{reset}}^* \sim \tau_E \log(\cdot)$ main §8.4(b): главный текст даёт *логарифмическую* форму через линейную плату за обновление с экспоненциальным устареванием, тогда как BGZ regret-optimal restart — *степенную* $(T/V_T)^{2/3}$. Совпадает лишь монотонность по τ_E (медленнее дрейф — реже сброс), не функциональная форма. В no-free-lunch (Wolpert 1996) универсальный τ_{reset}^* невозможен, что согласуется с условностью (12) main относительно класса § 5.2 main.

5.5 S5.5 Аналогия со спин-стёклами

(11b) main — баланс среднего поля, структурно аналогичный реплика-симметрии в статистической механике обучения (Engel and Van den Broeck 2001). В классической модели Хопфилда (Hopfield 1982) критическая нагрузка $\alpha_c \approx 0,138$ (Amit et al. 1985) — порог, за которым ассоциативная память теряет способность извлекать запомненные паттерны без ошибок. Наш ν_c^{theor} есть аналог в неравновесной обучающейся системе: порог, за которым ностальгическая фракция превышает критическую долю и предсказательная сила $\eta_L(t)$ коллапсирует.

Количественная связь между ν_c^{theor} и α_c Хопфилда — отдельная задача: α_c — отношение числа запомненных паттернов к числу нейронов в равновесной системе с фиксированным набором мишеней, ν_c^{theor} — пороговое отношение ностальгической фракции в неравновесной системе с дрейфующим латентным параметром. Структурное соответствие — обе величины отражают предельную нагрузку на ёмкость памяти в системах с фиксированным числом степеней свободы; динамические же характеристики существенно различны.

6 S6. Полные технические детали § 6 main: PSP-параметры, Robbins—Monro learner, контроль с расширенным окном

Раздел собирает технические детали численных иллюстраций § 6.1 (PSP) и § 6.2 (OU) main, которые в основном тексте оставлены в виде краткой формулировки результатов с cross-ref сюда. Структура: S6.1 — полные параметры

PSP-симуляции (§ 6.1 main) и оценщик MI; S6.2 — псевдокод симуляции и сравнительный анализ оценщиков; S6.3 — Robbins—Monro online learner OU-симуляции (§ 6.2 main) и его асимптотическая Bayes-оптимальность; S6.4 — численная оценка c для Robbins—Monro и расхождение с предсказанием (8a); S6.5 — отрицательный контроль с расширенным окном адиабатического скана и расхождение $C_v^{\text{static}}/C_v^{\text{predictive}}$; S6.6 — эмпирический ν_c^{emp} и его статус.

Все параметры воспроизводимости (зерно, версии библиотек, директории) — S4 supplementary (параметры симуляций для воспроизводимости); этот раздел сосредоточен на методологическом обосновании выбора параметров и интерпретации результатов.

6.1 S6.1 PSP-симуляция (§ 6.1 main): полные параметры и оценщик

Модель. Конечно-состояний марковский процесс с пуассоновскими сменами матрицы переходов. Алфавит $\Omega = \{1, \dots, k\}$, $k = 8$. Матрица $P(t)$ кусочно-постоянна на интервалах $[T_i, T_{i+1})$; моменты смены $\{T_i\}$ — пуассоновский поток с интенсивностью λ . В момент T_i матрица обновляется до случайной стохастической $P^{(i)} \sim \text{Dirichlet}(\alpha = 0,3)$ по строкам. $\alpha = 0,3$ даёт $\langle \tau_{\text{relax}} \rangle \approx 2\text{--}3$ шагов и $\lambda \tau_{\text{relax}} \approx 3 \cdot 10^{-3} \ll 1$ с запасом — slow-driving выполнено.

Память наблюдателя. Система-наблюдатель удерживает память M_t , состоящую из оценки текущей матрицы переходов $\hat{P}(t)$ по скользящему окну длины τ_w с Laplace-сглаживанием (псевдоотсчёт 1 на ячейку). Структурная размерность памяти $|M_t| = k^2 = 64$ параметров — число независимых ячеек оценщика; для бюджета $N_{\text{max}}(t) = N_0 + R \cdot t$ в симуляции принята нормировка $k_B T \ln 2 = 1$ и $R = 1$ единица в шаг (базовая операционная плата плюс Лемма 1 на k^2 удерживаемых параметрах).

Параметры трёх режимов. Стационарный режим: $\lambda = 0$ (матрица не меняется), $\tau_w = 100$, $T = 10^4$ шагов, усреднение по 80 реализациям. Дрейф без сброса: $\lambda = 10^{-3}$ (среднее $\tau_E = 10^3$ шагов между сменами), $\tau_w \rightarrow \infty$ (память не очищается, $\hat{P}(t)$ усредняется по всей истории), $T = 10^5$ шагов, 60 реализаций. Дрейф со сбросом: $\lambda = 10^{-3}$, $\tau_w \in \{100, 500, 2000\}$, $T = 10^5$, 60 реализаций.

Сетка τ_w для Рис. 2. Восемь точек $\tau_w \in \{50, 100, 200, 500, 10^3, 2 \cdot 10^3, 5 \cdot 10^3, 10^4\}$ при $\lambda = 10^{-3}$, $T = 5 \cdot 10^4$, 40 реализаций на точку.

6.2 S6.2 Псевдокод симуляции и сравнительный анализ MI-оценщиков

Псевдокод PSP-симуляции.

для каждого условия (λ, τ_w) :

инициализировать P_0 , выбрать $T_1 \sim \text{Exp}(\lambda)$

инициализировать память: $\text{empirical_freq} = \text{матрица нулей } (k \times k)$


```

для t = 0, 1, ..., T:

    если t == T_i: обновить P до случайной  $P(i) \sim \text{Dirichlet}(\alpha=0,3, k \text{ строк})$ ,

        выбрать  $T_{i+1}$ 

     $X_t$  = сэмпл из  $P_t[X_{t-1}, :]$ 

    обновить  $\text{empirical\_freq}[X_{t-1}, X_t] += 1$ 

    если  $t \bmod \tau_w == 0$  и  $\tau_w < \infty$ :  $\text{empirical\_freq} = 0$  # сброс

     $P_{\text{hat}}(t)$  =  $\text{empirical\_freq}$  нормировать по строкам (с Laplace smoothing)

    вычислить  $I_{\text{pred}}(t, \tau) = \text{MI}(X_{t+1..t+\tau}; P_{\text{hat}}(t))$ 

    вычислить  $\nu(t) = 1 - I_{\text{pred}}(t, \tau) / I_{\text{pred}}^{\text{optimal}}(P_t, \tau)$ 

    накопить  $N_{\text{max}}(t)$  = накопленная стоимость хранения  $\text{empirical\_freq}$  + рост ёмкости

     $\eta_L(t) = I_{\text{pred}}(t, \tau) / N_{\text{max}}(t)$ 

для каждого набора  $(\lambda, \tau_w)$ : построить графики  $\eta_L(t)$ ,  $\nu(t)$ 

```

Оценщик MI: KL-detuned proxy. При горизонте предсказания τ численная оценка ядрового определения (4) main проводится через

$$\hat{I}_{\text{pred}}(t, \tau) = I_{\text{opt}}(P(t), \tau) - \mathbb{E}_{X_t \sim \pi(t)} [D_{\text{KL}}(P(t)^\tau(\cdot | X_t) \| \hat{P}(t)^\tau(\cdot | X_t))],$$

отсечённый снизу нулём. Здесь $I_{\text{opt}}(P, \tau) = H(\pi) - \sum_i \pi_i H(P_{i,\cdot}^\tau)$ — predictive information оптимального наблюдателя с точной моделью; вычитается KL-штраф за несоответствие $\hat{P}$ истинному P . Связь с (4) main: для марковской цепи с фиксированным оценщиком $\hat{I}_{\text{pred}}(t, \tau)$ мажорируется условной MI $I(X_t; X_{t+\tau} | \hat{P}(t))$ сверху (KL-штраф учитывает дезадаптацию модели как нижнюю границу потерь информативности); отсечение снизу нулём обеспечено тем, что условная MI неотрицательна. На эргодическом плато $\hat{P}(t) \rightarrow P(t)$ KL-штраф обнуляется, и $\hat{I}_{\text{pred}} \rightarrow I_{\text{opt}} = I(X_t; X_{t+\tau} | P_0)$, что согласовано с (4) main в стационарном пределе.

Сравнение с независимыми оценщиками. Альтернативные дискретные оценки MI с коррекцией смещения (Treves and Panzeri 1995) и непрерывный KSG-оценщик с k -NN, $k_{NN} = 3$ (Kraskov et al. 2004) дают согласованные результаты на сетке параметров PSP-симуляции. Согласованность трёх независимых оценщиков

(KL-detuned proxy, Treves—Panzeri plug-in, KSG) на одних и тех же траекториях подтверждает, что наблюдаемые качественные паттерны (Рис. 1–3 main) — не артефакт конкретного метода оценки MI.

Куполообразная зависимость $\langle \eta_L \rangle(\tau_w)$. Куполообразная кривая Рис. 2 main с максимумом $\langle \eta_L \rangle^* \approx 1,3 \cdot 10^{-5}$ при $\tau_w^* \approx 200$ шагов (плато 200–500) — нестационарный аналог bias-variance компромисса классической теории обучения: малый τ_w — высокая дисперсия оценщика $\hat{P}$ (недостаточно данных), большой τ_w — смещение из-за усреднения по неактуальным режимам; оптимум τ_w^* — баланс, аналогичный structural risk minimization.

Положение максимума $\tau_w^* \approx 0,2 \tau_E$ согласуется с (12) main с точностью до логарифмического множителя; точное значение оптимума зависит от мелких параметров оценщика (Laplace-сглаживание, α Dirichlet).

6.3 S6.3 Robbins—Monro online learner OU-симуляции (§ 6.2 main)

Поддержание онлайн-оценки. В OU-симуляции (§ 6.2 main) обучатель поддерживает онлайн-оценку $\hat{\theta}(t)$ через максимизацию условного логарифма правдоподобия с убывающим шагом $\eta_t = c_0/\sqrt{t}$ ($c_0 = 3$): на каждом шаге при наблюдении $(x_t \rightarrow x_{t+1})$ выполняется

$$\hat{\theta}_{x_t,j}(t+1) = \hat{\theta}_{x_t,j}(t) + \eta_t \cdot [\mathbb{K}[x_{t+1} = j] - \hat{P}_{x_t,j}(t)]$$

для $j \neq x_t$. Это диффузионно-prior-Bayes-аппроксимация байесовского обновления по OU-латенту в смысле § 5.2 main; скорость $1/\sqrt{t}$ соответствует concentration апостериора по каждому из K направлений и асимптотически Bayes-оптимальна для регулярных параметрических моделей (Clarke and Barron 1990, § 3).

Polyak—Ruppert averaging note. Стандартное улучшение Robbins—Monro — усреднение итераций Polyak—Ruppert даёт асимптотически эффективную оценку с меньшей дисперсией; в настоящей реализации не использовано, поскольку наблюдаемые качественные паттерны (Рис. 4–5 main) робастны к выбору варианта Robbins—Monro в пределах log-факторов на финальную дисперсию. Использование Polyak—Ruppert изменило бы количественные значения $\eta_L(t)$ на константный множитель, но не качественную картину коллапса.

Структурная эквивалентность Bayes. Robbins—Monro с указанной скоростью $\eta_t \propto 1/\sqrt{t}$ структурно эквивалентна online-аппроксимации байесовского обновления по OU-латенту § 5.2 main в следующем смысле: посткумулятивное распределение оценок $\hat{\theta}(t)$ при $t \rightarrow \infty$ концентрируется вокруг условного среднего апостериора с ковариацией порядка $\mathcal{F}^{-1}/t$, где $\mathcal{F}$ — Fisher information matrix параметрической модели (Clarke and Barron 1990). Это обоснование выбора $\eta_t \propto 1/\sqrt{t}$ как функционально эквивалентного байесовскому обучателю.

6.4 S6.4 Численная оценка c для Robbins—Monro и расхождение c (8a)

Эффективный темп refresh. Адаптивный шаг $\eta_t = c_0/\sqrt{t}$ с $c_0 = 3$ даёт эффективный темп refresh $\dot{M}_{\text{refresh}}^{\text{eff}}(t) \sim K \cdot \eta_t/\tau_E = Kc_0/(\tau_E\sqrt{t})$; при $K = 56$, $\tau_E = 10^3$, $t = 2 \cdot 10^4$ получается

$$c(t) = \frac{\dot{M}_{\text{refresh}}^{\text{eff}} \cdot \tau_E}{|M_{\leq t}|} \approx \frac{Kc_0}{|M_{\leq t}|\sqrt{t}} \approx \frac{56 \cdot 3}{56 \cdot \sqrt{2} \cdot 10^4} \approx 0,02.$$

Расхождение c предсказанием Леммы 2. Лемма 2 даёт $\liminf \nu^{\text{theor}}(t) \geq 1 - c \approx 0,98$. Наблюдаемое $\nu(t > 10^4) = 0,82 \pm 0,03$ — ниже предсказанной асимптоты; разрыв $\approx 0,16$ объясняется (i) конечностью времени наблюдения (асимптотика (8a) main — $\liminf$ при $t \rightarrow \infty$); (ii) допущением per-bit-uniformity Замечания 5 (S5.1 supplementary), выполняющимся лишь приближённо для ОУ-параметризации логитов с softmax-нелинейностью (Замечание 6). Полное доказательство сходимости к $1 - c$ для конкретной ОУ-параметризации — открытая задача § 8.5 main.

6.5 S6.5 Отрицательный контроль с расширенным окном и расхождение $C_v^{\text{static}}/C_v^{\text{predictive}}$

Отрицательный контроль с расширенным окном. При расширении окна совместной подгонки адиабатического скана (§ S8.3) до $[10^3, T_{\text{total}}]$ (вместо фиксированного $[10^3, 10^4]$) фит вырождается: при $\sigma^2/\lambda = 10^{-3}$ и $T_{\text{total}} = 2 \cdot 10^5$ коэффициент $B/(K/2)$ растёт до 2,0 — артефакт Robbins—Monro $1/\sqrt{t}$ -bias обучателя на длинных горизонтах, не часть BNT-эффекта. Окно $[10^3, 10^4]$ выбрано для прямого сопоставления между точками адиабатической серии и согласовано с transient-условием $t \ll 1/\sigma^2$. Этот контроль фиксирует чувствительность результата к выбору окна фита и предотвращает интерпретацию монотонного тренда $B/(K/2)$ как результата выборочного предъявления.

Численный scan $B/(K/2) \in \{0,54, 0,78, 0,85\}$. Полные результаты — § S8.3 (таблица B , $B/(K/2)$, R^2 , drift-share); S4.3 supplementary (параметры скана).

Расхождение $C_v^{\text{static}}/C_v^{\text{predictive}}$. В режиме «дрейф без сброса» (§ 6.1 main) при $\nu(t) \rightarrow 0,999$ имеем $C_v^{\text{predictive}}(t) = (1 - \nu(t)) \cdot C_v^{\text{static}}(t) \rightarrow 0$, тогда как C_v^{static} остаётся ограниченным снизу размером накопленной памяти $\dot{P}(t)$. Отношение $C_v^{\text{static}}/C_v^{\text{predictive}} \rightarrow \infty$ — численная иллюстрация диагностического сигнала ностальгии (§ 4.3 main): два прокси, согласующиеся в стационарном режиме, расходятся при наблюдаемом дрейфе. Это операционализирует Предсказание 1 § 8.6 main: пересечение ν_c^{op} диагностируется через расхождение двух прокси, без прямого измерения $\nu(t)$.

6.6 S6.6 Эмпирический ν_c^{emp} и его статус

Эмпирический ν_c^{emp} , определённый как значение $\nu(t)$ в момент, когда $\eta_L(t)$ падает вдвое от своего пика в режиме дрейфа без сброса, составляет $\nu_c^{\text{emp}} \approx 0,44$ для базовой параметризации PSP. Это значение согласуется со структурным утверждением § 5.3 main о существовании $\nu_c \in (0, 1)$, разделяющего адаптивный режим

и режим коллапса, но не претендует на универсальную количественную оценку: ν_c^{emp} зависит от выбранного оперативного определения (порог полураспада η_L) и от параметров конкретного PSP-суррогата.

Расхождение с (11b). Прямая балансовая подстановка $\nu_c = \eta_M / (1 + \eta_M) \approx 0,016$ в (11b) main отвергается эмпирически — расхождение более чем на порядок. Это поддерживает решение § 5.3 main / S5.3 supplementary трактовать (11b) как структурное балансовое условие, не как количественный предсказатель. Вывод универсальной формулы $\nu_c(\lambda, \sigma, K, \tau_{1/2}, \dot{M}_{\text{refresh}})$ — открытая задача § 8.5 main.

Стабильность под сменой нормировки. По DPI $\nu^{\text{op}}(t) \leq \nu^{\text{theor}}(t)$ pointwise (§ 4.1 main; меньший знаменатель $C_\mu^{\text{emp}} \leq I_{\text{pred}}^{\text{opt}}$ в (7') даёт больший фрагмент и меньшую ностальгию); следовательно эмпирический ν_c^{emp} — это ν_c^{op} , оценка снизу для ν_c^{theor} . Рабочее допущение § 4.1 main о монотонности режимного порога под сменой нормировки обеспечивает применимость эмпирического ν_c^{emp} как операционального суррогата теоретического ν_c^{theor} с возможным численным сдвигом, но без качественного смещения порога.

7 S7. Active inference: полное формальное соответствие η_L и EFE, $\rho(t)$, оговорки

Раздел собирает формальные детали § 7 main, вынесенные сюда для разгрузки основного изложения. Структура: S7.1 — heuristic correspondence $\Delta G^{\text{epist}} \leftrightarrow -\Delta I_{\text{pred}}$ (S7.1), полное обоснование с переводом единиц; S7.2 — conjecture (S7.2) с явным гипотетическим статусом и обсуждение направления формализации; S7.3 — категориальная оговорка $I_q(s'; o') \neq I(X_t; X_{t+\tau})$ через достаточность $\hat{P}(t)$; S7.4 — контекст sophisticated inference (Friston et al. 2021) и Pearl/Friston-blanket (Bruineberg et al. 2018; Bruineberg et al. 2022) демаркация; S7.5 — парирование Andrews (2021) / Williams (2020) через cross-ref на paper #1; S7.6 — метрика информационного омоложения $\rho(t)$ подробно с эмпирической интерпретацией.

7.1 S7.1 Heuristic correspondence: полное обоснование

В формулировке active inference (Friston et al. 2017a, ур. 3; Parr2022, гл. 7) expected free energy политики π исчисляется в натах и есть

$$G[\pi] = \mathbb{E}_{q(o', s' | \pi)} [\ln q(s' | \pi) - \ln p(o', s' | C)],$$

где $p(o', s' | C)$ — распределение предпочтений с параметром C , кодирующим цели агента. Каноническое разложение раскладывает $G = -\mathbb{E}_q[D_{\text{KL}}(q(s' | o', \pi) || q(s' | \pi))] - \mathbb{E}_q[\ln p(o' | C)]$ на эпистемическую ценность (информационный выигрыш о скрытых состояниях) и прагматическую ценность (близость к предпочтениям).

Конверсия единиц. G измеряется в натах; I_{pred} — в битах (Приложение A main). Перевод: $G_{[\text{нат}]} = G_{[\text{бит}]} \cdot \ln 2$; конверсия в энергетические единицы через

$\beta = 1/(k_B T)$ даёт $E_G = k_B T \cdot G_{[\text{нат}]}$. Аналогично $E_{I_{\text{pred}}} = k_B T \ln 2 \cdot (I_{\text{pred}})_{[\text{бит}]}$. Для приращения за окно политики Δt :

$$k_B T \cdot \Delta G^{\text{epist}}[\pi] \big|_{\Delta t} \approx -k_B T \ln 2 \cdot \Delta I_{\text{pred}} \big|_{\Delta t}, \quad (\text{S7.1})$$

с точностью до аддитивной константы, поглощающей прагматический вклад и не зависящей от π . Обе стороны имеют размерность энергии (Дж); знак минус отражает соглашение « G минимизируется при максимизации I_{pred} »; эквивалентная безразмерная форма получается делением на $k_B T$.

Гипотетический статус. (S7.1) фиксируется как *heuristic correspondence*, не как доказанное неравенство. Доказательство строгого неравенства требует (i) аккуратной работы с временными производными в нестационарной generative model; (ii) демонстрации, что прагматический вклад действительно не зависит от π на временной шкале Δt ; (iii) учёта поправок от категориальной оговорки S7.3. Все три ингредиента отсутствуют в существующей литературе по active inference в нестационарном режиме.

7.2 S7.2 Conjecture: гипотетический статус

Гипотетическая теорема — направление, в котором (S7.1) может быть превращено в строгое неравенство:

$$k_B T \cdot \Delta G^{\text{epist}}[\pi] \big|_{\Delta t} \stackrel{\text{conj.}}{\geq} -k_B T \ln 2 \cdot \Delta I_{\text{pred}} \big|_{\Delta t}, \quad (\text{S7.2})$$

где пометка «conj.» отмечает гипотетический статус. Формальная доказательность (S7.2) — открытая задача, требующая аккуратной работы с временными производными и нестационарной generative model в расширенном active inference framework (Parr et al. 2022).

Sophisticated inference как направление формализации. Sophisticated inference (Friston et al. 2021) расширяет стандартный active inference на политики, учитывающие пост-наблюдательные обновления будущих априорных распределений; это естественная рамка для аккуратной работы с временными производными в нестационарной generative model. Доказательство (S7.2) в sophisticated inference framework — естественный следующий шаг расширения настоящей работы.

7.3 S7.3 Категориальная оговорка $I_q(s'; o') \neq I(X_t; X_{t+\tau})$

Эпистемическая ценность в (Friston2017) — взаимная информация $I_q(s'; o' \mid \pi)$ между скрытым состоянием s' и наблюдением o' , тогда как $I_{\text{pred}}(t, \tau)$ по (4) main — MI между двумя последовательными наблюдениями X_t и $X_{t+\tau}$. Это категориально различные объекты: первое — MI в одной точке времени между латентом и наблюдением, второе — MI между двумя моментами времени по наблюдаемой траектории.

Мост через достаточность $\hat{P}(t)$. При интерпретации $s' = \theta(t + \tau)$, $o' = X_{t+\tau}$ и условии $X_{t+\tau} \perp \theta(t) \mid \hat{P}(t)$ (статистическая достаточность $\hat{P}(t)$ относительно $X_{t+\tau}$) по chain rule MI получается

$$I_{\text{pred}}(t, \tau) \leq I_q(\theta(t + \tau); X_{t+\tau} \mid \hat{P}(t)).$$

Минимизация эпистемической части $G[\pi]$ при бюджете $N_{\max}(t)$ *эвристически соответствует* локальной максимизации $\eta_L(t)$ (в смысле heuristic correspondence § S7.1; строгое следствие не доказано — мост даёт верхнюю границу на I_{pred} , не равенство). Прагматическая компонента через предпочтение C — *вне* термодинамической шкалы; полная эквивалентность η_L и G требовала бы кодирования предпочтение через минимизацию $\dot{E}_{\text{actual}}$ — нетривиальное расширение FER.

Условие соответствия — $M_{\leq t}$ включает $q(s)$ и историю наблюдений (расширение generative model на episodic уровень через иерархическую/мотивированную active inference (Pezzulo et al. 2018; Parr et al. 2022, гл. 7–8), где высшие уровни иерархии удерживают медленно дрейфующий контекст; parametric predictive coding (Bogacz 2017) не вводит отдельного эпизодического слоя).

7.4 S7.4 Pearl/Friston-blanket демаркация и нестационарный режим

Связь между η_L и принципом свободной энергии Фристона (Friston 2010; Friston et al. 2017a) сформулирована в (Andriishin 2026, § 4.4): требование self-payment превращает FER в дискриминационный критерий, а η_L операционально закрывает зазор между общим формализмом и требованием принадлежности энергии моделирующему контуру. Опора — разведение Pearl-blanket (эпистемический инструмент) и Friston-blanket (онтологическое свойство с требованием self-payment) (Bruineberg et al. 2018; Bruineberg et al. 2022).

В нестационарном режиме демаркация сохраняется: соответствие η_L и EFE имеет смысл только для Friston-blanket; для систем с экстернализованной платой (LLM-as-agent в стандартной архитектуре) $\eta_L(t) \rightarrow 0$ — соответствия нет. Это согласуется со структурой § 2.6 main: self-payment как критерий применимости η_L переносится на нестационарный режим и на каждое из трёх слагаемых (1) main.

Destructive argument Bruineberg. Аргумент (Bruineberg et al. 2018; Bruineberg et al. 2022) против онтологизации FER без self-payment-критерия — структурный аргумент в пользу настоящей рамки: η_L операционализирует требование self-payment и тем самым отвечает на критику Bruineberg в смысле, развёрнутом в (Andriishin 2026, § 4.4a).

7.5 S7.5 Andrews (2021) / Williams (2020) cross-ref на paper #1

Парирование возражений Andrews (2021) (FER как пустая тавтология при отсутствии независимых критериев) и Williams (2020) (FER как корректная, но неинформативная характеристика любой неравновесной системы) развёрнуто в (Andriishin 2026, § S4.4a); в настоящей работе оно не повторяется, но структурное соответствие сохраняется: нестационарный $\eta_L(t)$ закрывает тот же зазор, что и стационарный η_L — требование принадлежности диссипативного потока моделирующему контуру через self-payment. Категория соответствия — *функциональное* (общая структура «оптимизация predictive information под бюджетом»), не онтологическое (полное тождество EFE и η_L как объектов).

7.6 S7.6 Метрика информационного омоложения $\rho(t)$: подробно

Метрика информационного омоложения — отношение темпов обновления и роста памяти:

$$\rho(t) = \frac{\dot{M}_{\text{refresh}}(t)}{\dot{M}_{\text{grow}}(t)}.$$

Интерпретация полюсов. $\rho \gg 1$ — обновление обгоняет рост ёмкости: refresh-фракция доминирует, ностальгия ν остаётся низкой (адаптивный режим § 5.3 main). $\rho \ll 1$ — рост ёмкости обгоняет обновление: архивный слой $M_{<t}$ накапливается быстрее, чем успевает обновляться актуальный слой, и ностальгия монотонно растёт (режим ностальгического коллапса).

Эпистемический статус ρ . (13) main — диагностика, независимая от прямого измерения $\nu(t)$: $\dot{M}_{\text{refresh}}$ и $\dot{M}_{\text{grow}}$ измеримы операционально в системах, где прямая оценка $\nu(t)$ через (7) main недоступна. У бактерии $\dot{M}_{\text{refresh}}$ — частота CheB-опосредованного деметилирования рецепторов; $\dot{M}_{\text{grow}}$ — частота репликации с добавлением новых копий рецепторов. У LLM-corp $\dot{M}_{\text{refresh}}$ — частота continual pre-training или RAG-обновления индекса; $\dot{M}_{\text{grow}}$ — частота расширения корпоративного корпуса.

Эмпирическая калибровка. Численные пороги ρ_c — отдельное исследование. В первом приближении $\rho \sim 1$ соответствует балансовому условию (11b) main; точное соотношение $\rho_c(\lambda, \sigma, K, \tau_{1/2})$ зависит от той же параметрической структуры, что и ν_c^{theor} (S5.3 supplementary), и наследует её открытый статус.

Эпистемо-прагматическая декомпозиция (опционально). В терминах active inference $\rho(t)$ можно интерпретировать как баланс эпистемического импульса (увеличение эпистемической ценности через $\dot{M}_{\text{refresh}}$) и прагматической инвестиции (расширение горизонта политики через $\dot{M}_{\text{grow}}$). Эта декомпозиция — естественное следствие соответствия S7.1; её формальная разработка требует sophisticated inference framework S7.2.

8 S8. Адиабатическая асимптотика L_{excess} как открытая гипотеза

Раздел содержит полную развёртку открытой гипотезы об адиабатической асимптотике кумулятивной excess-loss, на которую main § 8.1, § 8.5 ссылаются как на главную открытую количественную задачу работы. Структура: S8.1 — постановка гипотезы и теоретическая мотивация; S8.2 — условия применимости и разделение двух адиабатических режимов; S8.3 — параметрический скан и численная поддержка.

Конверсия единиц для L_{excess} (наты $\leftrightarrow$ биты) — Приложение A main: L_{excess} измеряется в **натах** (как в оригинальной BNT-литературе (Bialek et al. 2001, § VI)

и MDL-формулировке); явная конверсия $L_{\text{excess}}^{[\text{бит}]}(t) = L_{\text{excess}}^{[\text{нат}]}(t)/\ln 2$ применяется при сравнении с основным текстом.

8.1 S8.1 Постановка гипотезы и теоретическая мотивация

Альтернативная теоретическая характеристика накопления информации обучающейся системой о латентном параметре среды — кумулятивная excess-loss обучателя относительно оракула:

$$L_{\text{excess}}(t) := \sum_{s \leq t} [\ln p(X_s | X_{s-1}, \theta(s)) - \ln \hat{p}(X_s | X_{s-1}, \hat{\theta}(s))]. \quad (\text{S8.1})$$

Здесь $\theta(s)$ — истинное значение латентного параметра среды на шаге s , $\hat{\theta}(s)$ — оценка обучателя по истории наблюдений; $L_{\text{excess}}(t)$ измеряется в натах. Операциональный статус (S8.1): эта величина непосредственно вычислима в симуляциях с известной ground truth $\theta(s)$, но в реальных системах (биосфера, LLM-corp, бактерия) латентный параметр $\theta(s)$ принципиально недоступен — L_{excess} остаётся контрфактической, теоретически родственной операционально измеримой одношаговой $I_{\text{pred}}(t, \tau)$ (4) main, но не эквивалентной ей.

Связь с (4) main и термодинамикой памяти. $L_{\text{excess}}(t)$ — кумулятивный Bayesian regret обучателя относительно оракула в смысле (Rissanen 1986; Clarke and Barron 1990); для регулярных параметрических моделей он асимптотически связан с $I(M_{\leq t}; \theta(t))$ через теорему о достаточной статистике в смысле (Cover and Thomas 2006, гл. 2.9). Различие: L_{excess} — интегральная информация о латенте, накопленная к моменту t ; (4) main — плотность информационного потока через текущий шаг, ограниченная $\ln k$.

Гипотеза S8.1 (адиабатическая асимптотика). В адиабатическом OU-пределе $\sigma^2/\lambda \ll 1$ при идеальном байесовском обучении кумулятивная excess-loss $L_{\text{excess}}(t)$ (S8.1) растёт как $(K/2) \ln(\lambda t)$ — Class II асимптотика (Bialek et al. 2001, § VI):

$$L_{\text{excess}}^{\text{Bialek}}(t) \sim \frac{K}{2} \ln(\lambda t), \quad (\text{S8.2})$$

где $K = k(k-1)$ — размерность логитов. Если эту вторичную метрику принять за нестационарный аналог predictive information и определить через неё $\eta_L^{\text{excess}}(t) := L_{\text{excess}}(t)/N_{\text{max}}(t)$, то в ведущем порядке при $t \rightarrow \infty$ в адиабатическом OU-пределе $\sigma^2/\lambda \ll 1$ при идеальном байесовском обучателе и линейном росте знаменателя $N_{\text{max}}(t) \sim Rt$:

$$\eta_L^{\text{excess}}(t) \sim -\frac{K \ln(\lambda t)}{2Rt^2}. \quad (\text{S8.3})$$

Статус гипотезы. (S8.2) — известная Class II асимптотика BNT (Bialek et al. 2001) для регулярных параметрических моделей; коэффициент $K/2$ возникает в нескольких парадигмах статистической теории обучения для регулярных параметрических моделей размерности K : MDL (Rissanen 1986; Grünwald 2007) и BIC

(Schwarz 1978) через Laplace approximation на posterior; PAC-Bayes (McAllester 1999; Catoni 2007) для гауссова prior; online Newton-step regret (Cesa-Bianchi and Lugosi 2006; Hazan et al. 2007) для exp-concave loss (формальный класс, к которому применима логарифмическая граница (Hazan et al. 2007); self-concordant — более узкое свойство, не использованное в Hazan et al. 2007). (S8.3) — её прямое алгебраическое следствие в предположении линейного роста знаменателя. Гипотетический статус относится к двум аспектам: (i) сходимости коэффициента в фите L_{excess} к $K/2$ в реализуемых параметризациях OU при конечном σ ; (ii) применимости результата к операционально измеримой эффективности $\eta_L(t)$ (10) main, а не к вторичной η_L^{excess} .

8.2 S8.2 Условия применимости и разделение двух адиабатических режимов

Гипотеза S8.1 требует *одновременного* выполнения двух условий (см. § 5.2 main):

1. **Slow-driving** $\lambda\tau_{\text{relax}} \ll 1$ — необходимо для применимости Леммы 2 § 4.4 main и квазистационарной интерпретации $\theta(t)$.
2. **OU-concentration** $\sigma^2/\lambda \ll 1$ — необходимо именно для (S8.2), не для (4) main: концентрация апостериора по $\theta(t)$ должна обгонять собственный дрейф $\theta(t)$.

Дополнительно: (iii) ограниченно растущая память $|M_{\leq t}| = o(t/\ln t)$ (для линейности знаменателя $N_{\text{max}} \sim Rt$); (iv) OU-параметризация именно логитов (softmax-форма обеспечивает регулярность параметрической модели); (v) идеальный байесовский обучатель (плата за обновление — в $\dot{E}_{\text{actual}}^{\text{curr}}$, не в ностальгическом слое).

8.3 S8.3 Параметрический скан и численная поддержка гипотезы

Численное исследование (S8.2) — параметрический скан OU-симуляции по σ^2/λ с прямым измерением (S8.1). Реализация — `simulations/markov_drift_ou_iinf_adiab/`.

Модель. OU-параметризация § 5.2 / § 6.2 main без изменений ($k = 8$, $\lambda = 10^{-3}$, $K = 56$, Эйлер—Маруяма $\Delta t = 1$); идеальный байесовский обучатель аппроксимирован Robbins—Монро $\eta_t = c/\sqrt{t}$, $c = 3$. Измеряется $L_{\text{excess}}(t)$ по (S8.1) напрямую — не ограничена $\ln k$, асимптотически растёт как (S8.2).

Параметрический скан. Три значения σ при фиксированном $\lambda = 10^{-3}$: $\sigma \in \{0,01, 0,003, 0,001\}$, дающие $\sigma^2/\lambda \in \{0,1, 9 \cdot 10^{-3}, 10^{-3}\}$ соответственно. Transient-окно $1/\sigma^2 \in \{10^4, 1,1 \cdot 10^5, 10^6\}$; время симуляции $T \in \{5 \cdot 10^4, 5 \cdot 10^4, 2 \cdot 10^5\}$ в пределах transient-окна для всех случаев. Каждая точка — среднее по 25 независимым реализациям OU-процесса; зерно SEED = 20260524. Совместная подгонка $L_{\text{excess}}(t) = A \cdot t + B \cdot \ln(\lambda t) + C$ на окне $t \in [10^3, 10^4]$ (фиксированном для прямого сопоставления между σ).

Результаты. Рис. 6: B против σ^2/λ





Рис. 7: семейство $L_{\text{excess}}(t)$ для трёх σ



σ	σ^2/λ	B	$B/(K/2)$	R^2	drift-share при $t = 10^4$
0,01	10^{-1}	15,15	0,54	0,9998	76%
0,003	$9 \cdot 10^{-3}$	21,85	0,78	0,9996	27%
0,001	10^{-3}	23,84	0,85	0,9995	10%

Коэффициент B монотонно растёт при $\sigma^2/\lambda \rightarrow 0$, давая $B/(K/2) = 0,54, 0,78, 0,85$ соответственно; $R^2 \geq 0,9995$ во всех точках, drift-share $A \cdot t/L_{\text{excess}}(t)$ падает с 76% до 10%.

Отрицательный контроль с расширенным окном. При расширении окна совместной подгонки до $[10^3, T_{\text{total}}]$ (вместо фиксированного $[10^3, 10^4]$) фит вырождается: при $\sigma^2/\lambda = 10^{-3}$ и $T_{\text{total}} = 2 \cdot 10^5$ коэффициент $B/(K/2)$ растёт

до 2,0 — артефакт Robbins—Monro $1/\sqrt{t}$ -bias обучателя на длинных горизонтах, не часть BNT-эффекта. Окно $[10^3, 10^4]$ выбрано для прямого сопоставления между точками адиабатической серии и согласовано с transient-условием $t \ll 1/\sigma^2$. Этот контроль фиксирует чувствительность результата к выбору окна фита и предотвращает интерпретацию монотонного тренда $B/(K/2)$ как результата выборочного предъявления.

Интерпретация. Функциональная форма $L_{\text{excess}}(t) = A \cdot t + B \ln(\lambda t) + C$ извлекается с $R^2 \geq 0,9995$; коэффициент B монотонно растёт от 0,54 до 0,85 $\cdot K/2$ при σ^2/λ от 10^{-1} до 10^{-3} . **Это не доказательство сходимости** $B \rightarrow K/2$; асимптотический предел B_∞ остаётся открытым вопросом. Pre-registered протокол для подтверждения гипотезы (S8.2) требует минимум 5–6 точек скана с явной аналитической формой finite- σ correction $B(\epsilon) = (K/2)(1 - g(\epsilon))$.

Перенос (S8.2) и (S8.3) в статус открытой гипотезы отражает текущее состояние теоретического обоснования, не финальный приговор: численная поддержка функциональной формы и монотонная сходимость к $K/2$ — нетривиальная эмпирическая регулярность, заслуживающая дальнейшего аналитического исследования (см. § 8.5 main).

Воспроизводимость. Полная реализация — `simulations/markov_drift_ou_iinf_adiaab/` (model.py, main.py, README.md); графики в `paper/figs/Fig6.pdf` и `paper/figs/Fig7.pdf`; сводный лог — `simulations/markov_drift_ou_iinf_adiaab/results_summary.{txt,json}` и `run.log`. Зерно SEED = 20260524; запуск `python main.py` (~1 минута на современном ноутбуке) восстанавливает все численные значения.

9 S9. Детали §§ 2.1 и 2.3 main: three-faces-сопоставление и majority-vote-деривация

Раздел собирает плотный стат-механический аппарат, вынесенный из §§ 2.1, 2.3 main для разгрузки основного изложения. S9.1 — полное сопоставление декомпозиции (1) main с three-faces / Hatano–Sasa классификацией entropy production; S9.2 — полный вывод majority-vote-варианта Леммы 1 (формула (2') main).

9.1 S9.1 Сопоставление декомпозиции (1) main с three-faces / Hatano–Sasa

Декомпозиция (1) main *тематически параллельна* three-faces-разложению entropy production (Esposito and Van den Broeck 2010) и Hatano–Sasa-декомпозиции (Hatano and Sasa 2001), но не сводится к ней автоматически. В канонической трактовке housekeeping-компонента поддерживает фиксированный NESS при стационарных управляющих параметрах, excess-компонента — изменение NESS под медленным изменением параметров. Соответствие компонент (1) main:

- $\dot{E}_{\text{store}}$ для удержания конкретного информационного состояния против релаксации к симметричному равновесию относится к *excess*-классу (relaxation-driven), а не к housekeeping: поддерживается не фиксированный NESS, а конкретное неравновесное информационное состояние, релаксирующее к симметричному равновесию.
- $\dot{E}_{\text{actual}}^{\text{curr}}$ при перенастройке $\hat{P}(t)$ под дрейф среды также относится к excess-классу (изменение целевого состояния под медленным дрейфом параметров).
- refresh-операции Леммы 1 — серия неравновесных протоколов поверх этого, не сводимая ни к чисто housekeeping, ни к чисто excess.
- $\dot{E}_{\text{grow}}$ — структурная перестройка (constraint-driven), выходящая за рамки канонической трёхчастной декомпозиции: добавление новых степеней свободы меняет само пространство состояний, а не только распределение на нём.

Точное вложение нестационарной информационной декомпозиции в three-faces-аппарат — открытая задача (§ 8.5 main).

9.2 S9.2 Полный вывод majority-vote-варианта Леммы 1 (формула (2') main)

В пределе $\varepsilon \rightarrow 0$ полиномиальная граница (2) main $\sim 1/\varepsilon$ заменяется majority-vote-вариантом через избыточное кодирование. Для n копий бита с независимыми ошибками $\varepsilon < 1/2$ majority-vote ошибается, лишь когда не менее $n/2$ копий перевернуты; вероятность этого хвоста биномиала $\text{Bin}(n, \varepsilon)$ ограничивается границей Чернова

$$\varepsilon^{\text{eff}} = \Pr[\text{Bin}(n, \varepsilon) \geq n/2] \leq \exp(-n D(\tfrac{1}{2} \parallel \varepsilon)), \quad D(\tfrac{1}{2} \parallel \varepsilon) = \tfrac{1}{2} \ln \frac{1}{4\varepsilon(1-\varepsilon)},$$

где $D(\tfrac{1}{2} \parallel \varepsilon)$ — KL-дивергенция Бернулли $\text{Ber}(1/2)$ от $\text{Ber}(\varepsilon)$. Здесь ε в $D(\tfrac{1}{2} \parallel \varepsilon)$ — *сырая покопийная ошибка* (вероятность переворота на одну копию бита, физический параметр носителя), тогда как ε^{eff} — *целевая* (достигаемая) эффективная ошибка декодированного бита после majority-vote; именно различие этих двух величин и обеспечивает экспоненциальное подавление $\varepsilon^{\text{eff}} \leq e^{-n D(\tfrac{1}{2} \parallel \varepsilon)}$ при фиксированном $\varepsilon < 1/2$. Отсюда для достижения целевой эффективной ошибки ε^{eff} достаточно

$$n \sim \frac{\ln(1/\varepsilon^{\text{eff}})}{D(\tfrac{1}{2} \parallel \varepsilon)}$$

копий — *логарифмическое* по $1/\varepsilon^{\text{eff}}$ число копий (а не линейное по $1/\varepsilon$, как в naive refresh). Каждая из n копий деградирует независимо с тем же $\tau_{1/2}$, поэтому темп refresh для majority-vote сохраняет фактор $t/\tau_{1/2}$ (число refresh-циклов), но плата на цикл — логарифмическая по $1/\varepsilon$, а не полиномиальная:

$$E_{\text{store}}^{(1), \text{maj}}(t) \geq C \cdot \frac{t}{\tau_{1/2}} \cdot k_B T \ln(1/\varepsilon), \quad C = O(1), \quad (2')$$

с константой C , зависящей от схемы majority-vote (Sagawa–Ueda расширение Sagawa and Ueda 2009; Parrondo et al. 2015). Структурно (2) main и (2') совпадают по линейному росту с $t/\tau_{1/2}$ — числу refresh-циклов; различие — по зависимости от ε : полиномиальная в naïve / логарифмическая в majority-vote. Класс систем-камертонов, к которым применима исходная (2) main: ферромагнитные домены тёплых сред и системы с naïve refresh; для биологических систем с feedback-репарацией используется (2') с логарифмической зависимостью от ε . Feedback-assisted refresh (DNA mismatch repair) дополнительно смягчает границу по Sagawa–Ueda $\langle W \rangle \geq k_B T (\Delta S - I_{\text{meas}})$ (Sagawa and Ueda 2009): обнуляется *структурированный* бит с условной энтропией $H(\varepsilon) = -\varepsilon \ln \varepsilon - (1 - \varepsilon) \ln(1 - \varepsilon) \ll \ln 2$ при $\varepsilon \ll 1$, и в пределе идеального измерения цена refresh уходит к нулю — асимптотика автономных демонов Максвелла (Koski et al. 2014; Mandal and Jarzynski 2012; Barato and Seifert 2014; Bauer et al. 2014).

Список литературы

- Amit, D.J., Gutfreund, H., Sompolinsky, H.: Storing infinite numbers of patterns in a spin-glass model of neural networks. *Phys. Rev. Lett.* **55**(14), 1530–1533 (1985) <https://doi.org/10.1103/PhysRevLett.55.1530>
- Andrews, M.: The math is not the territory: navigating the free energy principle. *Biology & Philosophy* **36**(3), 30 (2021) <https://doi.org/10.1007/s10539-021-09807-0>
- Andriishin, A.: Landauer efficiency of self-modeling: an operational scale of vitality. Companion paper submitted simultaneously to *Theory in Biosciences* (Springer); preprint deposited on Zenodo. Public open-access mirror: <https://github.com/andriishin/landauer-self-modeling-oa>. (2026). <https://doi.org/10.5281/zenodo.20262946>
- Alon, U., Surette, M.G., Barkai, N., Leibler, S.: Robustness in bacterial chemotaxis. *Nature* **397**(6715), 168–171 (1999) <https://doi.org/10.1038/16483>
- Bauer, M., Abreu, D., Seifert, U.: Efficiency of a Brownian information machine. *J. Phys. A: Math. Theor.* **47**(29), 292002 (2014) <https://doi.org/10.1088/1751-8113/47/29/292002>
- Bruineberg, J., Dołęga, K., Dewhurst, J., Baltieri, M.: The Emperor’s new Markov blankets. *Behav. Brain Sci.* **45**, 183 (2022) <https://doi.org/10.1017/S0140525X21002351>
- Bennett, C.H.: Logical reversibility of computation. *IBM J. Res. Dev.* **17**(6), 525–532 (1973) <https://doi.org/10.1147/rd.176.0525>
- Bennett, C.H.: The thermodynamics of computation—a review. *Int. J. Theor. Phys.*

- 21**(12), 905–940 (1982) <https://doi.org/10.1007/BF02084158>
- Bifet, A., Gavalda, R.: Learning from time-changing data with adaptive windowing. In: Proceedings of the 2007 SIAM International Conference on Data Mining, pp. 443–448 (2007). <https://doi.org/10.1137/1.9781611972771.42>
- Besbes, O., Gur, Y., Zeevi, A.: Non-stationary stochastic optimization. *Oper. Res.* **63**(5), 1227–1244 (2015) <https://doi.org/10.1287/opre.2015.1408>
- Belkin, M., Hsu, D., Ma, S., Mandal, S.: Reconciling modern machine-learning practice and the classical bias–variance trade-off. *Proc. Natl. Acad. Sci. USA* **116**(32), 15849–15854 (2019) <https://doi.org/10.1073/pnas.1903070116>
- Bruineberg, J., Kiverstein, J., Rietveld, E.: The anticipating brain is not a scientist: The free-energy principle from an ecological-enactive perspective. *Synthese* **195**, 2417–2444 (2018) <https://doi.org/10.1007/s11229-016-1239-1>
- Boyd, A.B., Mandal, D., Crutchfield, J.P.: Leveraging environmental correlations: The thermodynamics of requisite variety. *J. Stat. Phys.* **167**(6), 1555–1585 (2017) <https://doi.org/10.1007/s10955-017-1776-0>
- Borgeaud, S., Mensch, A., Hoffmann, J., Cai, T., Rutherford, E., Millican, K., Driessche, G., Lespiau, J.-B., Damoc, B., Clark, A., *et al.*: Improving language models by retrieving from trillions of tokens. In: Proceedings of the 39th International Conference on Machine Learning (ICML), vol. 162, pp. 2206–2240 (2022)
- Bialek, W., Nemenman, I., Tishby, N.: Predictability, complexity, and learning. *Neural Comput.* **13**(11), 2409–2463 (2001) <https://doi.org/10.1162/089976601753195969>
- Bogacz, R.: A tutorial on the free-energy framework for modelling perception and learning. *J. Math. Psychol.* **76**, 198–211 (2017) <https://doi.org/10.1016/j.jmp.2015.11.003>
- Boyd, R.: Realism, anti-foundationalism and the enthusiasm for natural kinds. *Philosophical Studies* **61**(1–2), 127–148 (1991) <https://doi.org/10.1007/BF00385837>
- Barato, A.C., Seifert, U.: Stochastic thermodynamics with information reservoirs. *Phys. Rev. E* **90**(4), 042150 (2014) <https://doi.org/10.1103/PhysRevE.90.042150>
- Bricken, T., Templeton, A., Batson, J., Chen, B., Jermyn, A., Conerly, T., Turner, N., Anil, C., Denison, C., Askell, A., *et al.*: Towards monosemanticity: Decomposing language models with dictionary learning. *Transformer Circuits Thread*, Anthropic. <https://transformer-circuits.pub/2023/monosemantic-features/> (2023)
- Catoni, O.: PAC-Bayesian Supervised Classification: The Thermodynamics of

- Statistical Learning. IMS Lecture Notes Monograph Series, vol. 56. Institute of Mathematical Statistics, ??? (2007). <https://doi.org/10.1214/074921707000000391>
- Clarke, B.S., Barron, A.R.: Information-theoretic asymptotics of Bayes methods. *IEEE Trans. Inf. Theory* **36**(3), 453–471 (1990) <https://doi.org/10.1109/18.54897>
- Cesa-Bianchi, N., Lugosi, G.: Prediction, Learning, and Games. Cambridge University Press, ??? (2006). <https://doi.org/10.1017/CBO9780511546921>
- Crutchfield, J.P., Feldman, D.P.: Regularities unseen, randomness observed: levels of entropy convergence. *Chaos* **13**(1), 25–54 (2003) <https://doi.org/10.1063/1.1530990>
- Cleland, C.E.: The Quest for a Universal Theory of Life: Searching for Life As We Don’t Know It. Cambridge University Press, Cambridge (2019). <https://doi.org/10.1017/9781139046893>
- Crooks, G.E.: Entropy production fluctuation theorem and the nonequilibrium work relation for free energy differences. *Phys. Rev. E* **60**(3), 2721–2726 (1999) <https://doi.org/10.1103/PhysRevE.60.2721>
- Crooks, G.E.: Measuring thermodynamic length. *Phys. Rev. Lett.* **99**(10), 100602 (2007) <https://doi.org/10.1103/PhysRevLett.99.100602>
- Cover, T.M., Thomas, J.A.: Elements of Information Theory, 2nd edn. Wiley-Interscience, Hoboken, NJ (2006)
- Cummins, R.: Functional analysis. *The Journal of Philosophy* **72**(20), 741–765 (1975) <https://doi.org/10.2307/2024640>
- Dhingra, B., Cole, J.R., Eisenschlos, J.M., Gillick, D., Eisenstein, J., Cohen, W.W.: Time-aware language models as temporal knowledge bases. *Trans. Assoc. Comput. Linguist.* **10**, 257–273 (2022) https://doi.org/10.1162/tacl_a_00459
- Decaestecker, E., Gaba, S., Raeymaekers, J.A.M., Stoks, R., Van Kerckhoven, L., Ebert, D., De Meester, L.: Host–parasite “Red Queen” dynamics archived in pond sediment. *Nature* **450**(7171), 870–873 (2007) <https://doi.org/10.1038/nature06291>
- England, J.L.: Statistical physics of self-replication. *J. Chem. Phys.* **139**(12), 121923 (2013) <https://doi.org/10.1063/1.4818538>
- Errington, J.: Regulation of endospore formation in *bacillus subtilis*. *Nature Reviews Microbiology* **1**(2), 117–126 (2003) <https://doi.org/10.1038/nrmicro750>
- Engel, A., Broeck, C.: Statistical Mechanics of Learning. Cambridge University Press, ??? (2001)
- Esposito, M., Broeck, C.: Three faces of the second law. I. Master equation formulation. *Phys. Rev. E* **82**(1), 011143 (2010) <https://doi.org/10.1103/PhysRevE.82.011143>

- Endres, R.G., Wingreen, N.S.: Precise adaptation in bacterial chemotaxis through “assistance neighborhoods”. *Proc. Natl. Acad. Sci. USA* **103**(35), 13040–13044 (2006) <https://doi.org/10.1073/pnas.0603101103>
- Finn, C., Abbeel, P., Levine, S.: Model-agnostic meta-learning for fast adaptation of deep networks. In: *Proceedings of the 34th International Conference on Machine Learning (ICML)*, vol. 70, pp. 1126–1135 (2017)
- Friston, K., Da Costa, L., Hafner, D., Hesp, C., Parr, T.: Sophisticated inference. *Neural Comput.* **33**(3), 713–763 (2021) https://doi.org/10.1162/neco_a_01351
- Friston, K., FitzGerald, T., Rigoli, F., Schwartenbeck, P., Pezzulo, G.: Active inference: a process theory. *Neural Comput.* **29**(1), 1–49 (2017) https://doi.org/10.1162/NECO_a_00912
- Friston, K., Lin, M., Frith, C.D., Pezzulo, G., Hobson, J.A., Ondobaka, S.: Active inference, curiosity and insight. *Neural Comput.* **29**(10), 2633–2683 (2017) https://doi.org/10.1162/neco_a_00999
- Friston, K.: The free-energy principle: a unified brain theory? *Nat. Rev. Neurosci.* **11**(2), 127–138 (2010) <https://doi.org/10.1038/nrn2787>
- Gama, J., Medas, P., Castillo, G., Rodrigues, P.P.: Learning with drift detection. In: *Advances in Artificial Intelligence – SBIA 2004*, pp. 286–295 (2004). https://doi.org/10.1007/978-3-540-28645-5_29
- Goodfellow, I.J., Mirza, M., Xiao, D., Courville, A., Bengio, Y.: An empirical investigation of catastrophic forgetting in gradient-based neural networks (2014)
- Grünwald, P.D.: *The Minimum Description Length Principle*. MIT Press, ??? (2007)
- Goldt, S., Seifert, U.: Stochastic thermodynamics of learning. *Phys. Rev. Lett.* **118**(1), 010601 (2017) <https://doi.org/10.1103/PhysRevLett.118.010601>
- Garg, S., Tsipras, D., Liang, P., Valiant, G.: What can transformers learn in-context? A case study of simple function classes. In: *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, pp. 30583–30598 (2022)
- Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., Bouchachia, A.: A survey on concept drift adaptation. *ACM Comput. Surv.* **46**(4), 44–14437 (2014) <https://doi.org/10.1145/2523813>
- Hazan, E., Agarwal, A., Kale, S.: Logarithmic regret algorithms for online convex optimization. *Mach. Learn.* **69**(2–3), 169–192 (2007) <https://doi.org/10.1007/s10994-007-5016-8>
- Hartich, D., Barato, A.C., Seifert, U.: Stochastic thermodynamics of bipartite systems: transfer entropy inequalities and a maxwell’s demon interpretation. *J. Stat. Mech.*,

- 02016 (2014) <https://doi.org/10.1088/1742-5468/2014/02/P02016>
- Hopfield, J.J.: Neural networks and physical systems with emergent collective computational abilities. *Proc. Natl. Acad. Sci. USA* **79**(8), 2554–2558 (1982) <https://doi.org/10.1073/pnas.79.8.2554>
- Hatano, T., Sasa, S.-i.: Steady-state thermodynamics of Langevin systems. *Phys. Rev. Lett.* **86**(16), 3463–3466 (2001) <https://doi.org/10.1103/PhysRevLett.86.3463>
- Hazan, E., Seshadhri, C.: Efficient learning algorithms for changing environments. In: *Proceedings of the 26th International Conference on Machine Learning (ICML)*, pp. 393–400 (2009). <https://doi.org/10.1145/1553374.1553425>
- Izacard, G., Lewis, P., Lomeli, M., Hosseini, L., Petroni, F., Schick, T., Dwivedi-Yu, J., Joulin, A., Riedel, S., Grave, E.: Atlas: Few-shot learning with retrieval augmented language models. *J. Mach. Learn. Res.* **24**(251), 1–43 (2023)
- Jarzynski, C.: Nonequilibrium equality for free energy differences. *Phys. Rev. Lett.* **78**(14), 2690–2693 (1997) <https://doi.org/10.1103/PhysRevLett.78.2690>
- Karnin, Z., Anava, O.: Multi-armed bandits: Competing with optimal sequences. In: *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 29, pp. 199–207 (2016)
- Kauffman, S.A.: *The Origins of Order: Self-Organization and Selection in Evolution*. Oxford University Press, New York (1993)
- Khalidi, M.A.: *Natural Categories and Human Kinds: Classification in the Natural and Social Sciences*. Cambridge University Press, Cambridge (2013). <https://doi.org/10.1017/CBO9781139022507>
- Kussell, E., Leibler, S.: Phenotypic diversity, population growth, and information in fluctuating environments. *Science* **309**(5743), 2075–2078 (2005) <https://doi.org/10.1126/science.1114383>
- Khandelwal, U., Levy, O., Jurafsky, D., Zettlemoyer, L., Lewis, M.: Generalization through memorization: Nearest neighbor language models. In: *International Conference on Learning Representations (ICLR)* (2020)
- Koski, J.V., Maisi, V.F., Sagawa, T., Pekola, J.P.: Experimental observation of the role of mutual information in the nonequilibrium dynamics of a Maxwell demon. *Phys. Rev. Lett.* **113**(3), 030601 (2014) <https://doi.org/10.1103/PhysRevLett.113.030601>
- Kirkpatrick, J., Pascanu, R., Rabinowitz, N., Veness, J., Desjardins, G., Rusu, A.A., Milan, K., Quan, J., Ramalho, T., Grabska-Barwinska, A., Hassabis, D., Clopath, C., Kumaran, D., Hadsell, R.: Overcoming catastrophic forgetting in neural networks. *Proc. Natl. Acad. Sci. USA* **114**(13), 3521–3526 (2017) <https://doi.org/10.1073/pnas.1611335114>

[//doi.org/10.1073/pnas.1611835114](https://doi.org/10.1073/pnas.1611835114)

- Kraskov, A., Stögbauer, H., Grassberger, P.: Estimating mutual information. *Phys. Rev. E* **69**(6), 066138 (2004) <https://doi.org/10.1103/PhysRevE.69.066138>
- Landauer, R.: Irreversibility and heat generation in the computing process. *IBM J. Res. Dev.* **5**(3), 183–191 (1961) <https://doi.org/10.1147/rd.53.0183>
- Landenmark, H.K.E., Forgan, D.H., Cockell, C.S.: An estimate of the total DNA in the biosphere. *PLoS Biol.* **13**(6), 1002168 (2015) <https://doi.org/10.1371/journal.pbio.1002168>
- Lazaridou, A., Kuncoro, A., Gribovskaya, E., Agrawal, D., Liska, A., Terzi, T., Gimenez, M., Masson d’Autume, C., Kocisky, T., Ruder, S., *et al.*: Mind the gap: Assessing temporal generalization in neural language models. In: *Advances in Neural Information Processing Systems*, vol. 34, pp. 29348–29363 (2021)
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., Kiela, D.: Retrieval-augmented generation for knowledge-intensive NLP tasks. In: *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, pp. 9459–9474 (2020)
- Lopez-Paz, D., Ranzato, M.: Gradient episodic memory for continual learning. In: *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30 (2017)
- Levin, D.A., Peres, Y., Wilmer, E.L.: *Markov Chains and Mixing Times*, 2nd edn. American Mathematical Society, Providence, RI (2017)
- Lan, G., Sartori, P., Neumann, S., Sourjik, V., Tu, Y.: The energy–speed–accuracy trade-off in sensory adaptation. *Nat. Phys.* **8**(5), 422–428 (2012) <https://doi.org/10.1038/nphys2276>
- McCloskey, M., Cohen, N.J.: Catastrophic interference in connectionist networks: the sequential learning problem. In: Bower, G.H. (ed.) *Psychology of Learning and Motivation* vol. 24, pp. 109–165. Academic Press, ??? (1989). [https://doi.org/10.1016/S0079-7421\(08\)60536-8](https://doi.org/10.1016/S0079-7421(08)60536-8)
- McAllester, D.A.: PAC-Bayesian model averaging. In: *Proceedings of the Twelfth Annual Conference on Computational Learning Theory (COLT)*, pp. 164–170 (1999). <https://doi.org/10.1145/307400.307435>
- Mandal, D., Jarzynski, C.: Work and information processing in a solvable model of Maxwell’s demon. *Proc. Natl. Acad. Sci. USA* **109**(29), 11641–11645 (2012) <https://doi.org/10.1073/pnas.1204263109>
- Mossio, M., Montévil, M., Longo, G.: Theoretical principles for biology: Organization. *Progress in Biophysics and Molecular Biology* **122**(1), 24–35 (2016) <https://doi.org/>

- Mehta, P., Schwab, D.J.: Energetic costs of cellular computation. *Proc. Natl. Acad. Sci. USA* **109**(44), 17978–17982 (2012) <https://doi.org/10.1073/pnas.1207814109>
- Maynard Smith, J., Szathmáry, E.: *The Major Transitions in Evolution*. Oxford University Press, Oxford (1995)
- Maturana, H.R., Varela, F.J.: *Autopoiesis and Cognition: The Realization of the Living*. D. Reidel, Dordrecht (1980)
- Olsson, C., Elhage, N., Nanda, N., Joseph, N., DasSarma, N., Henighan, T., Mann, B., Askell, A., Bai, Y., Chen, A., et al.: In-context learning and induction heads. *Transformer Circuits Thread*, Anthropic. <https://transformer-circuits.pub/2022/in-context-learning-and-induction-heads/> (2022)
- Pavliotis, G.A.: *Stochastic Processes and Applications: Diffusion Processes, the Fokker–Planck and Langevin Equations*. Texts in Applied Mathematics, vol. 60. Springer, New York (2014). <https://doi.org/10.1007/978-1-4939-1323-7>
- Power, A., Burda, Y., Edwards, H., Babuschkin, I., Misra, V.: Grokking: Generalization beyond overfitting on small algorithmic datasets (2022)
- Parrondo, J.M.R., Horowitz, J.M., Sagawa, T.: Thermodynamics of information. *Nat. Phys.* **11**(2), 131–139 (2015) <https://doi.org/10.1038/nphys3230>
- Parisi, G.I., Kemker, R., Part, J.L., Kanan, C., Wermter, S.: Continual lifelong learning with neural networks: A review. *Neural Netw.* **113**, 54–71 (2019) <https://doi.org/10.1016/j.neunet.2019.01.012>
- Perunov, N., Marsland, R.A., England, J.L.: Statistical physics of adaptation. *Phys. Rev. X* **6**(2), 021036 (2016) <https://doi.org/10.1103/PhysRevX.6.021036>
- Parr, T., Pezzulo, G., Friston, K.J.: *Active Inference: The Free Energy Principle in Mind, Brain, and Behavior*. MIT Press, ??? (2022). <https://doi.org/10.7551/mitpress/12441.001.0001>
- Pezzulo, G., Rigoli, F., Friston, K.J.: Hierarchical active inference: A theory of motivated control. *Trends Cogn. Sci.* **22**(4), 294–306 (2018) <https://doi.org/10.1016/j.tics.2018.01.009>
- Riemer, M., Cases, I., Ajemian, R., Liu, M., Rish, I., Tu, Y., Tesauero, G.: Learning to learn without forgetting by maximizing transfer and minimizing interference. In: *International Conference on Learning Representations (ICLR)* (2019)
- Reik, W.: Stability and flexibility of epigenetic gene regulation in mammalian development. *Nature* **447**(7143), 425–432 (2007) <https://doi.org/10.1038/nature05918>

- Rissanen, J.: Stochastic complexity and modeling. *Ann. Statist.* **14**(3), 1080–1100 (1986) <https://doi.org/10.1214/aos/1176350051>
- Rosen, R.: *Life Itself: A Comprehensive Inquiry Into the Nature, Origin, and Fabrication of Life*. Columbia University Press, New York (1991)
- Sourjik, V., Berg, H.C.: Receptor sensitivity in bacterial chemotaxis. *Proc. Natl. Acad. Sci. USA* **99**(1), 123–127 (2002) <https://doi.org/10.1073/pnas.011589998>
- Sivak, D.A., Crooks, G.E.: Thermodynamic metrics and optimal paths. *Phys. Rev. Lett.* **108**(19), 190602 (2012) <https://doi.org/10.1103/PhysRevLett.108.190602>
- Schwarz, G.: Estimating the dimension of a model. *Annals of Statistics* **6**(2), 461–464 (1978) <https://doi.org/10.1214/aos/1176344136>
- Schmidhuber, J.: A possibility for implementing curiosity and boredom in model-building neural controllers. In: *Proceedings of the International Conference on Simulation of Adaptive Behavior: From Animals to Animats*, pp. 222–227 (1991)
- Schreiber, T.: Measuring information transfer. *Phys. Rev. Lett.* **85**(2), 461–464 (2000) <https://doi.org/10.1103/PhysRevLett.85.461>
- Sharma, A., Czégel, D., Lachmann, M., Kempes, C.P., Walker, S.I., Cronin, L.: Assembly theory explains and quantifies selection and evolution. *Nature* **622**(7982), 321–328 (2023) <https://doi.org/10.1038/s41586-023-06600-9>
- Seifert, U.: Stochastic thermodynamics, fluctuation theorems and molecular machines. *Rep. Prog. Phys.* **75**(12), 126001 (2012) <https://doi.org/10.1088/0034-4885/75/12/126001>
- Schlimmer, J.C., Granger, R.H.: Incremental learning from noisy data. In: *Machine Learning vol. 1*, pp. 317–354 (1986). <https://doi.org/10.1007/BF00116895>
- Still, S., Sivak, D.A., Bell, A.J., Crooks, G.E.: Thermodynamics of prediction. *Phys. Rev. Lett.* **109**(12), 120604 (2012) <https://doi.org/10.1103/PhysRevLett.109.120604>
- Sagawa, T., Ueda, M.: Minimal energy cost for thermodynamic information processing: measurement and information erasure. *Phys. Rev. Lett.* **102**(25), 250602 (2009) <https://doi.org/10.1103/PhysRevLett.102.250602>
- Sagawa, T., Ueda, M.: Generalized Jarzynski equality under nonequilibrium feedback control. *Phys. Rev. Lett.* **104**(9), 090602 (2010) <https://doi.org/10.1103/PhysRevLett.104.090602>
- Treves, A., Panzeri, S.: The upward bias in measures of information derived from limited data samples. *Neural Comput.* **7**(2), 399–407 (1995) <https://doi.org/10.1162/neco.1995.7.2.399>

- Tishby, N., Pereira, F.C., Bialek, W.: The information bottleneck method (1999)
- Tsymbal, A.: The problem of concept drift: definitions and related work. Technical Report TCD-CS-2004-15, Department of Computer Science, Trinity College Dublin (2004)
- Williams, D.: Predictive coding and thought. *Synthese* **197**(4), 1749–1775 (2020) <https://doi.org/10.1007/s11229-018-1768-x>
- Wolpert, D.H.: The lack of a priori distinctions between learning algorithms. *Neural Comput.* **8**(7), 1341–1390 (1996) <https://doi.org/10.1162/neco.1996.8.7.1341>
- Wolpert, D.H.: The stochastic thermodynamics of computation. *J. Phys. A: Math. Theor.* **52**(19), 193001 (2019) <https://doi.org/10.1088/1751-8121/ab0850>
- Yi, T.-M., Huang, Y., Simon, M.I., Doyle, J.: Robust perfect adaptation in bacterial chemotaxis through integral feedback control. *Proc. Natl. Acad. Sci. USA* **97**(9), 4649–4653 (2000) <https://doi.org/10.1073/pnas.97.9.4649>